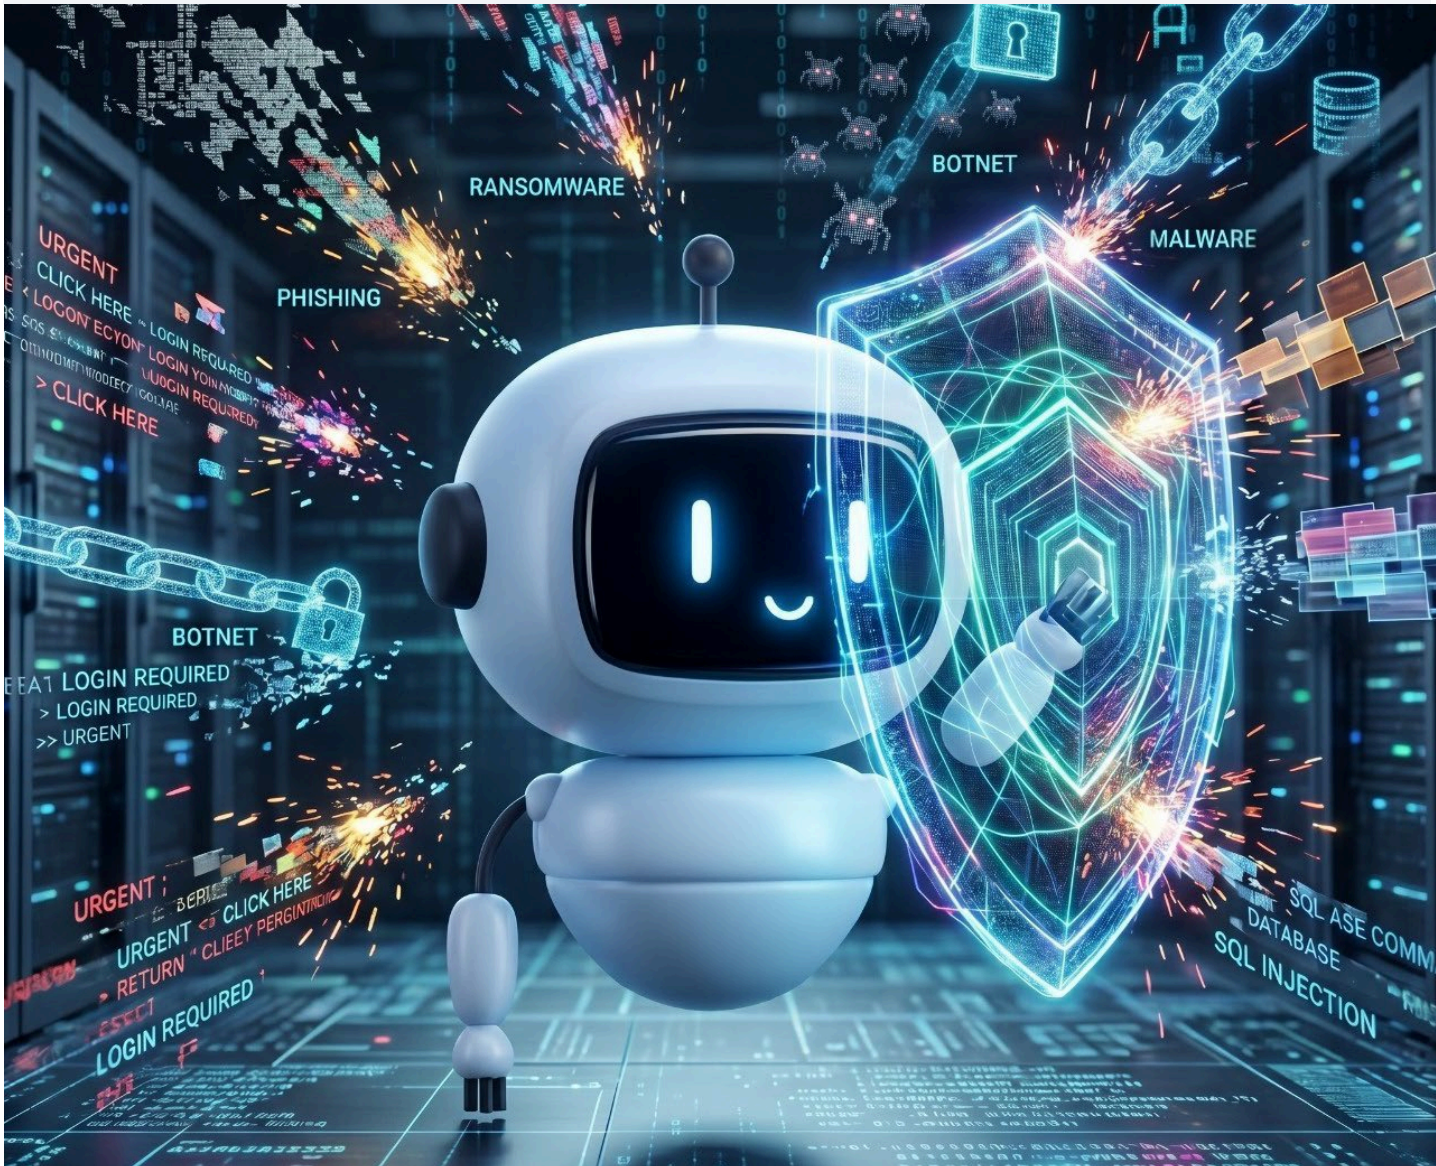
REPORT PROJECT

AI FOR CYBERSECURITY

A.A. 2025/2026

GRUPPO 16 – TRACCIA 1

LUONGO LEONARDO | 0622702606
MONDA FRANCESCO | 0622702620
PULZONE ANDREA | 0622702587



SOMMARIO

1. INTRODUZIONE 4

1.1. Obiettivi del progetto 4

1.2. Modello di Minaccia 4

1.3. Vincoli di Perturbazione (NORMA $L\infty$) 4

1.4. Modelli Pre-addestrati di Riferimento 4

2. PIPELINE DI VALUTAZIONE 5

2.1. Costruzione e Preparazione del Test Set 5

2.2. Pre-processing con MTCNN 5

2.3. Valutazione Baseline dell'Architettura NN1 5

2.4. Limitazioni dei formati classici delle immagini 5

2.4.1. Analisi del degrado lossy 6

2.4.2. Adozione del formato TIFF a 32-bit Floating-Point 6

2.5. Implementazione del Logger Cloud-Based 6

2.6. Evoluzione delle Metriche di Valutazione 6

3. ADVERSARIAL EXAMPLES 7

3.1. Scouting degli Iperparametri 7

3.2. Attacchi Error-Generic (Untargeted) 8

3.2.1. Metodologie di Valutazione Visiva e Quantitativa 8

3.2.2. Fast Gradient Sign Method (FGSM) UNTARGETED 9

3.2.3. Basic Iterative Method (BIM) UNTARGETED 10

3.2.4. Projected Gradient Descent (PGD) UNTARGETED 11

3.2.5. DeepFool UNTARGETED 12

3.2.6. Carlini & Wagner (C&W) UNTARGETED 13

3.2.7. Valutazione complessiva degli Attacchi Untargeted 17

3.3. Attacchi Error-Specific (Targeted) 18

3.3.1. Metodologie di Valutazione Visiva e Quantitativa 18

3.3.2. Fast Gradient Sign Method (FGSM) Targeted 19

3.3.3. Basic Iterative Method (BIM) Targeted 27

3.3.4. Projected Gradient Descent (PGD) Targeted 31

3.3.5. Carlini & Wagner (C&W) Targeted 35

3.3.6. Valutazione complessiva degli Attacchi targeted 37

4. VALUTAZIONE DELLA TRASFERIBILITÀ 38

4.1. Setup Sperimentale Black-Box 38

4.1.1. Sfide nella Trasferibilità Cross-Resolution 38

4.1.2. Scelta dell'Architettura Target: L'ipotesi RESNET50 e l'adozione di SENET50 39

4.1.3. Pre-processing e Normalizzazione Caffe per SENet50 40
4.2. Trasferibilità degli Attacchi Error-Generic (Untargeted) 41
4.2.1. Trasferibilità FGSM 41
4.2.2. Trasferibilità BIM 42
4.2.3. Trasferibilità PGD 43
4.2.4. Trasferibilità DeepFool 44
4.2.5. Trasferibilità C&W 45
4.3. Trasferibilità degli Attacchi Error-Specific (Targeted) 46
4.3.1. Trasferibilità FGSM (Targeted) 46
4.3.2. Trasferibilità BIM (Targeted) 48
4.3.3. Trasferibilità PGD (Targeted) 49
4.3.4. Trasferibilità C&W (Targeted) 50
5. MECCANISMO DI DIFESA 51
5.1. Preprocessing Pipeline 51
5.1.1. Scouting Individuale dei Filtri 51
5.1.2. Grid Search 3D e Selezione della Pipeline 51
5.1.3. Valutazione della Robustezza Post-Difesa 52
5.2. DENOSING AUTOENCODER (DAE) 56
5.2.1. Architettura e Addestramento (Float TIFF) 56
5.2.2. Denoising Purification 56
5.3. Anomaly Detection 59
5.3.1. Rilevamento Basato sull'Errore di Ricostruzione (MSE) 59
5.3.2. Definizione della Soglia e ROC Trade-off 59
6. CONCLUSIONI 63
6.1. Sintesi dell'Efficacia degli Attacchi e della Trasferibilità 63
6.2. Sviluppi Futuri 64

1. INTRODUZIONE

1.1. OBIETTIVI DEL PROGETTO

Il presente progetto (Traccia 1) ha l'obiettivo di analizzare in modo sistematico la vulnerabilità dei sistemi di riconoscimento facciale, valutandone la resilienza contro attacchi di tipo *evasion*. Lo studio si articola nella generazione, profilazione e valutazione di perturbazioni avversarie sotto stringenti vincoli di impercettibilità visiva (limite normativo L_∞).

Al fine di garantire la validità statistica degli esperimenti, la prima fase del lavoro si è concentrata sulla creazione di un dataset chiuso e bilanciato. Partendo dal dataset *VGGFace2*, è stata implementata una pipeline di campionamento per l'estrazione di un sottoinsieme composto da 100 identità distinte. Per ciascuna identità sono state campionate casualmente 10 immagini dalla partizione di test, ottenendo un dataset finale di 1000 campioni.

1.2. MODELLO DI MINACCIA

L'analisi della sicurezza del sistema è stata condotta formulando due distinti scenari di minaccia, definiti in base al livello di conoscenza a disposizione dell'attaccante:

- **Scenario White-Box:** L'attaccante ha conoscenza completa dell'architettura del modello bersaglio (oracolo), dei pesi addestrati e dei gradienti della funzione di costo. Questo scenario simula la vulnerabilità intrinseca della rete, permettendo la retropropagazione del gradiente per massimizzare l'efficacia della perturbazione. Tutti gli attacchi primari presentati in questo elaborato sono stati generati assumendo un contesto White-Box. *(Capitolo 3 – ADVERSARIAL EXAMPLES)*
- **Scenario Black-Box (Transferability):** L'attaccante non ha alcun accesso al modello schierato in produzione, ma genera l'attacco su un modello surrogato locale (White-Box) sperando che l'Esempio Avversario mantenga la sua efficacia una volta sottoposto al vero classificatore. Questo scenario modella le minacce nel mondo reale. Nel nostro progetto, tale dinamica è stata esplorata valutando la *transferability* degli attacchi generati. *(Capitolo 4 – VALUTAZIONE DELLA TRASFERIBILITÀ)*

1.3. VINCOLI DI PERTURBAZIONE (NORMA L_∞)

Il requisito fondamentale di un input avversario è che l'alterazione risulti impercettibile all'occhio umano. Per rispettare tale vincolo, il budget di perturbazione è stato rigorosamente limitato utilizzando la norma L_∞. Dato un input originale x e il suo corrispettivo avversario x_{adv} , è stato imposto il vincolo $|| x_{adv} - x ||_\infty \leq \epsilon$, garantendo che nessuna singola componente di colore venga alterata per una quantità superiore al limite $\epsilon = 0.1$ definito sperimentalmente.

1.4. MODELLI PRE-ADDESTRATI DI RIFERIMENTO

La valutazione architetturale è stata condotta avvalendosi di due modelli convoluzionali profondi, pre-addestrati sul dataset *VGGFace2* per la classificazione su 8631 identità.

Modello Sorgente (NN1): Il modello bersaglio primario (definito come *NN1*), utilizzato come oracolo in scenario White-Box, è basato sull'architettura **InceptionResnetV1**. Questa rete combina i moduli Inception con le connessioni residuali (ResNet), garantendo un'elevata capacità di astrazione delle *feature* facciali ed emettendo in output vettori latenti a 512 dimensioni e logit su 8631 classi.

Modello Target (NN2): Per simulare il contesto Black-Box e analizzare la trasferibilità delle perturbazioni, è stata introdotta una seconda architettura (definita *NN2*), basata sul modello **SENet50** (Squeeze-and-Excitation Networks). L'adozione di SENet50 fornisce un banco di prova ideale per la *transferability* a causa delle divergenze strutturali rispetto a NN1: oltre a sfruttare i meccanismi di ricalibrazione adattiva dei canali (SE blocks), SENet richiede pipeline di pre-processing dell'input intrinsecamente differenti, necessitando di tensori normalizzati secondo lo standard Caffe (formato BGR con sottrazione delle medie fisse) rispetto alla normalizzazione standard operata da InceptionResnetV1.

2. PIPELINE DI VALUTAZIONE

2.1. COSTRUZIONE E PREPARAZIONE DEL TEST SET

La generazione del set di valutazione ha richiesto l'allineamento tra i metadati delle cartelle sorgenti e l'output atteso delle reti neurali. Tramite un modulo di mappatura delle identità appositamente sviluppato, le stringhe identificative del dataset originale (es. *n007126*) sono state mappate deterministicamente all'indice di classe di addestramento atteso dalle reti (0-8630).

2.2. PRE-PROCESSING CON MTCNN

Le reti di estrazione delle *feature* facciali sono altamente sensibili al rumore di fondo (background) presente nelle immagini. Per stabilire una baseline di accuratezza rigorosa per la rete NN1, è stato condotto un esperimento A/B sull'introduzione di una fase di allineamento e ritaglio (Cropping).
Da un lato, le immagini sono state ridimensionate e sottoposte direttamente al modello; dall'altro, è stato utilizzato **MTCNN** (Multi-task Cascaded Convolutional Networks) per il rilevamento strutturale dei volti. I risultati dell'esperimento hanno dimostrato che il passaggio passivo dell'intera immagine al classificatore degrada in modo significativo le prestazioni. Viceversa, delegare a MTCNN l'isolamento del *bounding box* facciale e sottoporre solo quest'ultimo alla rete InceptionResnetV1 ha permesso di massimizzare l'accuratezza in fase di *Clean Evaluation*. Questo ha validato la scelta di utilizzare immagini pre-ritagliate come punto di partenza per tutti gli step di attacco successivi.

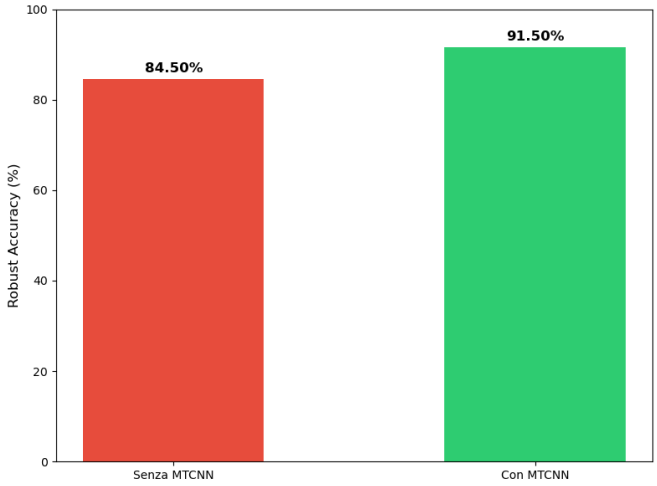


Figura 1 - Valutazione Pre-processing con MTCNN

2.3. VALUTAZIONE BASELINE DELL'ARCHITETTURA NN1

A seguito del filtraggio via MTCNN, le immagini sono state scalate alla risoluzione attesa dalla rete NN1 (160×160 pixel). Sulle immagini così processate è stata calcolata la metrica di riferimento (*Clean Accuracy*). Per garantire che la generazione degli Adversarial Examples fosse matematicamente significativa, la pipeline scarta sistematicamente tutti i campioni che la rete classifica in modo errato già in assenza di rumore avversario (filtro *zero-shot*). In questo modo, ogni successo registrato in fase di attacco è imputabile unicamente all'efficacia della perturbazione e non a incertezze pregresse del modello.

2.4. LIMITAZIONI DEI FORMATI CLASSICI DELLE IMMAGINI

Una sfida nella valutazione della robustezza avversaria riguarda il salvataggio fisico degli Adversarial Examples. Le perturbazioni ottimali generate dai gradienti esistono come tensori a virgola mobile continua in un range $[0.0, 1.0]$.

2.4.1. ANALISI DEL DEGRADO LOSSY

Si è osservato che il salvataggio in formato JPG vanifica l'attacco: la compressione *lossy* agisce da naturale meccanismo di difesa, distruggendo le alte frequenze in cui risiede il rumore avversario.
Un salvataggio raw tramite vettori NumPy mantiene l'integrità matematica assoluta, ma impedisce l'ispezione visiva e la compatibilità con librerie di computer vision standard.
L'adozione del formato PNG per quantizzare i tensori nel classico dominio intero $UINT8 \in [0,255]$, seppur funzionale, ha rivelato lievi artefatti di quantizzazione che, se sommati a perturbazioni ϵ estremamente restrittive, andavano ad alterare il corretto calcolo della norma L_∞.

2.4.2. ADOZIONE DEL FORMATO TIFF A 32-BIT FLOATING-POINT

Per risolvere il problema della quantizzazione, l'intera pipeline di input/output è stata riprogettata per adottare il formato **TIFF a 32-bit Floating-Point**. Questa scelta ha permesso di salvare su disco le immagini con la medesima precisione in virgola mobile dei tensori presenti nella VRAM della GPU. L'adozione del TIFF a 32-bit garantisce che la valutazione del budget perturbativo $L_\infty = \max \mid x_{adv} - x_{clean} \mid$ risulti matematicamente esatta, preservando i micro-gradienti calcolati da attacchi complessi (come Carlini & Wagner) e rendendo le immagini resistenti a distorsioni di salvataggio.

2.5. IMPLEMENTAZIONE DEL LOGGER CLOUD-BASED

Data l'enorme mole di esecuzioni, l'esplorazione multi-strategia e il tuning degli iperparametri su decine di valori ϵ, si è resa necessaria un'infrastruttura di tracciamento automatizzata e asincrona. È stato implementato un modulo di monitoraggio degli esperimenti appoggiato alle API di **Google Sheets**. Ad ogni conclusione di batch, la pipeline invia in cloud i log dell'esperimento. Questo sistema ha garantito la centralizzazione immediata dei risultati prodotti da diverse sessioni di elaborazione, strutturando i record mediante campi chiave quali: *Timestamp, Tester, Tipo di Attacco, Strategia, Valore Epsilon, Difesa, Robust Accuracy, Targeted ASR, Untargeted ASR* e *Note di esecuzione.*
LINK: [*Ai4CyberProject-Group16*]

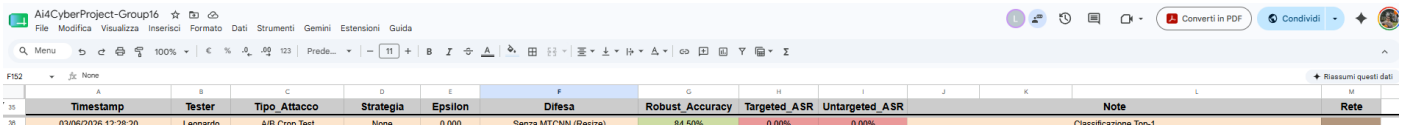


Figura 2 - File Logger

2.6. EVOLUZIONE DELLE METRICHE DI VALUTAZIONE

Nel campo della biometria standard, le prestazioni vengono misurate tramite il False Acceptance Rate (FAR) e il False Rejection Rate (FRR), basandosi su una distanza calcolata (es. similarità coseno) rispetto a una soglia prestabilita. Tuttavia, le librerie di attacco (*Adversarial Robustness Toolbox - ART*) operano una massimizzazione dell'errore di classificazione diretta sui logit emessi in fase di *Top-1 prediction*.
Di conseguenza, per coerenza matematica con l'obiettivo degli ottimizzatori, si è deciso di valutare la sicurezza non più come un task di similarità biometrica, ma come un task di *image classification robustness*, definendo tre metriche primarie:

- **Robust Accuracy:** La percentuale di immagini del test set che, pur essendo state alterate, vengono ancora predette correttamente dal modello ($y_{adv} = y_{true}$). È l'indice principale di resilienza della rete.
- **Untargeted Attack Success Rate (u-ASR):** Utilizzata negli attacchi *Error-Generic*, rappresenta la percentuale di immagini in cui l'attacco è riuscito a variare la predizione rispetto alla classe originale, causando una qualsiasi classificazione errata ($y_{adv} \neq y_{true}$). È complementare alla *Robust Accuracy*.
- **Targeted Attack Success Rate (t-ASR):** Utilizzata negli attacchi *Error-Specific*, indica la percentuale di immagini che l'attaccante è riuscito a far classificare **esattamente** come la specifica classe bersaglio scelta ($y_{adv} = y_{target}$).

3. ADVERSARIAL EXAMPLES

Il nucleo operativo dell'esperimento risiede nella perturbazione sistematica dei campioni appartenenti al test set, al fine di indurre la rete NN1 (InceptionResnetV1) in errore. Tutti gli attacchi presentati in questa sezione operano nel contesto *White-Box* e sono sottoposti a un rigoroso limite di percettibilità formulato attraverso il budget perturbativo massimo consentito, definito dalla norma L_∞.

Sebbene il Threat Model imponesse un limite di impercettibilità a $\epsilon = 0.1$, si è scelto di condurre uno stress test spingendo la perturbazione fino a 0.2. Estendere l'intervallo di indagine ha consentito di tracciare le Security Evaluation Curves nella loro interezza. L'obiettivo statistico era osservare la derivata del decadimento (quanto velocemente crolla la confidenza) in condizioni di rumore estremo, permettendo un'analisi del trend che a 0.1 sarebbe risultata incompleta. Questo ha permesso di individuare il vero breakdown point delle reti, dimostrando non solo se il modello resiste, ma come e quando crolla definitivamente. Il tutto chiaramente realizzato al solo scopo di analisi esplorativa e per nulla valutativa.

La valutazione è stata divisa in due macrocategorie in base all'obiettivo dell'ottimizzatore: attacchi *Error-Generic* (Untargeted) e attacchi *Error-Specific* (Targeted).

3.1. SCOUTING DEGLI IPERPARAMETRI

Prima di procedere alla generazione degli Adversarial Examples, è stata condotta una rigorosa fase di *scouting* per ciascun algoritmo di evasione.

Al fine di individuare la configurazione ideale, è stata implementata un'architettura di **Grid Search automatizzata on-the-fly**, ovvero senza salvare localmente le immagini avversarie generate.

L'ottimizzazione degli iperparametri è stata condotta inizialmente su un sottoinsieme di validazione estratto dal dataset pulito; la configurazione risultante è stata poi testata sull'intero dataset per verificarne l'effettiva capacità di generalizzazione.

Questo processo di *tuning* ha permesso di mappare empiricamente lo spazio di ricerca per ottimizzare il *trade-off* tra *Attack Success Rate* (ASR) e costo computazionale (tempo di inferenza/generazione), valutando la risposta della rete al variare dei seguenti parametri critici:

- **Budget e Passo di Discesa (ϵ e α):** Per algoritmi iterativi (BIM e PGD), la convergenza dipende dal bilanciamento tra l'intensità totale e la grandezza del singolo *step* di aggiornamento. Per massimizzare l'esplorazione del gradiente senza sconfinare L_∞, lo step size è stato calibrato dinamicamente implementando la nota **Regola di Madry** ($\alpha = 2.5 \cdot \frac{\epsilon}{N_{iter}}$), variando il fattore moltiplicativo (2.5 per BIM e 1.5 per PGD).
- **Iterazioni e Inizializzazione (Max Iter e Random Restarts):** È stata delineata la curva di saturazione dell'accuratezza all'aumentare dei cicli di ottimizzazione. Tale curva ha permesso la scelta ottimale dei parametri per i vari tipi di attacchi.

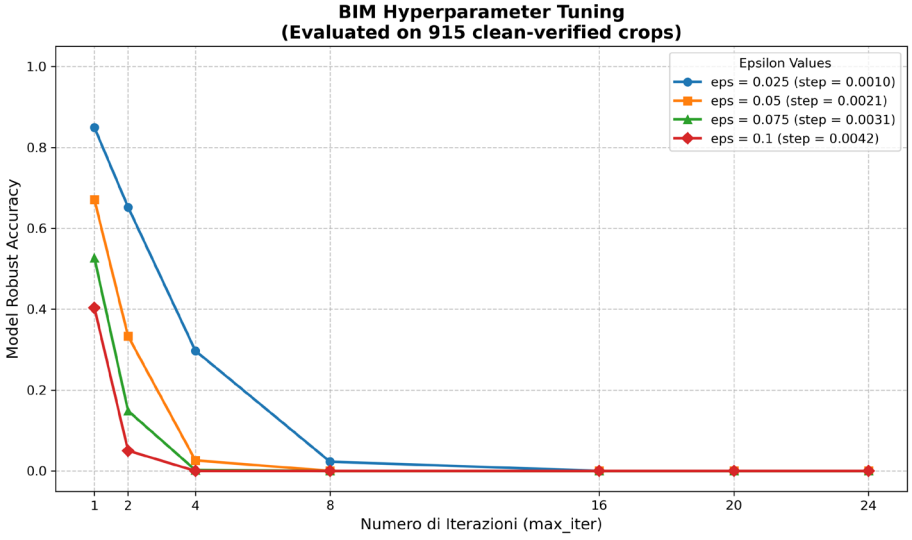


Figura 3 - Valutazione degli Iperparametri (con BIM)

- **Costanti di Approssimazione (Overshoot e Learning Rate):** Per algoritmi *margin-based* (DeepFool e Carlini & Wagner), lo scouting ha esplorato diverse scale logaritmiche per il *Learning Rate* e l'iperparametro di *Overshoot*. Per ottimizzare i tempi di esecuzione durante la Grid Search, è stato introdotto un meccanismo di Early Stopping. Tale criterio interrompe il ciclo iterativo nel momento in cui l'accuratezza del modello decade allo 0%, evitando l'esecuzione di iterazioni superflue. A seguito dell'interruzione anticipata, la pipeline procede in automatico alla valutazione del successivo valore di ϵ.

Solamente a valle di questa mappatura topologica degli iperparametri, registrata nei log di profilazione, sono stati finalizzati i setup per le successive fasi di generazione *Untargeted* e *Targeted*.

3.2. ATTACCHI ERROR-GENERIC (UNTARGETED)

L'obiettivo di un attacco Untargeted è massimizzare la funzione di costo (Loss) rispetto alla classe corretta y_{true}, spingendo il vettore di input al di fuori della regione di decisione associata all'identità originale, senza curarsi di quale sarà la nuova etichetta predetta.

3.2.1. METODOLOGIE DI VALUTAZIONE VISIVA E QUANTITATIVA

Prima di procedere con l'analisi dettagliata dei singoli attacchi Error-Generic (Untargeted), è opportuno definire le metodologie di valutazione adottate. Per quantificare e analizzare l'impatto delle perturbazioni, sono state formalizzate tre logiche di rappresentazione visiva, basate sui metadati estratti dalla pipeline e storicizzati in cloud:

- **Security Evaluation Curve:** Un grafico cartesiano che traccia il decadimento della *Robust Accuracy* all'aumentare del budget perturbativo ϵ. Questo strumento permette di confrontare l'efficacia dei diversi algoritmi d'attacco, evidenziando quale metodologia provochi più rapidamente il collasso delle prestazioni del modello.
- **Confidence Degradation Plot:** Rappresentato tramite *Boxplot*, questo grafico analizza l'andamento della probabilità (Softmax) assegnata dalla rete alla classe corretta. Esso rivela l'efficacia intrinseca dell'attacco: anche nei casi in cui l'algoritmo fallisca nell'alterare la predizione *top-1* (ovvero quando la rete resiste), si evince come la perturbazione distrugga quasi totalmente la confidenza matematica del classificatore, facendola crollare da percentuali prossime al 99% verso l'incertezza assoluta. È stato realizzato questo grafico per tutti gli attacchi, ma verrà mostrato solo negli attacchi in cui la degradazione è rappresentativa, come in Deepfool e Carlini & Wagner.
- **Perturbation Showcase:** Una campionatura visiva progettata per esporre qualitativamente gli effetti dell'attacco sui tensori di input. Per ciascuna istanza, viene messo a confronto il campione originale, il rumore avversario isolato (opportunamente amplificato per renderlo visibile) e l'immagine avversaria finale, corredati dalle rispettive predizioni della rete. Questa rappresentazione è fondamentale per valutare empiricamente l'effettivo limite di percettibilità umana della distorsione in relazione al budget ϵ impiegato.

3.2.2. FAST GRADIENT SIGN METHOD (FGSM) UNTARGETED

L'FGSM rappresenta la baseline algoritmica della sicurezza avversaria. È un attacco *single-step* che calcola il gradiente della funzione di perdita rispetto all'immagine di input e applica un'unica perturbazione di magnitudo ϵ nella direzione del segno del gradiente. Pur essendo computazionalmente estremamente rapido, tende a produrre perturbazioni sub-ottimali, rivelandosi facilmente gestibile dal modello per bassi valori del budget. Come si evince dalla Figura 4, il valore migliore di ϵ risulta essere 0.050 con una Robust Accuracy pari a 0.11%.

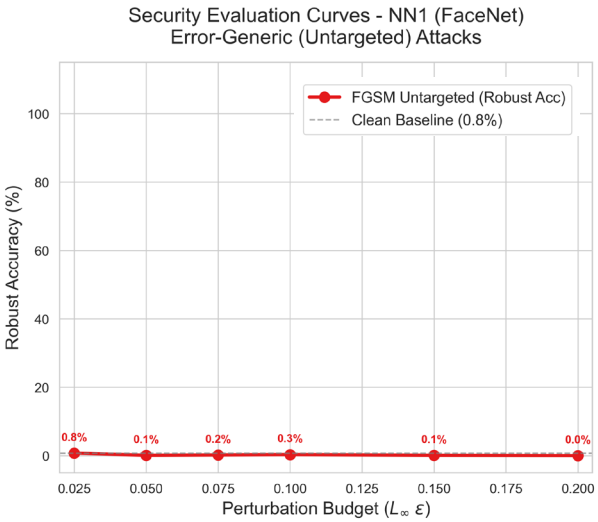


Figura 4 - Security Evaluation Curve - FGSM Untargeted

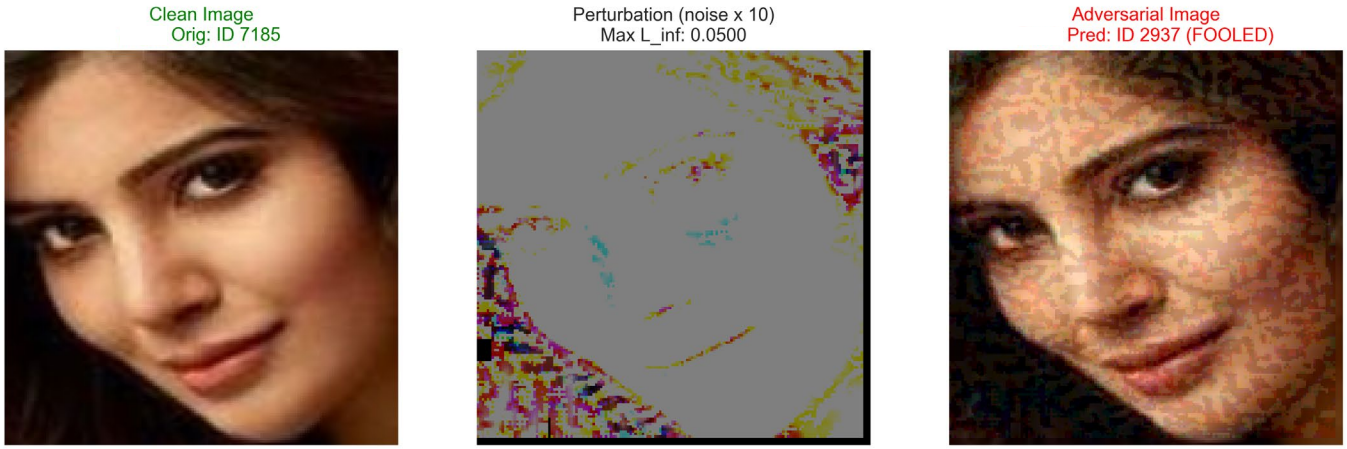


Figura 5 - Perturbation Showcase ($\epsilon = 0.050$)

3.2.3. BASIC ITERATIVE METHOD (BIM) UNTARGETED

Il BIM evolve il concetto dell'FGSM introducendo un processo di ottimizzazione iterativa. L'algoritmo applica perturbazioni multiple di passo frazionario α

$$\text{con } \alpha = \frac{\epsilon}{MAX_ITER},$$

calcolando nuovamente il gradiente ad ogni iterazione. Dopo la fase di scouting, è stato scelto un valore di **MAX ITER** pari a **4** che permetteva al sistema di raggiungere un Accuracy pari a 0 nel dominio degli ϵ disponibili. Come si evince dalla Figura 6, il valore migliore di ϵ risulta essere 0.1 con una Robust Accuracy pari a 0.0%.

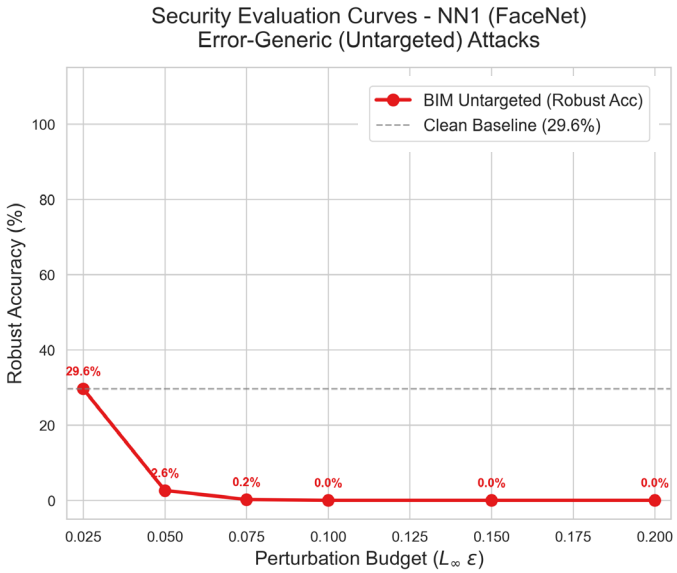


Figura 6 - Security Evaluation Curve - BIM Untargeted

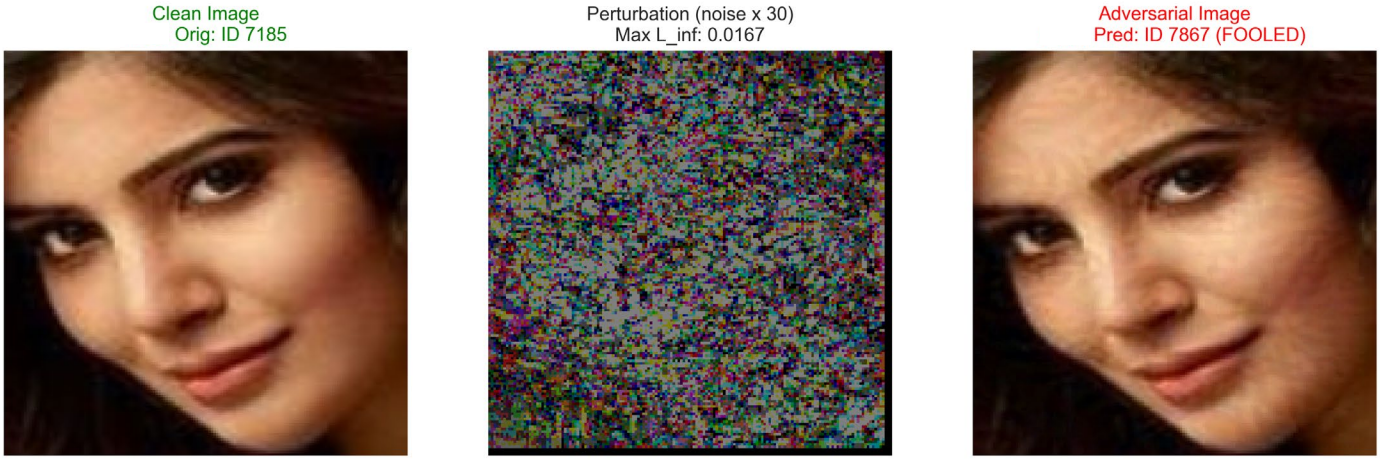


Figura 7 - Perturbation Showcase ($\epsilon = 0.1$)

3.2.4. PROJECTED GRADIENT DESCENT (PGD) UNTARGETED

L'algoritmo PGD condivide l'architettura iterativa del BIM, ma introduce una fase di inizializzazione casuale del rumore all'interno del limite ϵ prima di iniziare l'ottimizzazione. Per far fronte alle geometrie non convesse della funzione di *loss*, il setup sperimentale ha esplorato l'uso di molteplici *random restarts* e moltiplicatori dinamici del passo di discesa. Nello specifico, la configurazione adottata prevede 3 **inizializzazioni casuali (**`num_init = 3`**)**, un limite di 4 **iterazioni massime (**`max_iter = 4`**)** e un **moltiplicatore del passo pari a** 1.5. Al termine di questo processo esplorativo, l'algoritmo seleziona empiricamente la perturbazione che genera il danno maggiore (ossia l'esito *worst-case*).
Come si evince dalla Figura 8, il valore migliore di ϵ risulta essere 0.015 con una Robust Accuracy pari a 0.0%.

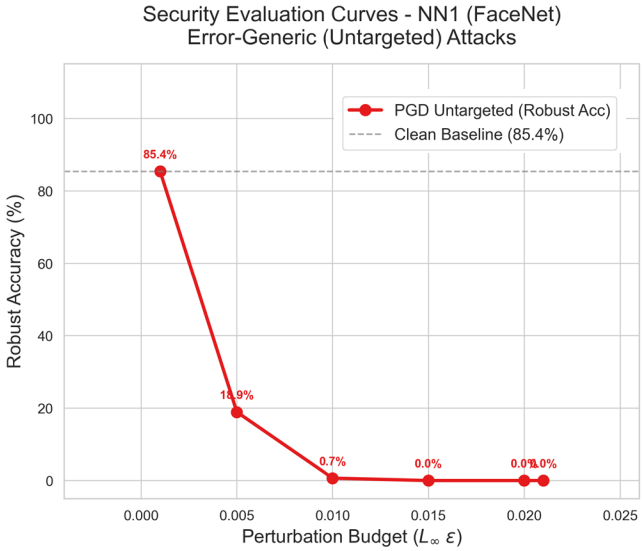


Figura 8 - Security Evaluation Curve - PGD Untargeted

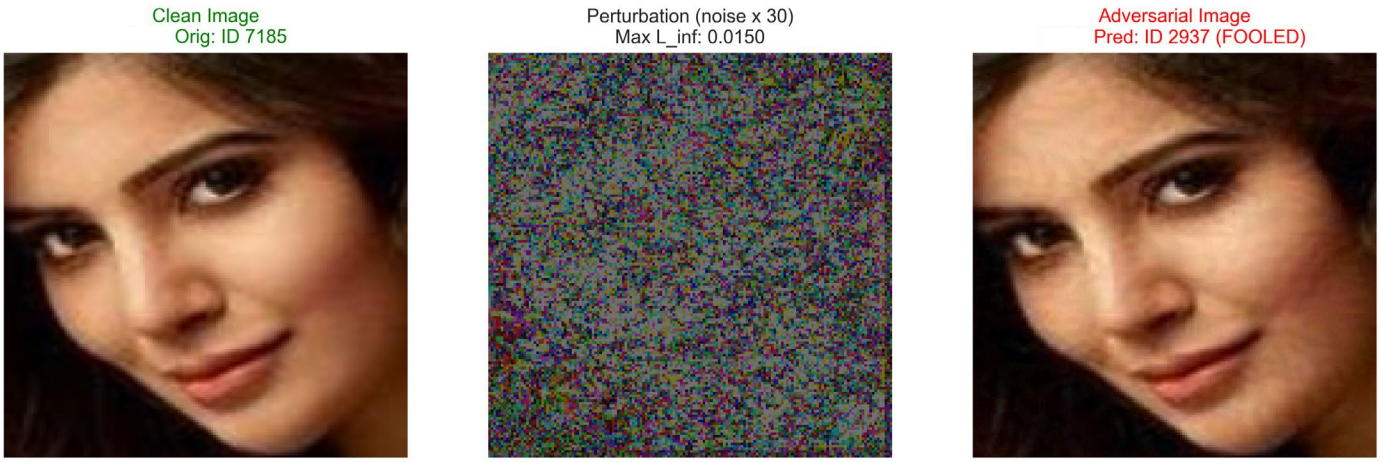


Figura 9 - Perturbation Showcase ($\epsilon = 0.015$)

3.2.5. DEEPFOOL UNTARGETED

DeepFool è un attacco iterativo progettato per calcolare la minima perturbazione necessaria a oltrepassare il confine decisionale, approssimando la regione di decisione del classificatore tramite iperpiani lineari. Poiché l'algoritmo nativamente non impiega un parametro ϵ stringente come criterio di terminazione, nel setup sperimentale l'output è stato sottoposto a una fase di *clipping* dinamico a posteriori. L'efficacia dell'attacco è stata poi valutata misurando la frazione di campioni avversari rientranti nei diversi intervalli del budget ϵ analizzati. Per calibrare l'approssimazione lineare e limitare il costo computazionale, la configurazione dell'ottimizzatore ha previsto un **fattore di compensazione** pari a 0.15 (`overshoot = 0.15`), un tetto massimo di 5 iterazioni (`max_iter = 5`) e il calcolo dei gradienti basato sulle 3 classi più probabili (`nb_grads = 3`). Come si evince dalla Figura 10, il valore migliore di ϵ risulta essere 0.1 con una Robust Accuracy pari a 0.11%.

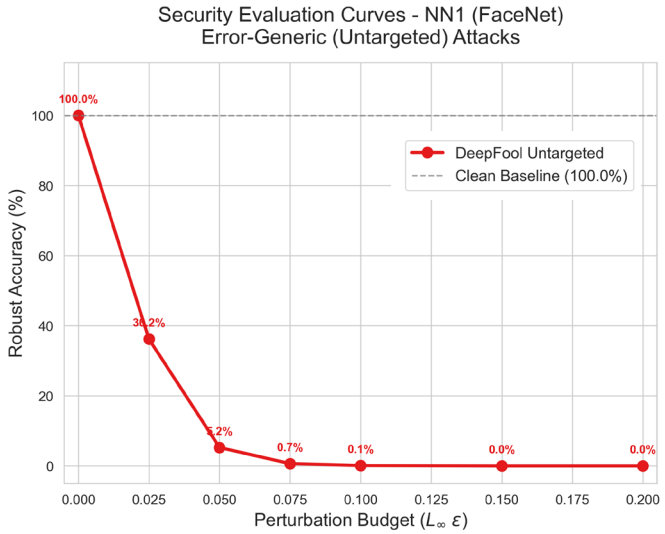


Figura 10 - Security Evaluation Curve - Deepfool Untargeted

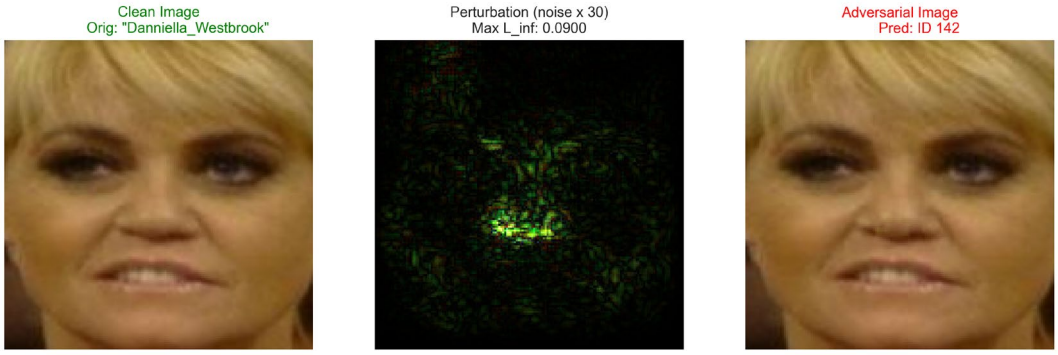


Figura 11 - Perturbation Showcase ($\epsilon = 0.015$)

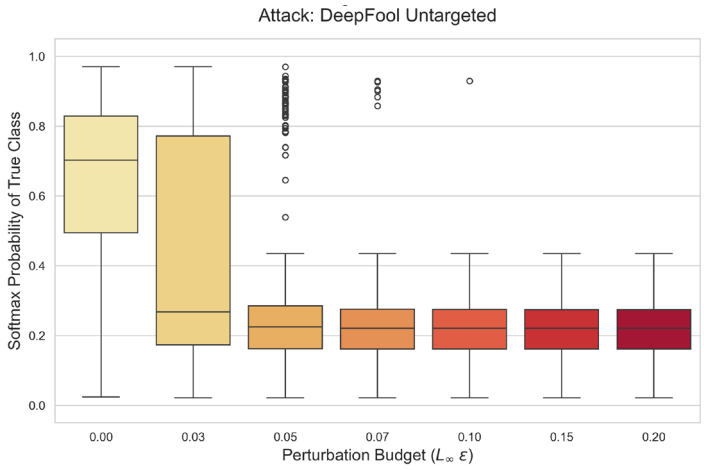


Figura 12 - Confidence Degradation on True Class

3.2.6. CARLINI & WAGNER (C&W) UNTARGETED

L'algoritmo Carlini & Wagner affronta il problema dell'evasione da una prospettiva puramente ottimizzata. Nello scenario *Error-Generic* (Untargeted), l'obiettivo non è proiettare una perturbazione massiva entro un budget ϵ predefinito, ma formulare una funzione di costo *margin-based* capace di penalizzare il logit della classe originale (y_{true}) a favore della classe estranea più prominente. L'algoritmo non ottimizza direttamente i pixel, ma opera su una trasformazione $tanh$ dell'immagine per aggirare i vincoli di clipping, bilanciando la distanza L_∞ e la funzione obiettivo tramite una ricerca binaria della costante c.

Poiché l'implementazione standard di C&W (es. libreria ART) risulta computazionalmente proibitiva per via dei cicli annidati sequenziali e soffre di severi limiti di approssimazione numerica per micro-budget, all'interno del progetto è stata sviluppata un'implementazione *custom* in PyTorch, con l'obiettivo di creare un clone della classe `CarliniLInfMethod` del framework ART. Le ottimizzazioni hanno incluso:

- **Architettura in Double Precision (64-bit) e Anti-Degrado:** Per calcolare perturbazioni minime nell'ordine di grandezza di 10^{-3}, lo standard Floating-Point a 32-bit genera fatali errori di quantizzazione sui gradienti. L'intero modello (InceptionResnetV1) è stato pertanto forzato in *Double Precision* (Float64). Per impedire alla libreria sottostante di effettuare *downcasting*, è stato progettato un modulo ARTFloat64Wrapper che intercetta i tensori e ne preserva l'integrità numerica a 64 bit durante l'intero *forward pass*.
- **Ricerca Binaria Vettorizzata:** I cicli *while* dipendenti dallo stato del singolo campione sono stati sostituiti da un'architettura completamente *batched*. Sfruttando lo slicing dinamico e l'uso di maschere booleane (active_tau_mask), l'algoritmo aggiorna dinamicamente i margini di ricerca simultaneamente per tutti i tensori allocati nella VRAM, diminuendo enormemente il carico computazionale.
- **Ottimizzatore Adam Custom In-Place (Senza CPU-Sync):** Invece di interrompere il ciclo con un *Early Stopping* convenzionale (che richiederebbe una lenta sincronizzazione continua tra CPU e GPU), l'aggiornamento dei gradienti è delegato a un modulo PyTorchCustomAdam. Questo ottimizzatore vettorizzato opera in modalità *in-place* tramite maschere attive (active_adam_mask), lasciando scorrere le iterazioni in "pipe puro" sulla GPU. Questo riduce il traffico in VRAM e massimizza la velocità di convergenza.

Tramite questa implementazione, l'algoritmo individua autonomamente la minima distorsione assoluta (L_∞) strettamente necessaria per attraversare il confine decisionale più vicino. I valori degli iperparametri scelti per la generazione degli attacchi avversari sono MAX_ITER = 5 e LEARNING RATE = 0.005.

Con questa ottimizzazione, usando la double precision, per lo scouting dei parametri abbiamo impiegato 15 minuti. Per la generazione di 1000 immagini avversarie, lo script ha impiegato circa 1h.

Svolgendo i calcoli in Float, i tempi si riducono a pochi secondi poiché l'hardware a disposizione (nvidvia 5070Ti) è ottimizzato per operazioni Float. Tuttavia, questo formato di dati, comporta anche un'approssimazione troppo marcata dovuta agli hardware utilizzati dai due algoritmi (ART si avvale della CPU, mentre Pytorch della GPU). Con un tipo Double, l'errore di approssimazione è trascurabile, abbiamo quindi scelto questo approccio per tenerci in linea con il framework ART. Nella prossima pagina sono riportate delle metriche che evidenziano la differenza tra i risultati ottenuti con ART ed il nostro clone pytorch.

```
                        [RISULTATI UNTARGETED]
          | Metrica         | ART Originale | Custom ART-Match |
          |-----------------|---------------|------------------|
          | Tempo (sec)     |        751.78 |            49.70 |
          | Success Rate    |        100.0% |           100.0% |
          | L_inf Max       |        0.0100 |           0.0100 |
          | L_inf Mean      |        0.0065 |           0.0065 |

                  [RISULTATI TARGETED (Least-Likely)]
          | Metrica         | ART Originale | Custom ART-Match |
          |-----------------|---------------|------------------|
          | Tempo (sec)     |        738.20 |            49.69 |
          | Success Rate    |         40.0% |            40.0% |
          | L_inf Max       |        0.0448 |           0.0448 |
          | L_inf Mean      |        0.0154 |           0.0154 |


      ============================================================
            VERIFICA IDENTICITÀ (CLONE vs ART - UNTARGETED)
      ============================================================
       Predizioni di Rete Identiche : 10/10 immagini corrispondono
      ------------------------------------------------------------
      L_inf Budget (Estremo Max)   : Clone=0.010006 | ART=0.010006
      L_inf Budget (Valore Medio)  : Clone=0.006502 | ART=0.006502
      ------------------------------------------------------------
             Differenza Rumore (Max)      : 2.98023168e-08
             Differenza Rumore (Min)      : 4.32986980e-15
             Differenza Rumore (Media)    : 9.78431052e-09
      ------------------------------------------------------------
                  Funzionalmente Equivalenti   : True
    [Plot] Seleziono l'immagine 6 per il plot. Differenza Max: 0.000000

      ============================================================
             VERIFICA IDENTICITÀ (CLONE vs ART - TARGETED)
      ============================================================
       Predizioni di Rete Identiche : 10/10 immagini corrispondono
      ------------------------------------------------------------
      L_inf Budget (Estremo Max)   : Clone=0.044814 | ART=0.044814
      L_inf Budget (Valore Medio)  : Clone=0.015403 | ART=0.015403
      ------------------------------------------------------------
             Differenza Rumore (Max)      : 2.98022235e-08
             Differenza Rumore (Min)      : 0.00000000e+00
             Differenza Rumore (Media)    : 4.05384949e-09
      ------------------------------------------------------------
    Funzionalmente Equivalenti   : True (Tolleranza Batch-CuDNN applicata)
     [Plot] Seleziono l'immagine 4 per il plot. Differenza Max: 0.000000
```

Per imitare ART al massimo ma battere i tempi di esecuzione utilizzando la GPU, abbiamo anche risolto un bug nel metodo `CarliniLInfMethod.generate` nel caso targeted. In particolare, l'implementazione originale della libreria ART presentava un errore logico nella condizione che verifica il successo della

perturbazione avversaria durante il ciclo di ottimizzazione. Nel codice nativo, l'algoritmo valutava la validità dell'esempio avversario generato richiedendo indistintamente che la classe predetta dal modello fosse diversa dall'etichetta di riferimento (y_batch), applicando sempre l'operatore di disuguaglianza (!=). Sebbene questo approccio sia matematicamente e logicamente corretto per gli attacchi untargeted (in cui l'obiettivo è massimizzare la distanza dalla classe originale), risulta invece fallace per gli scenari mirati. Negli attacchi targeted, infatti, il tensore y_batch rappresenta la classe bersaglio desiderata dall'attaccante. A causa di questa svista nell'implementazione originale, l'algoritmo scartava sistematicamente le perturbazioni valide, considerando "falliti" proprio quegli esempi avversari che riuscivano con successo a ingannare il classificatore forzandolo verso la classe target. Per ovviare a questa anomalia, abbiamo riscritto il blocco di controllo introducendo una diramazione logica dipendente dal flag booleano self.targeted. Nel caso mirato, il criterio di accettazione è stato modificato richiedendo l'uguaglianza stretta tra la predizione del modello e l'etichetta target (pred_labels == target_labels).

I dati empirici raccolti dimostrano la netta superiorità di questo approccio rispetto alle tecniche basate esclusivamente sull'ascesa del gradiente (come PGD o BIM). Valutando le immagini avversarie tramite il calcolo dinamico degli ϵ (basato sui percentili esatti del rumore generato), l'aspetto più eclatante emerge dall'osservazione della scala delle ascisse, che opera su ordini di grandezza nettamente inferiori.
Il grafico della *Robust Accuracy* (Figura 13) descrive un cedimento strutturale immediato del classificatore. Da una baseline del 100.0%, l'accuratezza viene letteralmente dimezzata (58.9%) con una perturbazione quasi impercettibile ($\epsilon \approx 0.0025$). L'algoritmo continua a erodere inesorabilmente la resistenza della rete, causando il collasso totale (*Robust Accuracy* allo 0.0%) a un valore di $\epsilon \approx 0.0126$.

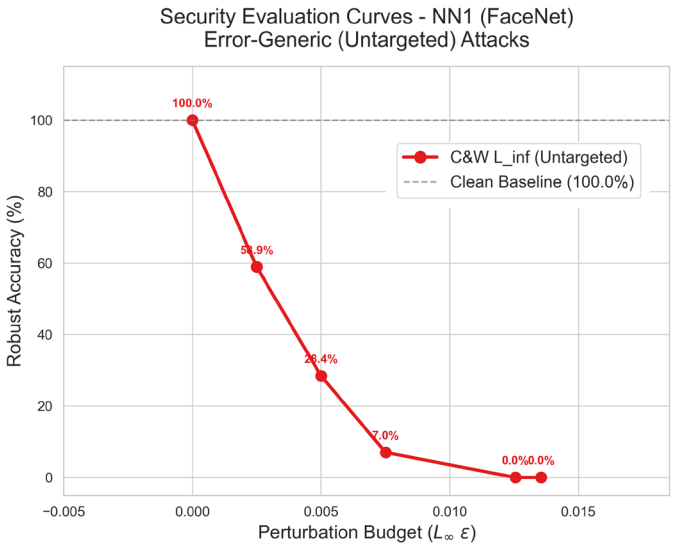


Figura 13 - Security Evaluation Curve – C&W Untargeted

Il Boxplot relativo al degrado della confidenza (Figura 14) conferma la natura precisa del C&W. A differenza di altri algoritmi che causano un decadimento graduale, C&W svuota quasi istantaneamente il bacino probabilistico della classe corretta. Già a $\epsilon = 0.0050$, la mediana della probabilità *Softmax* precipita a ridosso dello zero. Questo dimostra che la perturbazione non si limita a confondere marginalmente la rete, ma ne distrugge la certezza matematica alla radice.

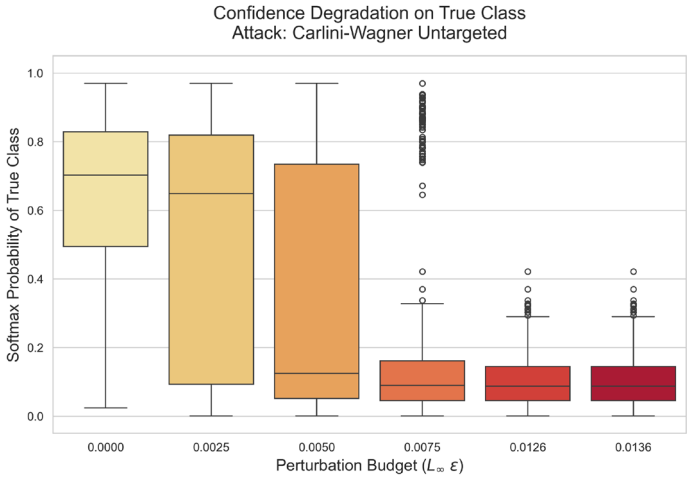


Figura 14 - Confidence Degradation on True Class

La natura sofisticata del C&W è ulteriormente dimostrata dall'analisi visiva della matrice di rumore nel *Perturbation Showcase* (Figura 15). Amplificando artificialmente il rumore calcolato sull'immagine campione (estratta dal TIFF a 32-bit), si nota un pattern profondamente diverso dal classico rumore stocastico globale generato dagli altri attacchi. La perturbazione assume chiari connotati strutturali, delineando in negativo le *feature* antropometriche del volto (i contorni degli occhi, del naso e delle ombreggiature).
Questo fenomeno certifica che l'algoritmo C&W non spreca energia perturbativa iniettando rumore nei pixel di background, ma aggredisce attivamente ed esclusivamente le alte frequenze semantiche estratte dai filtri convoluzionali di InceptionResnetV1. È proprio questa efficienza spaziale a permettere l'evasione del modello con valori di L_∞ così ristretti.

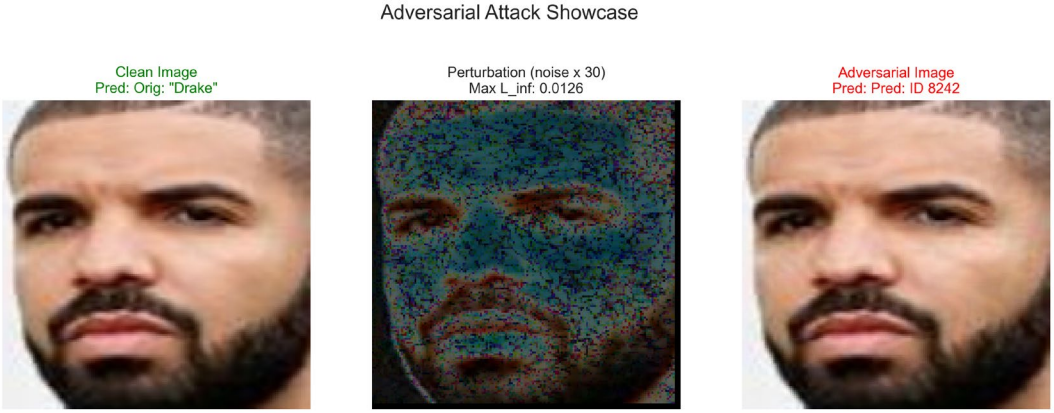


Figura 15 - Perturbation Showcase ($\epsilon = 0.0126$)

Nello scenario *Untargeted*, per l'algoritmo Carlini & Wagner, il valore ottimale assoluto per garantire la compromissione del modello si identifica in $\epsilon \approx 0.0126$. Una distorsione di tale entità risulta crittograficamente inscindibile dall'immagine sorgente pulita, garantendo l'invisibi\lità assoluta dell'attacco al sistema visivo umano.

3.2.7. VALUTAZIONE COMPLESSIVA DEGLI ATTACCHI UNTARGETED

I risultati riepilogati nella Figura 16 evidenziano la marcata vulnerabilità del modello di fronte alle perturbazioni Error-Generic. Sull'intero test set acquisito, composto da 1000 campioni, tutti gli attacchi implementati sono riusciti a forzare una classificazione errata con un tasso di successo (*Attack Success Rate*) costantemente superiore al 99%.

Attacco Error-Generic	Epsilon (ε)	Robust Accuracy
FGSM	0.050	0.11%
BIM	0.100	0.00%
PGD	0.015	0.00%
DeepFool	0.100	0.11%
Carlini & Wagner	0.0126	0.00%

Figura 16 - Tabella complessiva degli attacchi untargeted

3.3. ATTACCHI ERROR-SPECIFIC (TARGETED)

In uno scenario *Targeted*, la minaccia assume una complessità matematico-computazionale nettamente superiore: l'obiettivo dell'ottimizzatore non è semplicemente allontanare la predizione dalla classe corretta y_{true}, ma forzare l'algoritmo di discesa del gradiente a minimizzare la distanza verso una specifica e predeterminata regione spaziale appartenente alla classe bersaglio y_{target} desiderata dall'attaccante.

Per testare la robustezza della rete in condizioni eterogenee, sono state formalizzate e implementate specifiche **Euristiche di Targeting**:

- **Random:** Il bersaglio è selezionato mediante un campionamento casuale uniforme tra le 8631 classi rimanenti.
- **Next-Best:** Viene selezionata la classe che possiede la seconda probabilità Softmax più alta sull'immagine pulita. Costituisce la traiettoria di attacco a minor resistenza, ovvero l'obiettivo topologicamente più semplice da raggiungere.
- **Least-Likely:** Viene isolata la classe con la probabilità originaria più bassa in assoluto (tendente a zero). Costituisce lo scenario *worst-case*, obbligando l'ottimizzatore allo sforzo spaziale massimo per attraversare l'intera topologia decisionale della rete.
- **Round-Robin Subsets:** Raggruppamento logico delle identità (ottenuto via K-Means e calcolo delle distanze euclidee sugli embedding) per testare l'impersonificazione mirata all'interno di matrici chiuse tra soggetti "Sosia" (alta vicinanza), soggetti "Estremi" e gruppi ad "Alta Varianza Morfologica". *È fondamentale sottolineare che questa specifica euristica corale è stata impiegata esclusivamente per la realizzazione dell'attacco FGSM; per i successivi attacchi iterativi (BIM, PGD), l'analisi si è concentrata sulle euristiche Next-Best, Random e Least-Likely per vincoli di esplorazione computazionale, mentre per C&W l'analisi è stata svolta soltanto sull'euristica Next-Best per il medesimo problema computazionale.*

Per la scelta della configurazione ottimale degli attacchi mirati, è stata adottata la medesima architettura di *scouting* e *Grid Search* introdotta nella Sezione 3.1. Tuttavia, per ragioni di efficienza computazionale e rigore metodologico, il *tuning* degli iperparametri è stato condotto **esclusivamente sull'euristica Least-Likely**.

La scelta di testare unicamente questa classe bersaglio risiede nella sua natura intrinseca di scenario *worst-case*: la classe meno probabile costringe l'ottimizzatore a superare la massima resistenza topologica, calcolando la traiettoria più lunga e complessa attraverso la *loss landscape* per raggiungere una regione decisionale originariamente associata a una confidenza nulla. La logica alla base di questa scelta è che una configurazione ottimizzata per superare il caso limite garantisce ottime prestazioni anche per le restanti euristiche (come *Next-Best* o *Random*). Queste ultime, infatti, richiedono uno spostamento molto meno impegnativo all'interno dello spazio della rete per raggiungere il bersaglio.

3.3.1. METODOLOGIE DI VALUTAZIONE VISIVA E QUANTITATIVA

Prima di procedere con l'analisi dettagliata dei singoli algoritmi, è opportuno definire le metodologie di valutazione adottate per lo scenario mirato. Per quantificare l'impatto delle perturbazioni, sono state formalizzate quattro logiche di rappresentazione visiva e statistica, alcune basate sui metadati estratti dalla pipeline e altri archiviati nel database cloud:

1. **Targeted Success Rate (t-ASR) Curve:** È l'esatto opposto della *Security Evaluation Curve*. Strutturato come un grafico lineare (Line Plot) con il budget ϵ sull'asse delle ascisse e la percentuale di t-ASR sulle ordinate, questo grafico traccia il tasso di successo dell'attaccante. Misura esplicitamente la percentuale di volte in cui si verifica la condizione $f(x_{adv}) = y_{target}$, permettendo di confrontare quale algoritmo raggiunga per primo il 100% di efficacia con il minor budget perturbativo.
2. **Target Confidence Growth Plot:** Negli attacchi mirati, specialmente a regimi di ϵ molto bassi, l'attacco potrebbe fallire nel cambiare la label finale (t-ASR = 0%). Tuttavia, questo Boxplot dimostra come la probabilità (Softmax) della classe bersaglio venga matematicamente "trascinata" verso l'alto (ad esempio passando dallo 0.001% al 45%).

3. **Attack Outcome Distribution:** Un istogramma a barre percentuali che disgrega l'esito dell'attacco in tre stati mutuamente esclusivi: *Model Resisted* (la rete non cambia idea), *Untargeted Success* (l'attacco devia la predizione, ma manca il bersaglio finendo in una classe terza), e *Targeted Success* (impersonificazione perfetta). È essenziale per cogliere i "fallimenti parziali" degli ottimizzatori.
4. **Source-to-Target Vulnerability Heatmap:** Matrice asimmetrica di impersonificazione. Evitando l'illeggibilità di una matrice completa 100×100, la *heatmap* viene generata su sottoinsiemi strategici (es. le 10 identità più deboli contro le 10 più robuste). Il calore della cella indica il t-ASR, mostrando visivamente come impersonare l'Identità A partendo dalla B possa risultare elementare, mentre il percorso inverso sia matematicamente proibitivo a causa dell'asimmetria dello spazio latente.
5. **UMAP Trajectories:** La *Safe Zone* di un'identità legittima viene evidenziata come una distribuzione di densità (KDE plot) verde. Le immagini avversarie vengono iniettate in questo spazio, e una freccia vettoriale unisce l'embedding dell'immagine pulita a quello perturbato. Questa visualizzazione traccia l'esatta traiettoria balistica dell'attacco, mostrando come l'immagine venga "spinta" fisicamente fuori dal proprio cluster di appartenenza, finendo nel vuoto (scenario Error-Generic) o collassando chirurgicamente all'interno del cluster bersaglio (scenario Error-Specific).

Come per gli attacchi untargeted, anche qui i grafici vengono realizzati per tutti gli attacchi targeted, ma verranno illustrati solo i più rappresentativi.

3.3.2. FAST GRADIENT SIGN METHOD (FGSM) TARGETED

Nello scenario mirato, l'FGSM viene riadattato invertendo il segno della perturbazione per scendere lungo il gradiente della classe y_{target} anziché risalire quello della classe y_{true}. Essendo un attacco *single-step*, effettua un unico balzo lineare; questa linearità lo rende estremamente debole per raggiungere classi topologicamente distanti.

3.3.2.1. NEXT-BEST

I risultati ottenuti applicando l'FGSM Targeted sull'euristica *Next-Best* sono in linea con le aspettative. Poiché la classe bersaglio è la più vicina in assoluto a quella originale, l'uso di valori elevati di ϵ si rivela controproducente: il singolo balzo lineare dell'algoritmo (*single-step*) diventa troppo ampio e provoca un effetto di *overshooting*. In pratica, la perturbazione fa sì che l'immagine oltrepassi i confini decisionali della classe target, allontanandosi dallo spazio desiderato e vanificando l'attacco mirato. Viceversa, con valori bassi di ϵ, la perturbazione risulta contenuta e misurata: questo rende molto più semplice "atterrare" correttamente nello spazio della classe adiacente, portando a un maggiore tasso di successo.

Come si evince dalla Figura 17, con un budget minimo ($\epsilon = 0.025$) l'attacco ottiene un successo quasi totale (97.0%). Tuttavia, aumentando la magnitudo della perturbazione, la curva subisce un crollo drastico, precipitando ad appena il 47.2% per $\epsilon = 0.1$.

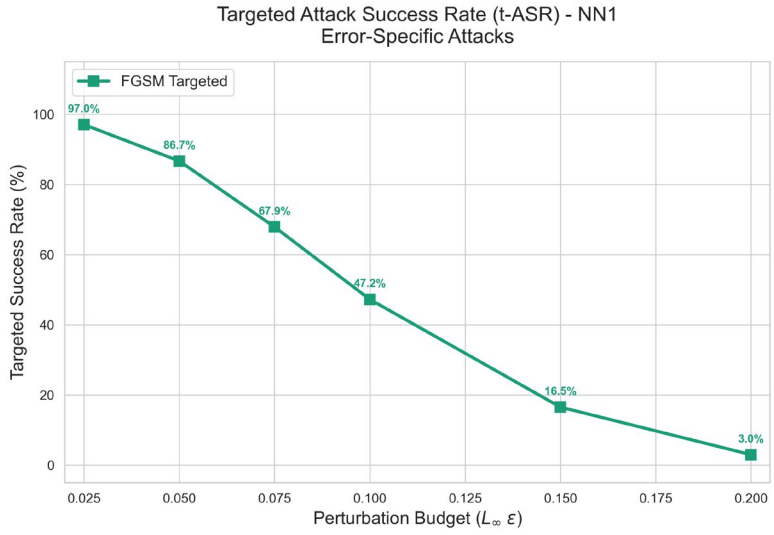


Figura 17 - Targeted Attack Success Rate FGSM NEXT-BEST

L'istogramma della distribuzione degli esiti in Figura 18 spiega l'esatta natura di questo crollo. Le immagini non tornano ad essere classificate correttamente (il *Model Resisted* rimane fisso allo 0%), bensì si tramutano in *Untargeted Success*. A $\epsilon = 0.2$, il 96.9% dei campioni fallisce l'impersonificazione mirata, finendo per essere classificato in classi terze casuali.

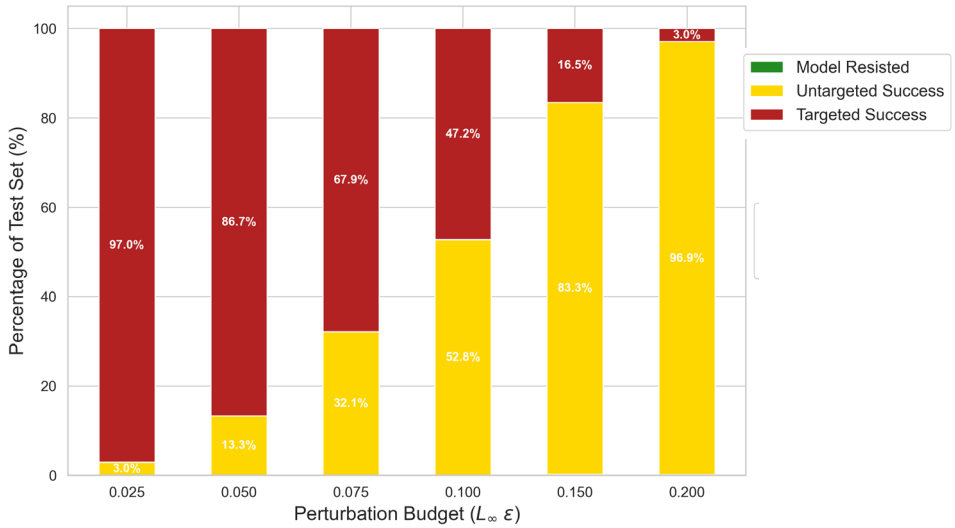


Figura 18 - Attack Outcome Distribution - FGSM Targeted NEXT-BEST

Il boxplot della confidenza conferma matematicamente il fenomeno. A $\epsilon = 0.025$, la rete assegna al bersaglio probabilità alte. Man mano che ϵ cresce, la distribuzione collassa verso lo zero, dimostrando che la classe bersaglio è stata completamente abbandonata.

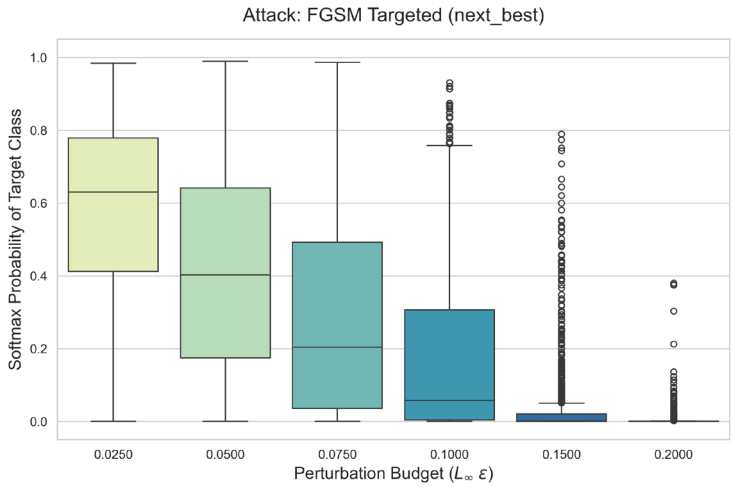


Figura 19 - Targeted Class Confidence Growth NEXT-BEST

Come dimostrato dalla Figura 18, il valore migliore di ϵ risulta essere 0.025 con una Robust Accuracy pari a 3.0%.

3.3.2.2. RANDOM

A differenza dell'euristica *Next-best*, la strategia *Random* seleziona la classe bersaglio campionandola uniformemente dall'intero insieme delle etichette disponibili. Da un punto di vista topologico, questo implica che il bersaglio si troverà, con alta probabilità, a una notevole distanza euclidea dalla regione decisionale dell'identità originaria, separato da innumerevoli confini decisionali intermedi.

I risultati empirici evidenziano la severa inadeguatezza dell'algoritmo FGSM nell'affrontare spostamenti latenti a lungo raggio.

Come illustrato nella curva del *Targeted ASR* (Figura 20), il tasso di successo dell'impersonificazione mirata risulta intrinsecamente basso fin dal principio. Il picco massimo si attesta ad un modesto 19.7% per il budget minimo ($\epsilon = 0.025$). Similmente al caso precedente, un incremento del budget perturbativo non migliora la convergenza, ma porta a un progressivo decadimento dell'efficacia, che crolla allo 0.9% per $\epsilon = 0.2$.

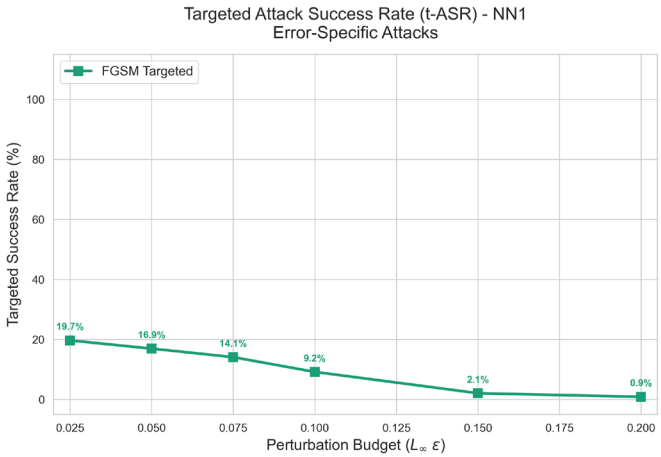


Figura 20 - Targeted Attack Success Rate - FGSM RANDOM

L'istogramma degli esiti (Figura 21) chiarisce in modo inequivocabile la dinamica di questo fallimento. L'attacco possiede energia sufficiente per eludere la classificazione corretta (il *Model Resisted* scende dal 9.2% allo 1.20%), ma è incapace di "centrare" il bersaglio. Di conseguenza, la quasi totalità dei tentativi degenera in un *Untargeted Success*, che satura il grafico raggiungendo l'89.6% al massimo budget ($\epsilon = 0.1$). L'attacco mirato si trasforma, di fatto, in un caotico attacco generico.

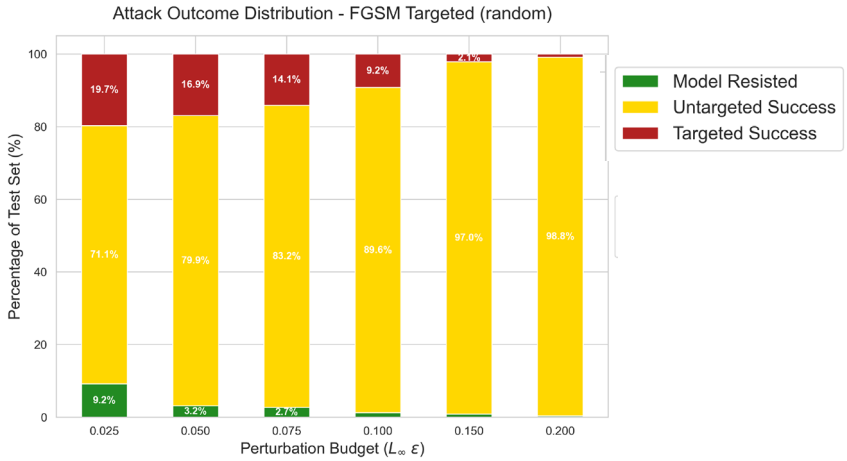


Figura 21 - Attack Outcome Distribution - FGSM Targeted RANDOM

Questo fallimento sistematico convalida i limiti matematici degli attacchi *single-step* su spazi ad alta dimensionalità. L'FGSM approssima la *loss landscape* localmente con una funzione lineare, scagliando il tensore in un'unica direzione netta. Un singolo balzo lineare non possiede i gradi di libertà (iteratività) necessari per "navigare" la complessa topologia della rete: la perturbazione spinge l'immagine fuori dalla classe originaria, ma questa finisce inevitabilmente per collassare nell'insieme di attrazione di una terza classe non voluta che si trovava lungo la traiettoria.

3.3.2.3. ROUND ROBIN DIVERSITY

L'euristica *Round-Robin Diversity* è stata concepita per testare le vulnerabilità del modello ai limiti estremi del suo spazio latente. A differenza dello scenario *Next-best* (che opera su classi spazialmente adiacenti), questo sottoinsieme è composto da 10 identità selezionate algoritmicamente (tramite clustering K-Means sugli embedding a 512 dimensioni) al fine di massimizzare la varianza morfologica e la distanza euclidea tra i cluster. L'obiettivo è forzare la rete a compiere un'impersonificazione tra soggetti diametralmente opposti per caratteristiche somatiche e topologiche.

I risultati empirici certificano in modo inequivocabile l'incapacità dell'algoritmo FGSM di colmare vasti "vuoti" decisionali all'interno di una *loss landscape* altamente non-convessa.

L'andamento della curva (Figura 22) ricalca il medesimo declino osservato nella strategia *Random*, ma partendo da premesse geometriche ancor più restrittive. Anche al budget minimo ($\epsilon = 0.025$), l'FGSM riesce a forzare l'impersonificazione mirata solo nel 17.9% dei casi. All'aumentare dell'intensità della perturbazione, l'attacco subisce un deterioramento, collassando fino a un marginale 8.8% per $\epsilon = 0.1$.

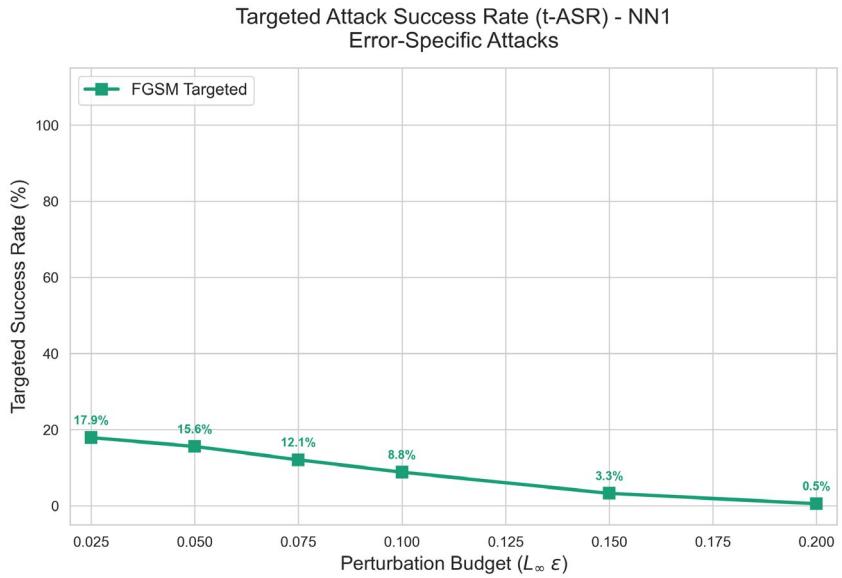


Figura 22 - Targeted Attack Success Rate - FGSM ROUND ROBIN DIVERSITY

L'istogramma degli esiti (Figura 23) svela la natura di questo fallimento. L'energia iniettata dall'attaccante è più che sufficiente a sradicare l'immagine dalla sua *Safe Zone* originaria (il *Model Resisted* si assottiglia rapidamente dal 5.4% allo 0.7%). Visualizzando il valore al massimo budget ($\epsilon = 0.1$), la quasi totalità degli attacchi (90.5%) degenera in un *Untargeted Success*.

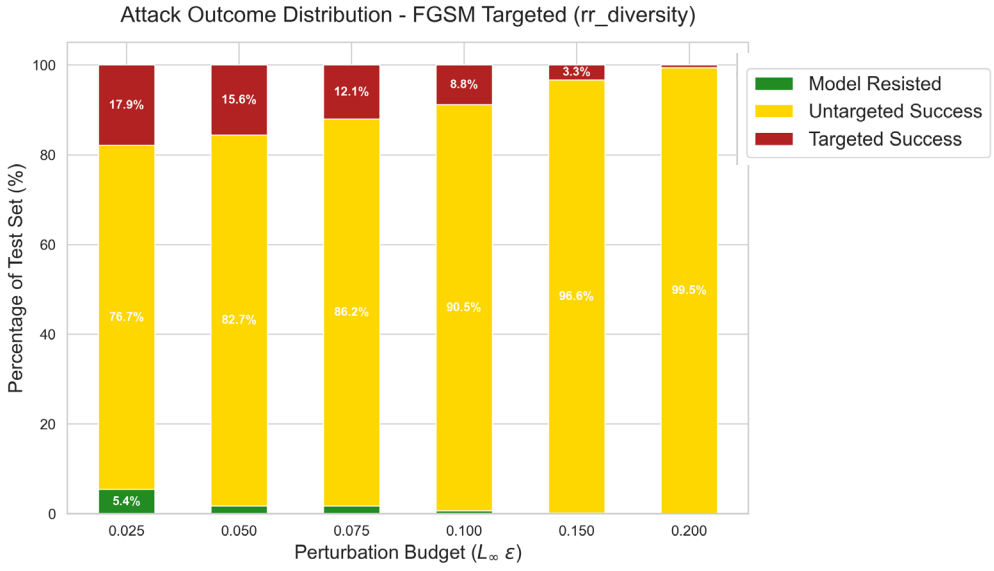


Figura 23 - Attack Outcome Distribution - FGSM Targeted ROUND ROBIN DIVERSITY

3.3.2.4. ROUND ROBIN EXTREMES

L'euristica *Round Robin Extremes* è stata progettata per valutare l'asimmetria dello spazio latente, testando l'impersonificazione incrociata tra le 5 identità intrinsecamente più robuste (altissima confidenza media) e le 5 identità più vulnerabili (bassa confidenza) del dataset. L'obiettivo topologico è verificare se un attacco lineare sia in grado di forzare il transito bidirezionale tra bacini di attrazione molto profondi e stabili (i soggetti "Forti") e regioni decisionali più superficiali e ristrette (i soggetti "Deboli").

I dati empirici rivelano un comportamento dinamico peculiare, dettato proprio dalla disomogeneità strutturale del sottoinsieme analizzato.

Osservando la curva del *Targeted ASR* (Figura 24), il tasso di impersonificazione massima si attesta al 18.4% con $\epsilon = 0.025$. Similmente alle euristiche *Random* e *Diversity*, la curva è affetta dal deterioramento delle performance all'aumentare dell'intensità dell'attacco, crollando verso il 5.9% al raggiungimento del budget massimo ($\epsilon = 0.1$).

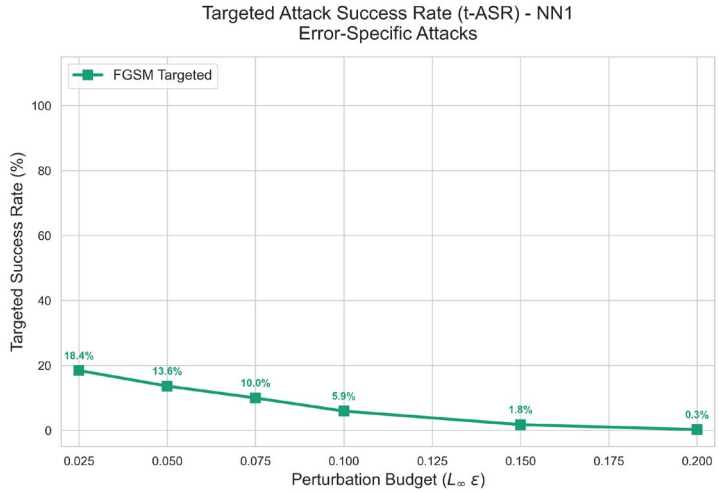


Figura 24 - Targeted Attack Success Rate - FGSM ROUND ROBIN EXTREMES

L'istogramma degli esiti (Figura 25) fornisce l'intuizione chiave sulle dinamiche di questo scenario. Al budget minimo ($\epsilon = 0.025$), il tasso in cui il modello resiste all'attacco (*Model Resisted*) è del **15.2%**, un valore sensibilmente superiore rispetto agli scenari *Diversity* (5.4%) e *Random* (9.2%). Questo picco di resilienza è la firma topologica delle 5 identità "Forti" inserite nel test, i cui gradienti locali sono sufficientemente stabili da neutralizzare una perturbazione lineare debole.

Tuttavia, quando il budget ϵ aumenta, l'energia iniettata diviene sufficiente per sradicare anche le identità più stabili dalle proprie *Safe Zones* (il verde scompare quasi totalmente a $\epsilon \geq 0.100$). A questo punto, riemerge il limite strutturale dell'FGSM: la perturbazione distrugge la classe originale, ma la linearità del *single-step* impedisce di centrare il target.

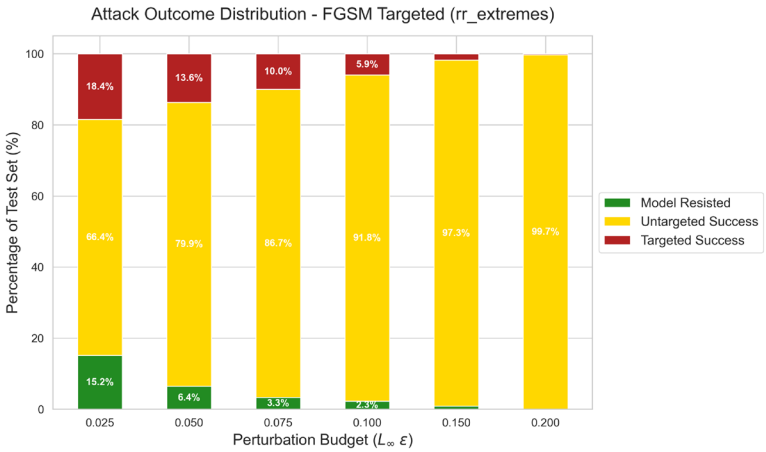


Figura 25 - Attack Outcome Distribution - FGSM Targeted ROUND ROBIN EXTREMES

Questo scenario certifica che l'FGSM è inefficace nel gestire l'**asimmetria vettoriale**.
Se si tenta di spostare un'identità "Forte" verso una "Debole", l'enorme spinta necessaria per farla uscire dal proprio profondo bacino decisionale si traduce in un vettore di tale magnitudo che, inevitabilmente, oltrepassa di slancio la ristretta regione bersaglio dell'identità debole (*overshooting*).
Al contrario, se si tenta di spostare un'identità "Debole" verso una "Forte", la traiettoria lineare richiesta per penetrare fino al centro del cluster robusto è troppo lunga e complessa per essere coperta con un singolo gradiente calcolato nel punto di origine, portando il tensore a deviare verso classi terze non previste. Anche in questo caso, l'assenza di iteratività condanna l'FGSM al fallimento nell'attacco mirato.

3.3.2.5. ROUND ROBIN LOOKALIKES

L'euristica *Round Robin Lookalikes* rappresenta lo scenario topologicamente più favorevole per un attacco mirato. Questo sottoinsieme è stato costruito aggregando le 10 identità caratterizzate dalla minima distanza euclidea reciproca all'interno dello spazio latente a 512 dimensioni (veri e propri "sosia" morfologici per la rete). L'obiettivo è testare la vulnerabilità di confini decisionali altamente condivisi e contigui.
I risultati empirici riflettono in modo inequivocabile questa adiacenza geometrica, esaltando per la prima volta l'efficacia del singolo balzo del gradiente.
Osservando la curva del *Targeted ASR* (Figura 26) e l'istogramma degli esiti (Figura 27), emerge un dato eclatante: al budget minimo ($\epsilon = 0.025$), il tasso di impersonificazione mirata raggiunge il **34.9%**. Questo valore risulta essere circa il doppio rispetto a quanto registrato negli scenari *Extremes* (18.4%), *Diversity* (17.9%) e *Random* (19.7%). Essendo i cluster delle identità confinanti, il vettore lineare calcolato dall'FGSM a basse intensità possiede l'esatta magnitudo per varcare la frontiera decisionale e arrestarsi correttamente nel bacino di attrazione del "sosia".

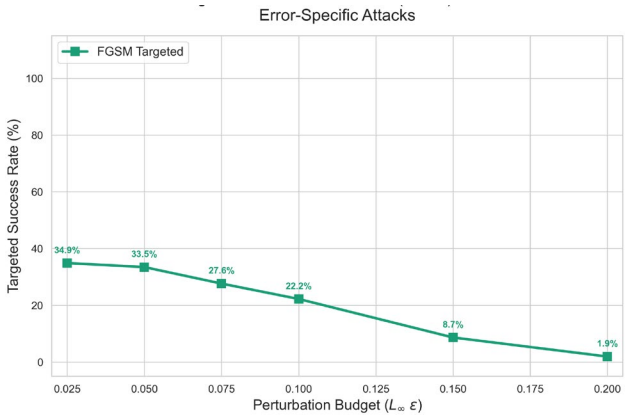


Figura 26 - Targeted Attack Success Rate - FGSM ROUND ROBIN LOOKALIKES

Pur partendo da un successo notevole, la rigidità del *single-step* non perdona l'aumento dell'intensità. Non appena il budget cresce, si innesca nuovamente l'effetto *overshooting*. A $\epsilon = 0.200$, il balzo vettoriale diventa troppo ampio per cluster così ravvicinati, spingendo le immagini ben oltre il bersaglio e facendo degenerare il 98.1% degli attacchi in un *Untargeted Success* caotico (il t-ASR crolla all'1.9%).

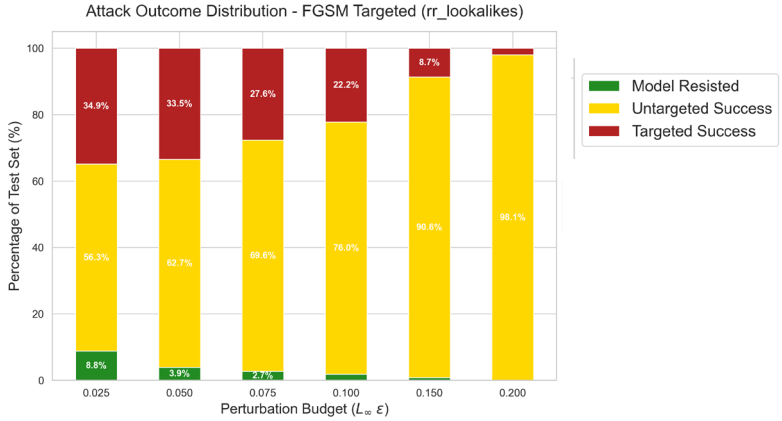


Figura 27 - Attack Outcome Distribution - FGSM Targeted ROUND ROBIN LOOKALIKES

La conferma visiva e formale di questa contiguità spaziale è fornita dalla *Impersonation Vulnerability Matrix* (Figura 28). A netta differenza dello scenario *Diversity* (caratterizzato da tassi di successo di impersonificazione pressoché nulli), questa *heatmap* presenta un'altissima densità di successi *off-diagonal*, rivelando vulnerabilità gravissime tra coppie specifiche. Spiccano, ad esempio, i tassi di impersonificazione di "Tomatito" verso "Mike_Posner" (100%) o di "Brad_Garrett" verso "Adam_Darski" (86%).

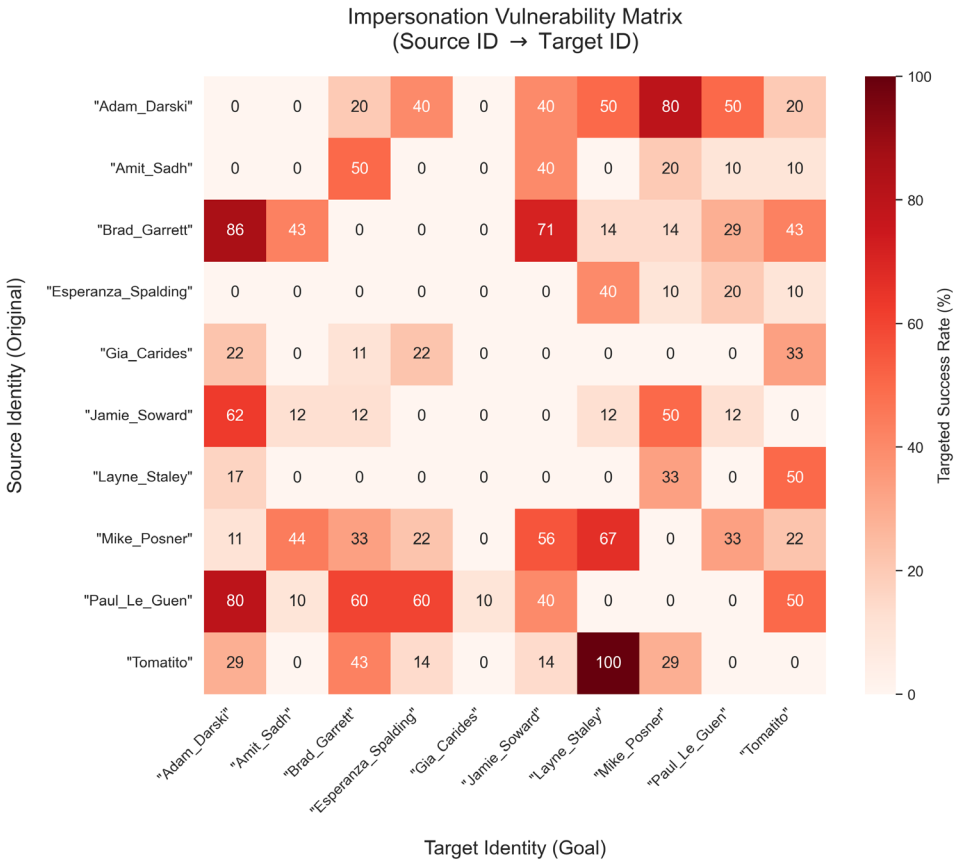


Figura 28 – Heatmap FGSM Targeted ROUND ROBIN LOOKALIKES

L'analisi della matrice rivela, tuttavia, una dinamica ancora più profonda: la **marcata asimmetria dello spazio latente**. Si osserva che sebbene l'identità "Paul_Le_Guen" riesca a impersonare "Adam_Darski" nell'80% dei casi, il percorso inverso ("Adam_Darski" verso "Paul_Le_Guen") fallisce totalmente (0%). Questo fenomeno dimostra matematicamente che i confini decisionali non sono speculari: il volume e la pendenza del gradiente (la "ripidità" del confine) tra due cluster contigui variano drasticamente in base al punto di origine.
In sintesi, i test sull'algoritmo FGSM certificano che un attacco mirato di tipo *single-step* possiede validità operativa **esclusivamente** per percorsi a cortissimo raggio (Next-best e Lookalikes) e solo per budget perturbativi minimi, fallendo strutturalmente nel generalizzare verso bersagli arbitrari.

3.3.2.6. LEAST-LIKELY

L'euristica *Least-Likely* costituisce lo scenario di impersonificazione più estremo e proibitivo (il *worst-case* assoluto). In questa configurazione, l'ottimizzatore viene forzato a colpire la classe che detiene la probabilità Softmax originaria più bassa (prossima allo zero). Dal punto di vista geometrico, questo equivale a richiedere all'algoritmo di attraversare l'intero spazio latente, superando la massima resistenza topologica per raggiungere il cluster diametralmente opposto all'identità di partenza.
I dati empirici certificano la totale inefficacia dell'approccio *single-step* a fronte di distanze latenti così elevate. La curva del *Targeted ASR* (Figura 29) restituisce un esito inequivocabile: una linea piatta fissa allo **0.0%** per l'intero spettro del budget perturbativo. A prescindere dalla magnitudo di ϵ, l'FGSM non è mai in grado di forzare l'identità desiderata.

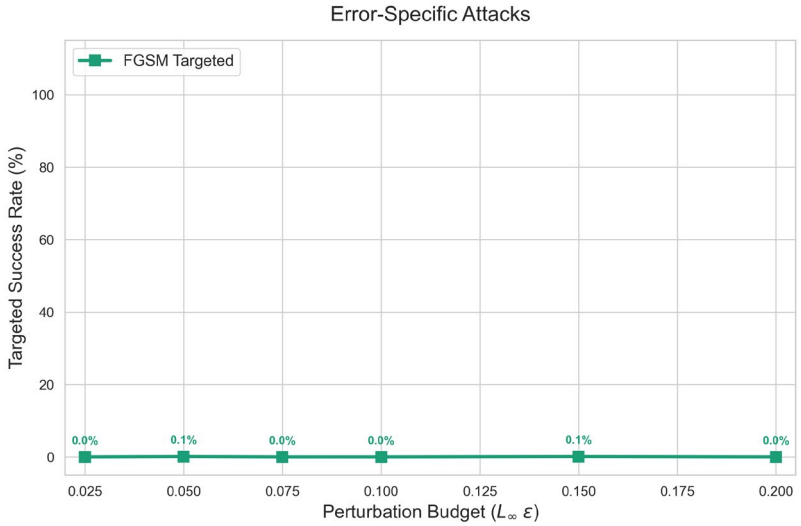


Figura 29 - Targeted Attack Success Rate - FGSM ROUND ROBIN LEAST-LIKELY

L'istogramma degli esiti (Figura 30) illustra la dinamica di questa impotenza. Sebbene a bassi budget ($\epsilon = 0.025$) la rete riesca a resistere nel 13.2% dei casi, aumentando ϵ la perturbazione guadagna energia sufficiente per sradicare completamente le immagini dalle loro classi originali (il *Model Resisted* scende all' 1.7% a $\epsilon = 0.1$). Tuttavia, mancando totalmente il bersaglio mirato, la totalità degli sforzi degenera in un *Untargeted Success*, che satura il grafico fino al 98.3%. L'attacco disancora l'identità, ma perde totalmente il controllo della destinazione.

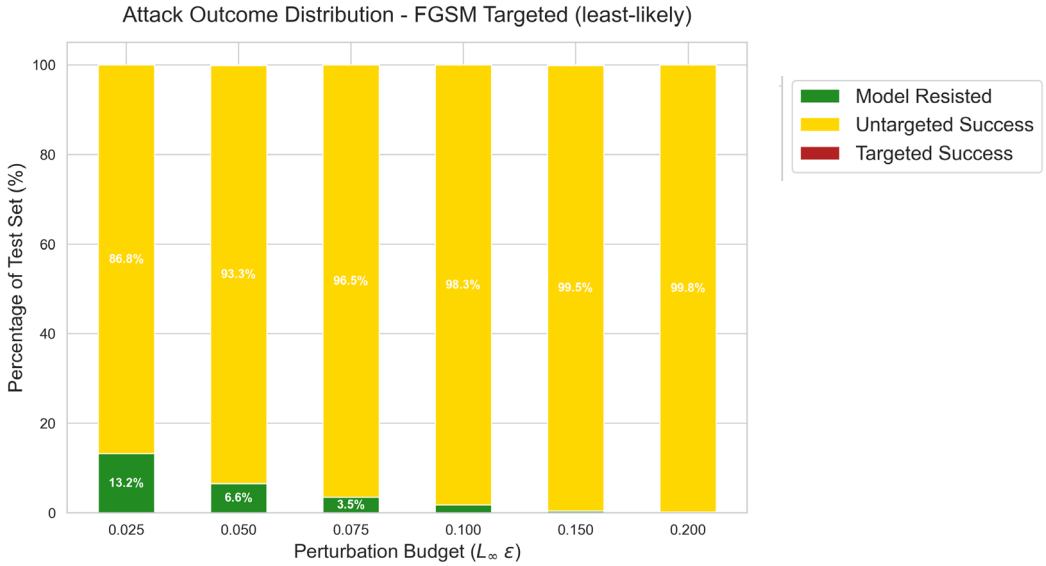


Figura 30 - Attack Outcome Distribution - FGSM Targeted ROUND ROBIN LEAST-LIKELY

Questo comportamento è la diretta conseguenza della natura dell'FGSM combinata con la **non-convessità** dello spazio latente di InceptionResnetV1. L'algoritmo calcola il gradiente in un'unica soluzione nel punto di partenza (l'immagine pulita) e traccia un vettore lineare che punta verso la classe *Least-Likely*. Tuttavia, essendo la distanza immensa, questa linea retta "cieca" interseca inevitabilmente i confini decisionali di dozzine di altre classi intermedie.

Privo di meccanismi iterativi che gli consentano di ricalcolare il gradiente per "curvare" ed evitare gli ostacoli topologici, l'FGSM schianta semplicemente il tensore contro la prima barriera decisionale che incontra lungo la traiettoria, tramutandosi in un puro attacco *Untargeted*.

In conclusione, i test sull'algoritmo FGSM certificano in modo definitivo che un attacco mirato di tipo *single-step* possiede validità operativa **esclusivamente** per percorsi a cortissimo raggio, fallendo strutturalmente dinanzi a bersagli arbitrari o topologicamente remoti.

3.3.3. BASIC ITERATIVE METHOD (BIM) TARGETED

Il BIM colma le lacune lineari dell'FGSM frazionando la perturbazione e ricalcolando la direzione del gradiente ad ogni step verso il target. Tuttavia, per forzare la convergenza nel regime *Error-Specific*, il calcolo del passo di avanzamento (step size) è stato ingegnerizzato seguendo la "Regola di Madry": $\alpha = (\epsilon/N_{iter}) \times 2.5$. Questo moltiplicatore dinamico consente all'algoritmo di compiere salti sufficientemente ampi per esplorare i bordi della sfera di raggio ϵ, accelerando l'ingresso nell' insieme di attrazione della classe y_{target} e prevenendo lo stallo prematura del gradiente. I valori degli iperparametri scelti per la generazione degli attacchi avversari sono MAX_ITER = 10 e MULTIPLIER = 2.5.

3.3.3.1. NEXT-BEST

Come illustrato dalla curva del *Targeted ASR* (Figura 31) e confermato dall'istogramma *Attack Outcome Distribution* (Figura 32), il BIM raggiunge una saturazione immediata. Già al budget minimo ($\epsilon = 0.025$), l'attacco ottiene un t-ASR del **100.0%**. Tutte le immagini del test set vengono perfettamente impersonificate, azzerando sia la resistenza del modello che i fallimenti accidentali (*Untargeted Success*). Questo dominio assoluto del 100% si mantiene perfettamente stabile per tutti i valori di ϵ successivi.

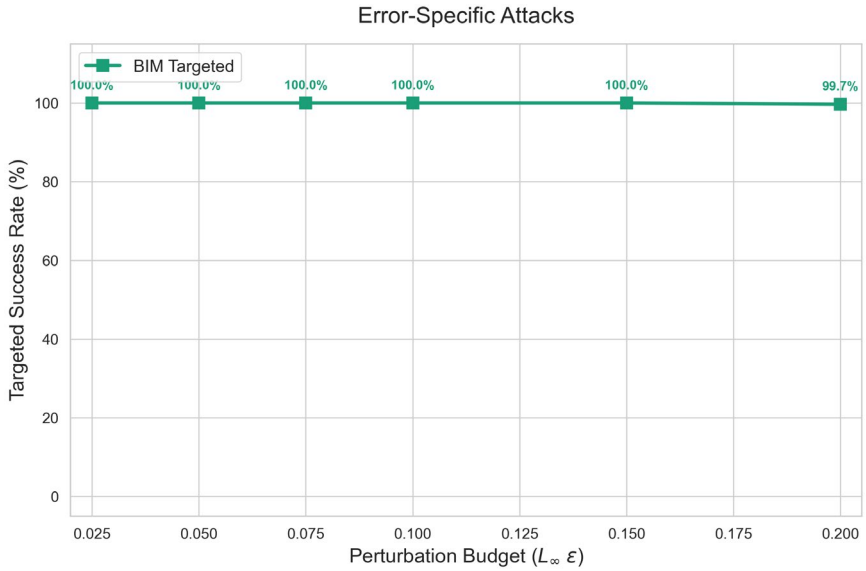


Figura 31 - Targeted Attack Success Rate - BIM NEXT-BEST

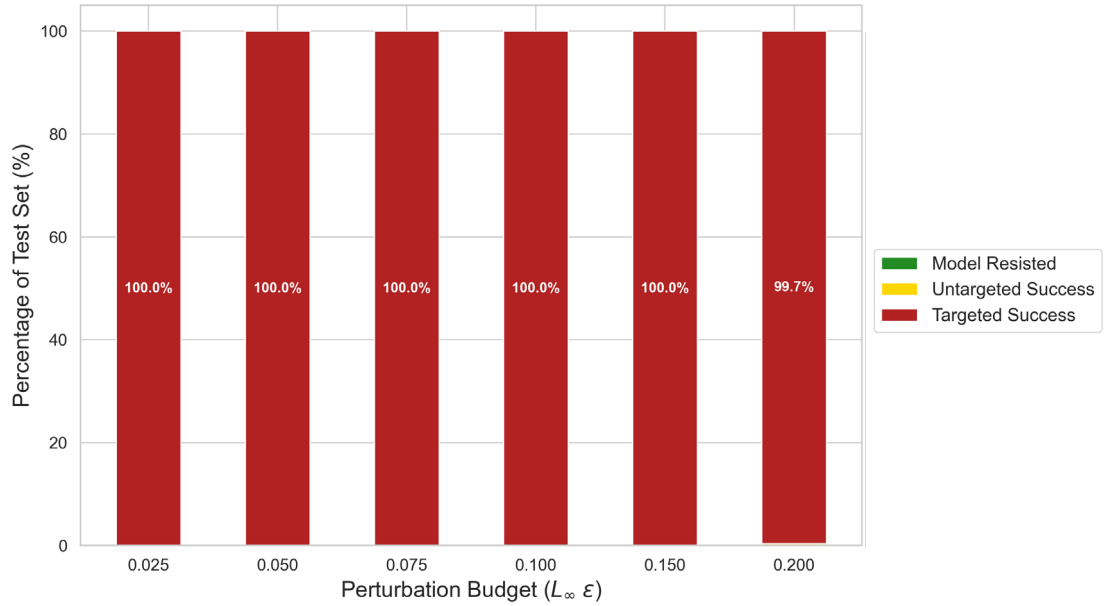


Figura 32 - Attack Outcome Distribution - BIM NEXT-BEST

Il Boxplot della confidenza (Figura 33) fornisce la prova matematica dell'efficacia dell'algoritmo. Non solo l'attacco cambia l'etichetta predetta, ma spinge la probabilità Softmax della classe bersaglio quasi esattamente a 1.0 (100% di certezza) per la quasi totalità dei campioni. È interessante notare come la distribuzione della confidenza sia estremamente compatta a bassi valori di ϵ, mentre all'aumentare del budget ($\epsilon \geq 0.100$) aumentino gli *outlier* verso il basso. Questo conferma che iterare con passi (e budget) troppo larghi su bersagli vicini innesca un lieve deterioramento della stabilità dell'ottimizzazione.

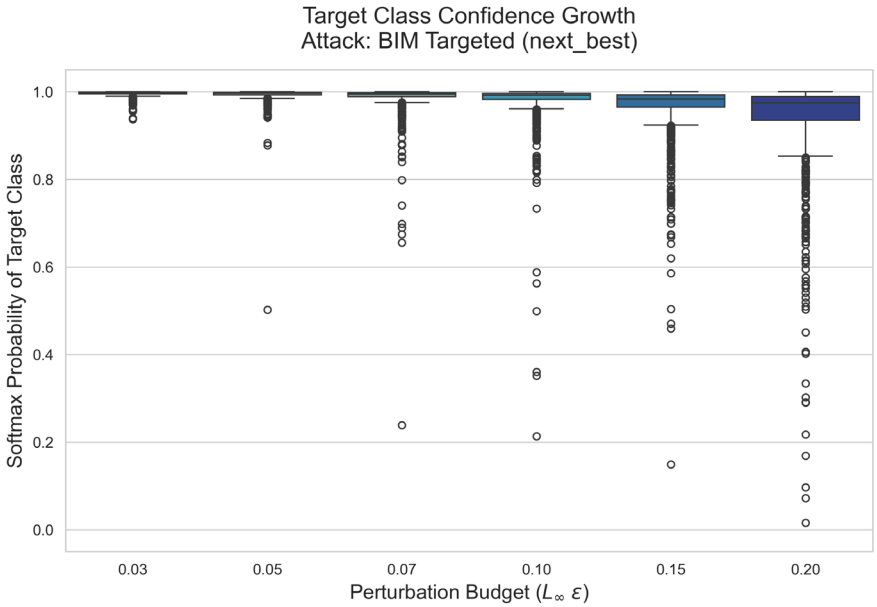


Figura 33 - Target Class Confidence Growth

Poiché il t-ASR raggiunge il **100.0%** e la confidenza risulta massimizzata con la minima dispersione statistica già al primo gradino di test, **il valore ottimale assoluto per l'euristica Next-best risulta essere** $\epsilon = 0.025$.

3.3.3.2. RANDOM

La curva del *Targeted ASR* (Figura 34) descrive un dominio algoritmico totale. A differenza del collasso registrato con l'FGSM, il BIM ottiene un tasso di successo del **100.0%** già al budget minimo ($\epsilon = 0.025$). L'ottimizzatore riesce a guidare ogni singola immagine del test set all'interno del bacino di attrazione del bersaglio casuale.

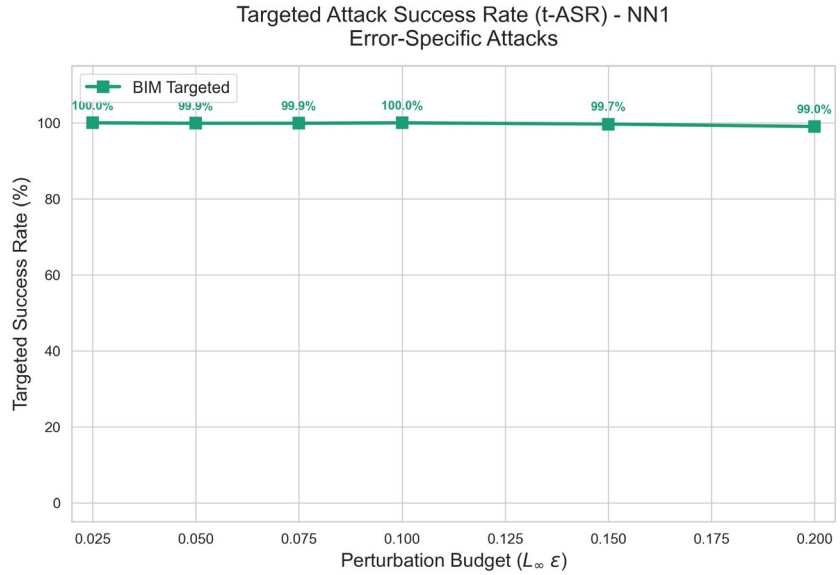


Figura 34 - Targeted Attack Success Rate - BIM RANDOM

Il Boxplot della confidenza (Figura 35) conferma l'esito dell'attacco mostrando mediane saldamente ancorate al 100% di probabilità Softmax. Si osserva tuttavia una dinamica analitica interessante all'aumentare di ϵ: per budget elevati (es. 0.150 e 0.200), la "scatola" della distribuzione si allarga verso il basso, rivelando una maggiore varianza e la presenza di *outliers* a bassa confidenza.

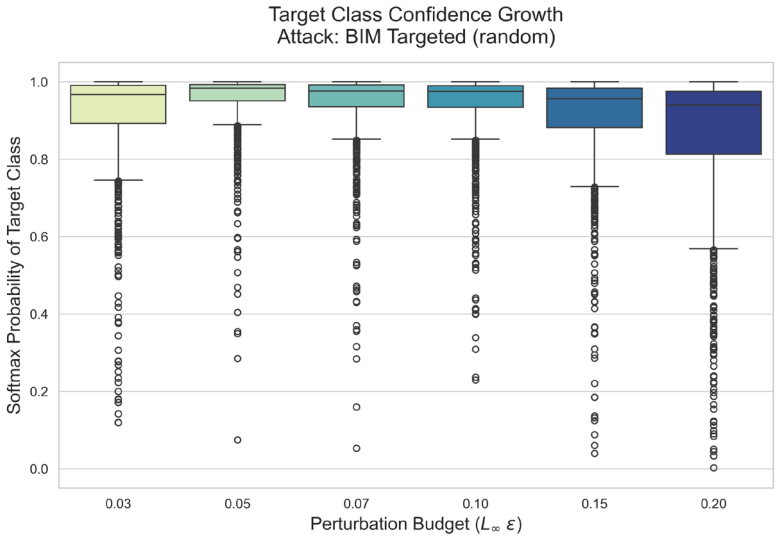


Figura 35 - Target Class Confidence Growth - BIM RANDOM

La prova definitiva della capacità del BIM di risolvere spostamenti a lungo raggio è fornita dalla proiezione topologica UMAP (*Latent Space Escape Trajectory*, Figura 36).
A differenza di scenari contigui, il plot evidenzia estese traiettorie vettoriali (le linee grigie di congiunzione). Le immagini pulite vengono sradicate dalla *Safe Zone* originaria (il cluster verde) e guidate attraverso lo spazio latente, evitando le regioni decisionali estranee di background, per atterrare con precisione esattamente sulle coordinate remote delle classi bersaglio casuali (i marker rossi). L'iteratività fornisce quindi all'attacco i "gradi di libertà" necessari per curvare la traiettoria, aggirando gli ostacoli topologici che causavano il fallimento dell'FGSM.

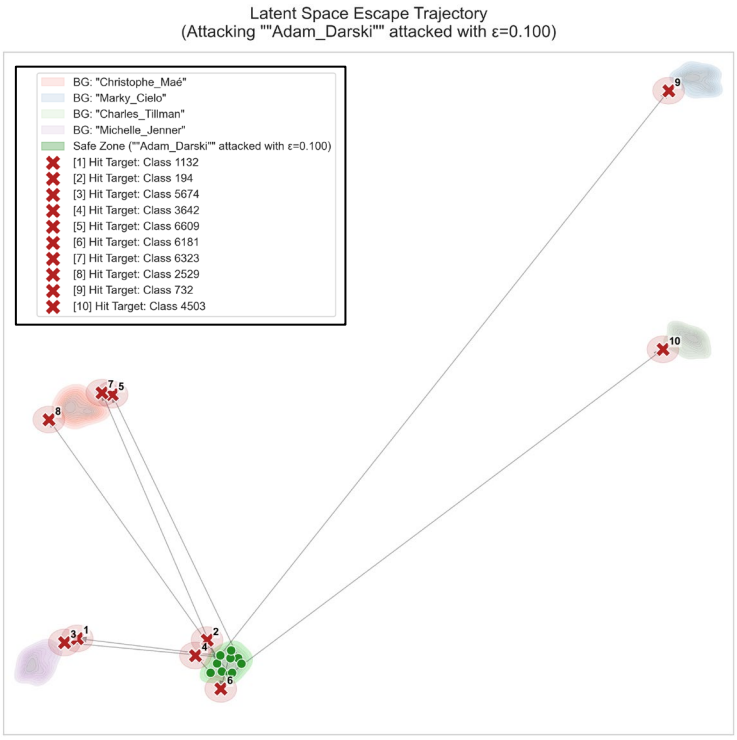


Figura 36 – Umap Weakest Case - BIM RANDOM

Anche nello scenario *Random* il valore ottimale assoluto si conferma $\epsilon = 0.025$, configurazione in cui l'algoritmo raggiunge la perfezione offensiva (t-ASR 100%) minimizzando la norma della perturbazione inserita.

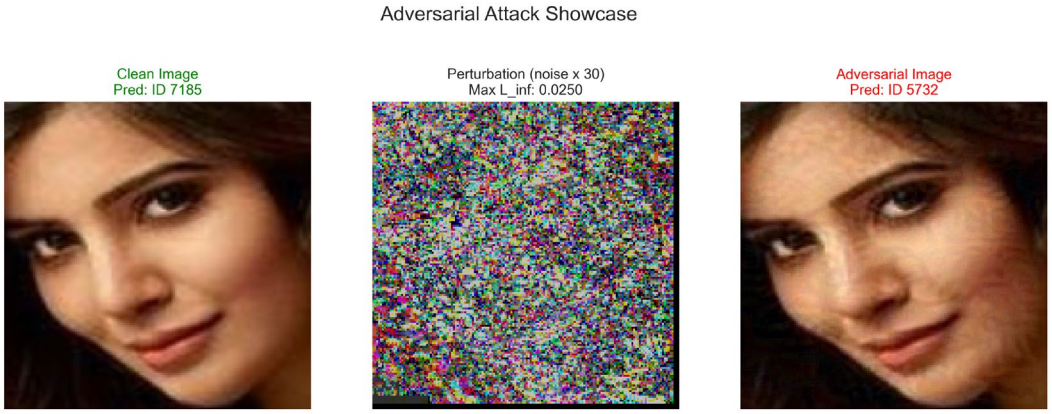


Figura 37 - Perturbation Showcase ($\epsilon = 0.025$) - BIM RANDOM

3.3.3.3. LEAST-LIKELY

In netto e drammatico contrasto con i fallimenti *single-step*, la curva del *Targeted ASR* (Figura 38) traccia un dominio algoritmico pressoché assoluto. Già al budget perturbativo minimo ($\epsilon = 0.025$), l'attacco riesce a forzare l'impersonificazione nel **98.5%** dei casi. Concedendo un frazionale incremento del budget ($\epsilon = 0.050$), la curva satura matematicamente al **100.0%**.

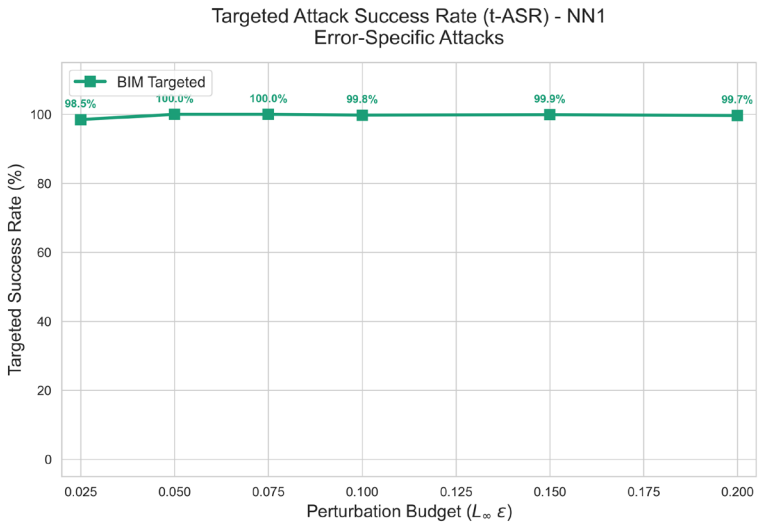


Figura 38 - Targeted Attack Success Rate - BIM LEAST-LIKELY

L'ottenimento del 100% di t-ASR sullo scenario *worst-case* convalida la decisione metodologica (descritta in apertura di capitolo) di condurre il *tuning* degli iperparametri esclusivamente su questa euristica. Un setup capace di piegare la massima resistenza topologica della rete si conferma, per inclusione, devastante su scenari a minor complessità (come dimostrato dai risultati *Next-best* e *Random*).

La giustificazione matematica di questo successo è illustrata in modo esemplare dalla proiezione topologica UMAP (*Latent Space Escape Trajectory*, Figura 39).
Il grafico evidenzia il caso di studio di un'identità ("Maura_Rivera", in verde) costretta a impersonare 10 differenti bersagli *Least-Likely* estratti dal test set (i marker rossi "X"). Le lunghe traiettorie vettoriali (frecce grigie) dimostrano l'entità dello spostamento richiesto attraverso lo spazio a 512 dimensioni. Grazie ai micropassi stabiliti dalla *Regola di Madry*, l'algoritmo BIM riesce a "curvare" lungo la traiettoria, evitando di schiantarsi contro i confini decisionali delle innumerevoli classi intermedie presenti nel dataset, per approdare chirurgicamente al centro delle regioni bersaglio più remote.

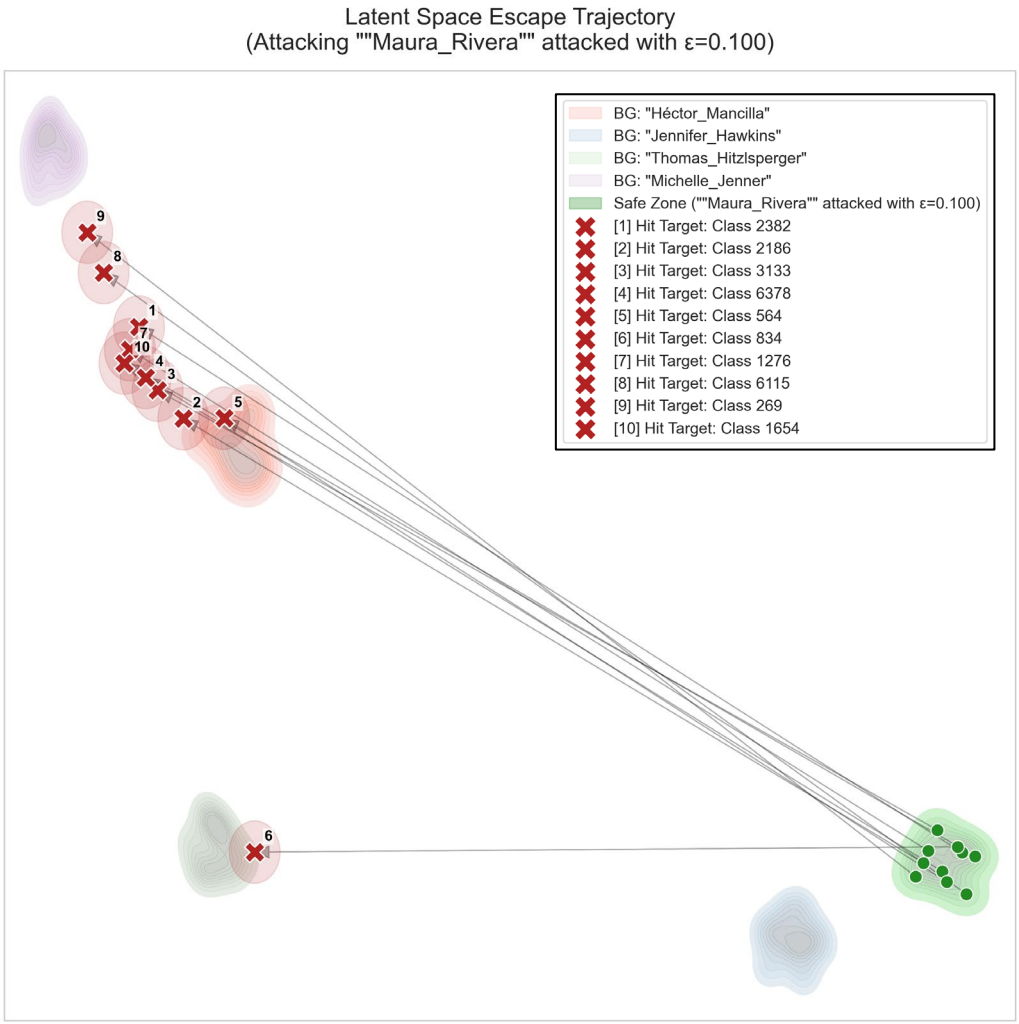


Figura 39 – Umap Strongest Case - BIM LEAST-LIKELY

L'analisi delle performance impone una selezione dell'Epsilon ottimale rigorosa. Sebbene $\epsilon = 0.025$ fornisca già un tasso di successo eccezionale (98.5%), lo scenario *Least-Likely* rappresenta l'unica euristica in cui un lievissimo incremento del rumore apporta un beneficio tangibile fino al raggiungimento della certezza matematica. Pertanto, nel rispetto del vincolo di *threat model* ($\epsilon \leq 0.10$), **il valore ottimale per garantire il collasso totale (100.0%) della rete nell'impersonificazione peggiore possibile si attesta a** $\epsilon = 0.050$.

3.3.4. PROJECTED GRADIENT DESCENT (PGD) TARGETED

L'algoritmo Projected Gradient Descent (PGD) eleva l'approccio iterativo introducendo inizializzazioni casuali multiple (*random restarts*) all'interno del budget L_∞. Questa esplorazione stocastica dello spazio perturbativo permette all'ottimizzatore di sfuggire a minimi locali sub-ottimali della *loss landscape*, conferendogli una capacità di convergenza nettamente superiore rispetto al BIM. I valori degli iperparametri scelti per la generazione degli attacchi avversari sono MAX_ITER = 10 , MULTIPLIER = 1.5 e NUM_INIT = 1.

3.3.4.1. NEXT-BEST

Osservando la curva del *Targeted ASR* (Figura 40), risulta evidente come il PGD operi a regimi di rumore microscopici. A un valore $\epsilon = 0.001$ (una distorsione pari a $1/1000$ del range dei pixel), l'attacco riesce già a forzare l'impersonificazione nel 17.3% dei casi. Impostando $\epsilon = 0.005$, la curva subisce una violenta impennata arrivando al **94.1%**, per poi saturare in modo definitivo e assoluto al **100.0%** già al gradino $\epsilon = 0.010$.

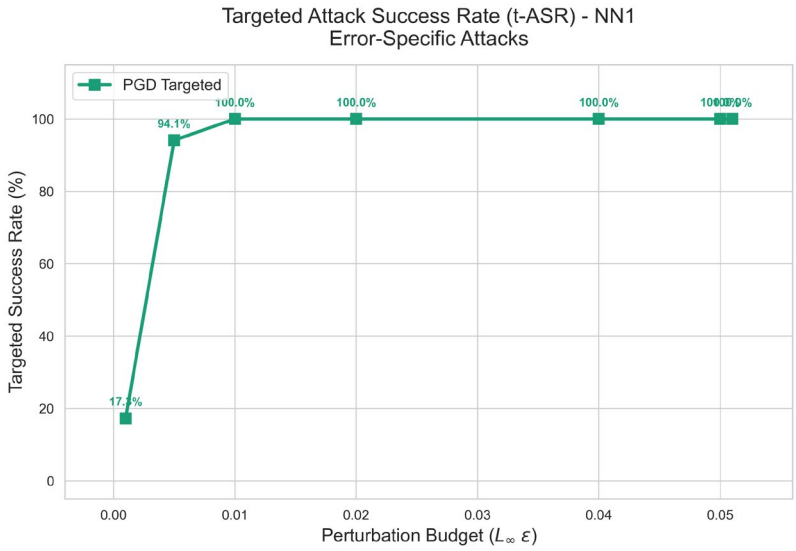


Figura 40 - Targeted Attack Success Rate - PGD NEXT-BEST

L'istogramma degli esiti (Figura 41) fornisce un'ulteriore prova della caratura matematica dell'algoritmo. Balza subito all'occhio la totale assenza di *Untargeted Success* (la porzione gialla delle barre è inesistente). Il PGD non perde mai il controllo della traiettoria: il tensore o rimane ancorato alla classe originale per mancanza di budget (area verde), oppure viene pilotato con precisione assoluta all'interno dell'insieme di attrazione del target (area rossa), senza alcuna dispersione in classi terze casuali.

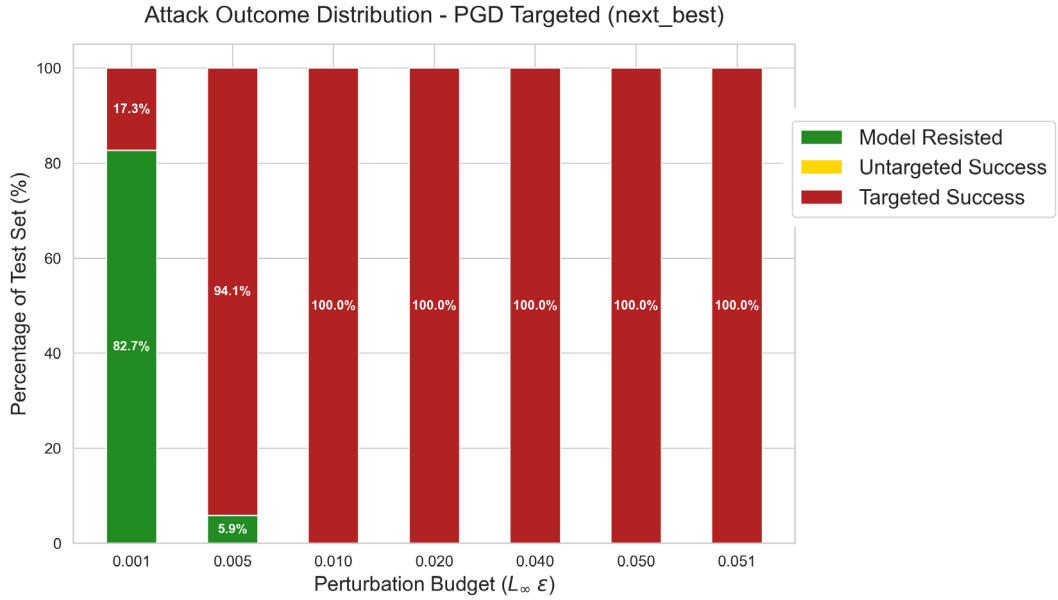


Figura 41 - Attack Outcome Distribution - PGD NEXT-BEST

In questo scenario il valore ottimale assoluto si attesta a $\epsilon = 0.010$. A questa soglia, la rete collassa integralmente (100.0% t-ASR).

3.3.4.2. RANDOM

L'analisi incrociata della curva del *Targeted ASR* (Figura 42) e della *Attack Outcome Distribution* (Figura 43) illustra perfettamente questa dinamica. A un regime perturbativo ultra-restrittivo ($\epsilon = 0.005$), il gradiente non possiede energia sufficiente per percorrere le lunghe traiettorie richieste dal bersaglio casuale; conseguentemente, il modello conserva una forte resilienza (71.7% di *Model Resisted*). Tuttavia, è sufficiente un modesto incremento del budget per innescare un collasso totale del classificatore: a $\epsilon = 0.020$, il tasso di impersonificazione subisce un'impennata verticale raggiungendo il **98.7%**, per poi saturare in modo assoluto e definitivo (**100.0%**) a $\epsilon = 0.040$.

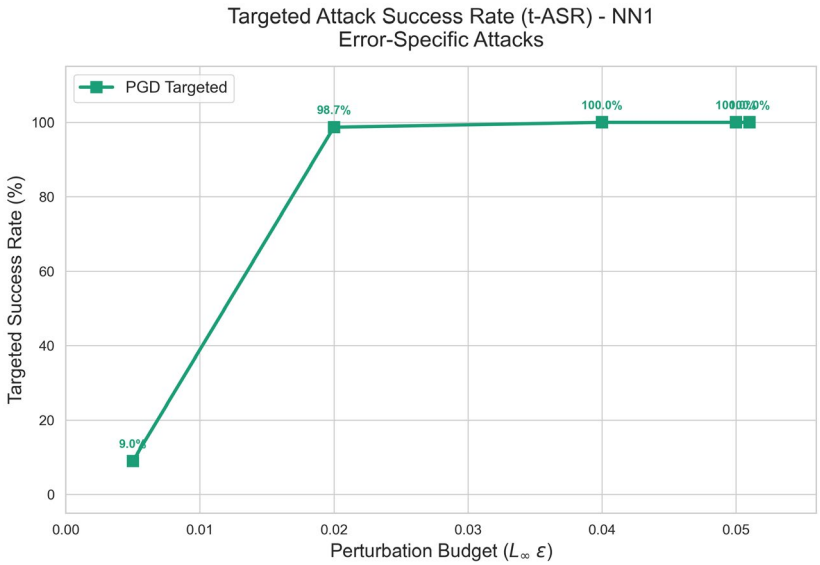


Figura 42 - Targeted Attack Success Rate - PGD RANDOM

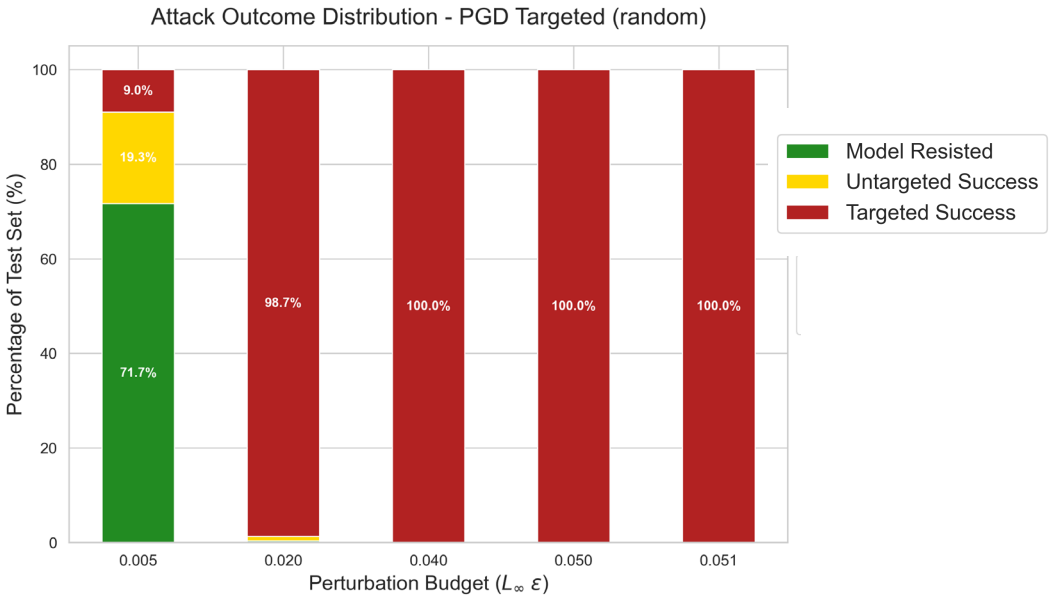


Figura 43 - Attack Outcome Distribution - PGD RANDOM

Il confronto tra i risultati *Random* e *Next-best* fornisce una prova empirica inconfutabile del comportamento geometrico delle CNN: maggiore è la distanza latente che separa due identità, maggiore è il budget L_∞ richiesto per costruire una traiettoria avversaria valida. Se l'euristica *Next-Best* saturava al 100% con un $\epsilon = 0.010$, lo scenario *Random* necessita di un budget marginalmente superiore per garantire la medesima certezza matematica.

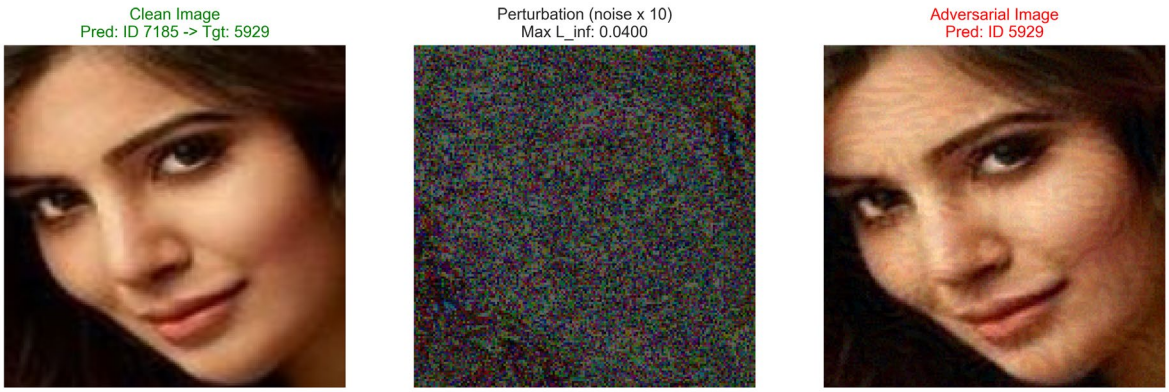


Figura 44 - Perturbation Showcase ($\epsilon = 0.04$)

3.3.4.3. LEAST-LIKELY

I dati empirici catturano in modo straordinario la dinamica "cinetica" dell'attacco, rivelando l'esistenza di una precisa soglia critica di energia perturbativa necessaria per attraversare la *loss landscape*.

- **Fase 1 – ($\epsilon = 0.005$):** A regimi ultra-restrittivi, l'algoritmo non possiede il raggio d'azione spaziale per colmare la distanza topologica. Come visibile nell'*Attack Outcome Distribution* (Figura 46), il modello resiste nel 70.4% dei casi (barra verde). Le immagini che vengono alterate finiscono per degenerare in *Untargeted Success* (29.5%), indicando che il gradiente ha spinto il tensore fuori dalla classe corretta, ma si è esaurito quasi istantaneamente, mancando totalmente l'impersonificazione (0.1% di t-ASR).
- **Fase 2 - ($\epsilon = 0.020$):** L'energia iniettata è ora sufficiente a sradicare la totalità delle immagini dalla *Safe Zone* originaria (il *Model Resisted* si azzera allo 0.0%). Tuttavia, la distribuzione degli esiti si spacca: se da un lato il 73.9% delle immagini raggiunge il bersaglio, un cospicuo **26.0%** degenera in *Untargeted Success* (barra gialla). Geometricamente, questo indica che i tensori sono "in transito": hanno intrapreso la traiettoria corretta verso il bersaglio *Least-Likely*, ma il budget ϵ si è esaurito a metà percorso, lasciando le immagini arenate nei confini decisionali di classi terze interposte lungo la rotta.
- **Fase 3 - ($\epsilon \geq 0.040$):** Il superamento della soglia di $\epsilon = 0.040$ conferisce all'algoritmo la totale libertà di manovra necessaria. La curva del *Targeted ASR* (Figura 45) raggiunge il **99.8%**, e l'area gialla degli errori intermedi scompare del tutto. L'algoritmo aggancia il target *worst-case* con precisione balistica assoluta, completando il percorso per l'intero test set.

L'analisi combinata conferma l'assunto teorico formulato all'inizio del capitolo: ottimizzare gli iperparametri per lo scenario *worst-case* garantisce di individuare il limite superiore di vulnerabilità della rete.
Per garantire il collasso assoluto **il valore ottimale si attesta a** $\epsilon = 0.040$.

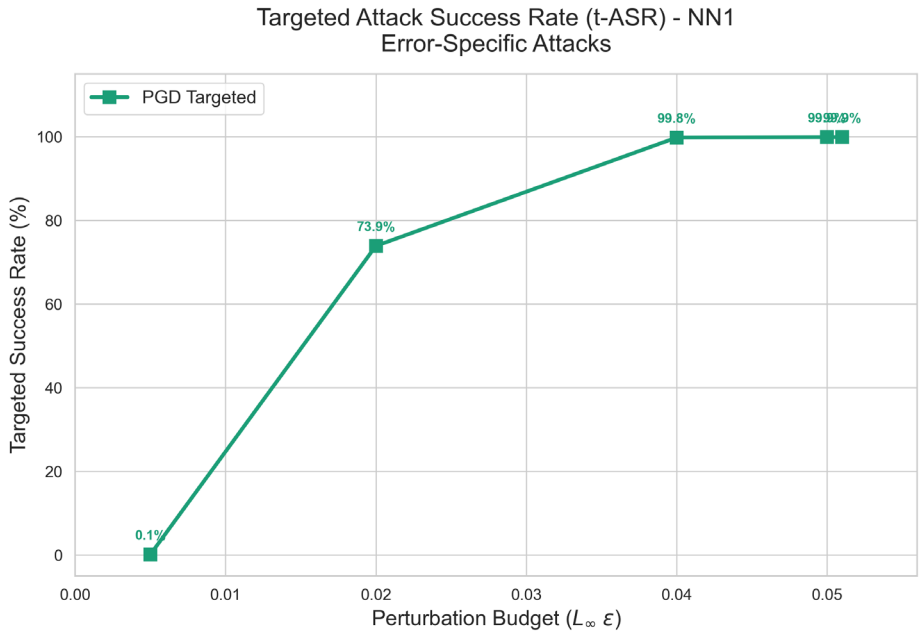


Figura 45 - Targeted Attack Success Rate - PGD LEAST-LIKELY

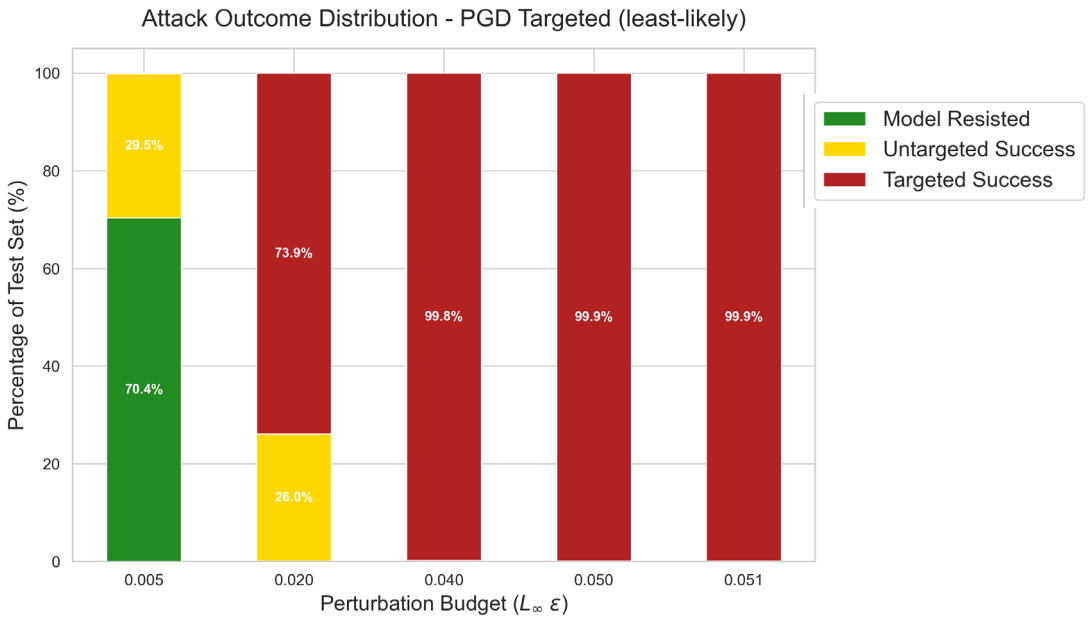


Figura 46 - Attack Outcome Distribution - PGD LEAST-LIKELY

3.3.5. CARLINI & WAGNER (C&W) TARGETED

Nello scenario *Error-Specific*, l'algoritmo Carlini & Wagner (C&W) affronta il problema dell'evasione in modo diametralmente opposto rispetto ai metodi iterativi rigidi (come BIM o PGD). Invece di proiettare brutalmente la perturbazione entro un budget prefissato, C&W riformula l'attacco come un problema di ottimizzazione senza vincoli geometrici. Impiega una funzione di costo *margin-based* per individuare la minima distorsione assoluta necessaria per non solo scavalcare il confine decisionale, ma approdare esattamente all'interno del bacino di attrazione della classe bersaglio.

Avvalendosi della medesima implementazione *custom* in **Double Precision (64-bit)** e dell'ottimizzatore **Adam In-Place** (descritti nella Sezione 3.2.6), l'algoritmo ha evitato la dissipazione dei gradienti sui target remoti. I valori degli iperparametri scelti per la generazione degli attacchi avversari sono stati adattati alla maggiore complessità topologica del *Targeted*: **MAX_ITER = 15** e **LEARNING RATE = 0.015**. A causa dell'estrema onerosità computazionale dell'ottimizzazione a 64-bit su matrici ad alta dimensionalità, i test valutativi per questo specifico algoritmo si sono concentrati esclusivamente sull'euristica *Next-Best*, scelto perché questo tipo di targeting è quello più difficile da difendere dopo.

3.3.5.1. NEXT-BEST

La curva del *Targeted ASR* (Figura 47) illustra una convergenza pressoché istantanea a fronte di perturbazioni visivamente nulle. A un budget microscopico calcolato in modo dinamico ($\epsilon \approx 0.007$), l'attacco vanta già un tasso di impersonificazione del **91.4%**. Concedendo un budget marginalmente superiore ($\epsilon \approx 0.023$), la curva satura in modo definitivo e matematico al **100.0%**.

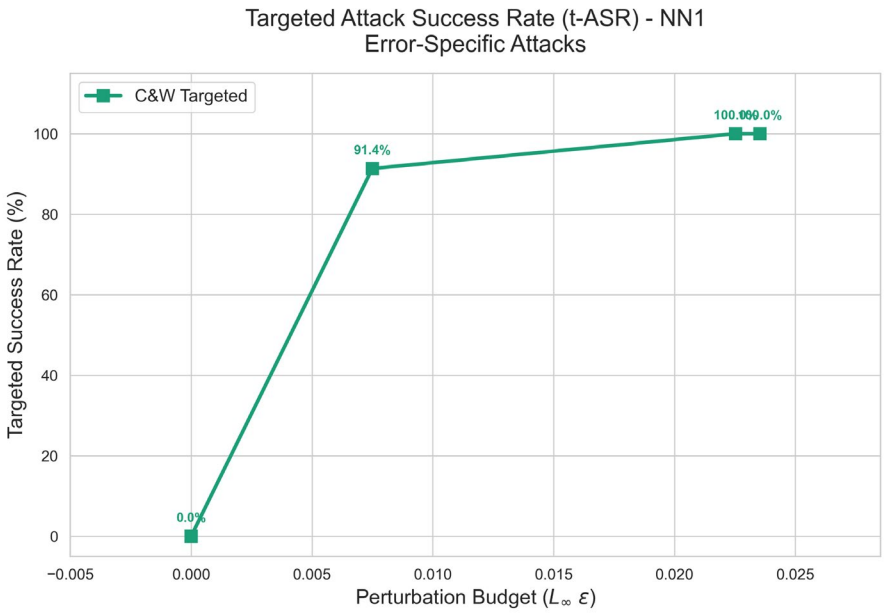


Figura 47 – Targeted Attack Success Rate – C&W NEXT-BEST

L'istogramma degli esiti (Figura 48) conferma l'assoluta precisione balistica dell'algoritmo. L'area gialla (*Untargeted Success*) è categoricamente assente (0.0%). Guidato dalla sua funzione di costo *margin-based*, C&W non innesca mai un *overshooting* caotico tipico degli attacchi *single-step*: la penalizzazione esatta dei logit estranei garantisce che il tensore rimanga ancorato alla classe originale finché il budget è insufficiente (area verde), per poi "scivolare" con precisione chirurgica esclusivamente all'interno della regione decisionale del bersaglio (area rossa).

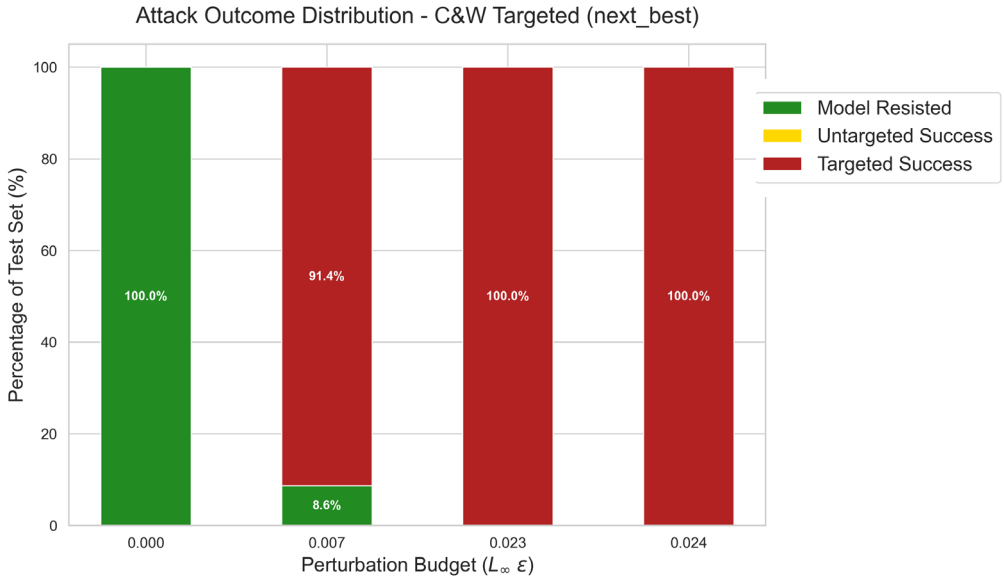


Figura 48 – Attack Outcome Distribution – C&W NEXT-BEST

La natura sofisticata del C&W è dimostrata visivamente nel *Perturbation Showcase* (Figura 49). Osservando la mappa del rumore generata per l'attacco a $\epsilon = 0.0075$ (amplificata artificialmente per l'ispezione), si nota la totale assenza del classico rumore stocastico a scacchiera o ad alta frequenza uniforme tipico di FGSM e PGD. La perturbazione assume chiari connotati strutturali, delineando in negativo i contorni semantici del volto (arcate sopraccigliari, profili del naso e delle labbra). Questo certifica che l'algoritmo sta attivamente manipolando le *feature* morfologiche profonde estratte da InceptionResnetV1, operando una vera e propria "chirurgia latente" sul volto della vittima.

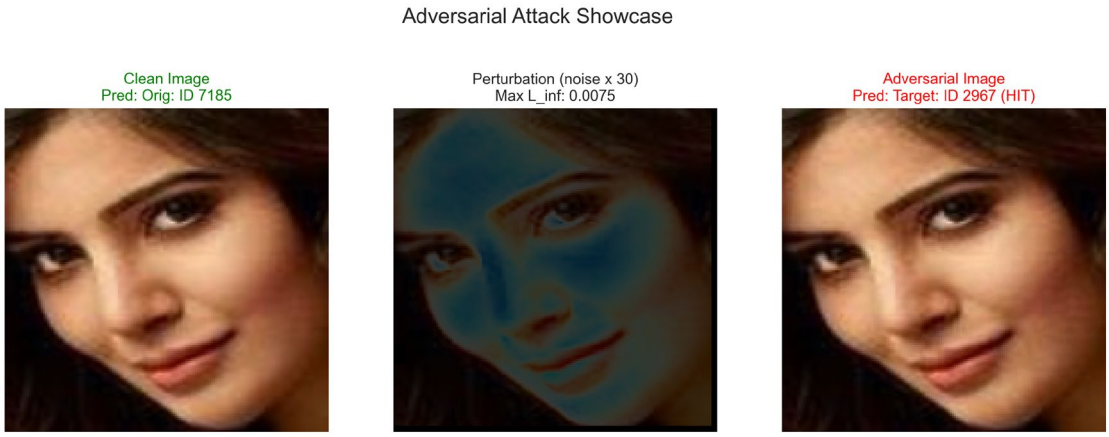


Figura 49 - Perturbation Showcase ($\epsilon = 0.0075$)

Nello scenario *Next-Best*, l'algoritmo C&W invalida di fatto il limite protettivo imposto dal *threat model* ($\epsilon \leq 0.10$). Il valore ottimale assoluto si attesta a $\epsilon \approx 0.023$. A questa soglia, la rete è totalmente compromessa (100% t-ASR) a fronte di un'alterazione massima limitata al 2.3% del range dinamico dei pixel, rendendo l'esito dell'attacco biologicamente impercettibile e crittograficamente inscindibile dall'immagine sorgente pulita.

3.3.6. VALUTAZIONE COMPLESSIVA DEGLI ATTACCHI TARGETED

I risultati riepilogati nella Figura 50 evidenziano la marcata e strutturale vulnerabilità del modello InceptionResnetV1 di fronte alle perturbazioni *Error-Specific*. Sull'intero test set acquisito, composto da 1000 campioni, l'analisi comparativa certifica che la capacità di impersonificazione mirata dipende strettamente dalla natura matematica dell'algoritmo di ottimizzazione impiegato.

Attacco	Scenario	Epsilon (ε)	t-ASR
FGSM	Next-Best	0.025	**97.0%**
	Random	0.025	**19.7%**
	Least-Likely	0.025	**0.0%**
BIM	Next-Best	0.025	**100.0%**
	Random	0.025	**100.0%**
	Least-Likely	0.050	**100.0%**
PGD	Next-Best	0.010	**100.0%**
	Random	0.040	**100.0%**
	Least-Likely	0.040	**99.8%**
Carlini & Wagner	Next-Best	0.023	**100.0%**
	Random	-	-
	Least-Likely	-	-

Figura 50 - Tabella complessiva degli attacchi targeted

4. VALUTAZIONE DELLA TRASFERIBILITÀ

Una delle proprietà più critiche degli Esempi Avversari è la loro intrinseca trasferibilità (*Transferability*). Questa si definisce come l'attitudine di una perturbazione, ottimizzata sui gradienti di un modello sorgente noto (*White-Box*), a mantenere intatta la propria efficacia offensiva quando sottoposta a un modello bersaglio differente e ignoto all'attaccante (*Black-Box*). Tale fenomeno si verifica poiché reti neurali addestrate sullo stesso dominio di dati (nel nostro caso, VGGFace2) tendono ad apprendere *feature* e confini decisionali topologicamente simili. Questo capitolo analizza l'efficacia degli attacchi generati sull'architettura NN1 (InceptionResnetV1) quando vengono sottoposti alla rete NN2 (SENet50_ft).

4.1. SETUP SPERIMENTALE BLACK-BOX

Per garantire la validità scientifica dell'esperimento di trasferibilità, il calcolo delle metriche è stato sottoposto a un rigoroso vincolo di filtraggio: il *Transfer Attack Success Rate* (Transfer ASR) è stato calcolato **esclusivamente** sul sottoinsieme di immagini per cui la rete NN2 forniva una classificazione corretta in assenza di rumore avversario. Ciò assicura che il fallimento predittivo sia imputabile unicamente all'efficacia della perturbazione trasferita, e non a un'intrinseca debolezza della rete bersaglio.

4.1.1. SFIDE NELLA TRASFERIBILITÀ CROSS-RESOLUTION

La prima e più complessa barriera alla trasferibilità tra i due modelli è di natura puramente spaziale geometrica. Il modello sorgente (NN1) opera su immagini 160×160, mentre il modello target (NN2) richiede tassativamente input a risoluzione 224×224.

L'approccio convenzionale prevede l'upscaling tramite interpolazione bilineare; tuttavia, tale interpolazione agisce matematicamente come un filtro spaziale passa-basso (*Low-Pass Filter*), che sfoca e diluisce le perturbazioni L_∞ ad alta frequenza generate da ottimizzatori come PGD o C&W, degradando massicciamente l'efficacia dell'attacco prima ancora che raggiunga NN2.

Per ovviare a questo problema e testare la "Trasferibilità Pura" del rumore tra le due topologie di rete, sono state ideate, testate e infine scartate quattro soluzioni ingegneristiche alternative, qui documentate a riprova della complessità del *Domain Shift*:

1. **Zero-Padding e Context-Aware Padding:**
   Invece di ridimensionare l'immagine avversaria 160×160, la si posiziona al centro di uno spazio tensoriale 224×224, riempiendo i 32 pixel di bordo per lato con valori neutri (Zero-Padding) o con le distribuzioni di sfondo dell'immagine originale. Ciò preserverebbe intatti i pixel alterati dall'attacco.
   Criticità: SENet50 è stata addestrata esclusivamente su volti che riempiono interamente il frame visivo. Fornire un volto rimpicciolito circondato da un bordo artificiale introduce un drastico effetto *Out-of-Distribution* (OOD). Il bordo altera irrimediabilmente le medie calcolate dal *Global Average Pooling* finale. L'accuratezza su tali immagini è crollata già sulla *Clean Baseline*, rendendo il sistema "invalido" ancor prima di subire l'attacco.
2. **Purificazione e Upscaling tramite Modelli Generativi (VAE):**
   Utilizzare un Autoencoder Variazionale (VAE) per eseguire l'upscaling "intelligente" dell'immagine da 160 a 224, evitando lo smussamento meccanico dell'interpolazione bilineare.
   Criticità: Il passaggio attraverso lo spazio latente compresso (*bottleneck*) di un modello generativo agisce come un potentissimo denoiser. L'Encoder cattura i tratti somatici macroscopici ma scarta il rumore avversario, non potendolo mappare nello spazio latente delle facce naturali. Il Decoder restituirebbe un'immagine a 224×224 purificata. Questa tecnica equivarrebbe ad applicare un meccanismo di *Adversarial Purification*, vanificando lo scopo del test Black-Box.

3. **Isolamento e Traslazione Indipendente della Perturbazione:**
   Estrarre la sola matrice di rumore avversario ($\delta_{160} = X_{adv} - X_{clean}$), scalarla tramite interpolazione *Nearest Neighbor* (per non alterare la norma ϵ) e sommarla direttamente al volto 224×224 pulito.
   Criticità: Si innesca un irrisolvibile *Semantic Misalignment*. La topologia del volto in un'immagine 160×160 ha coordinate diverse rispetto a quella a 224×224. Il rumore originariamente ottimizzato per corrompere i gradienti di un occhio, ad esempio, verrebbe traslato sulla guancia, distruggendo la precisione degli attacchi e rendendo inutile la perturbazione.
4. **Source Model Over-Resolution (Generazione nativa a 224x224 su NN1):**
   Sfruttare il layer AdaptiveAvgPool2d di InceptionResnetV1, che la rende teoricamente agnostica rispetto alla risoluzione. Sottoponendo a NN1 immagini già a 224×224 in fase di attacco, l'ottimizzatore calcolerebbe gradienti e perturbazioni direttamente alla risoluzione target di NN2.
   Criticità: Sottoposta a valutazione empirica, la *Clean Baseline* di NN1 alimentata a 224×224 ha mostrato un collasso dell'accuratezza dal 91.50% al 59.50%. I filtri convoluzionali (es. 3×3) di NN1 sono stati calibrati durante il training su scale facciali specifiche; un'immagine del 40% più grande causa un "fuori scala" per il Campo Recettivo (*Receptive Field*) della rete. Generare attacchi su una baseline già intrinsecamente "cieca" inficierebbe la validità scientifica del risultato.

Conclusione Adottata:
Alla luce delle sopracitate limitazioni topologiche e spaziali, si è optato per il mantenimento dell'approccio standard: **generazione dell'attacco alla risoluzione nativa del modello sorgente (**160×160**) e upscaling bilineare in fase di inferenza sul modello target.** Sebbene l'upscaling attenui parzialmente l'efficacia perturbativa L_∞, questo approccio modella rigorosamente lo scenario di attacco *Black-Box* più realistico in cui un aggressore debba forzare il proprio input malevolo in un sistema ignoto.

4.1.2. SCELTA DELL'ARCHITETTURA TARGET: L'IPOTESI RESNET50 E L'ADOZIONE DI SENET50

Oltre alle problematiche legate alla discrepanza dimensionale, la definizione del setup Black-Box ha richiesto un'attenta valutazione architetturale. In fase di progettazione, sono stati condotti test paralleli di trasferibilità utilizzando come rete bersaglio una **ResNet50 addestrata da *scratch*** sul medesimo dominio di dati. L'ipotesi speculativa iniziale presupponeva che, data la forte affinità topologica tra InceptionResnetV1 (NN1) e ResNet50 (entrambe basate sulla propagazione lineare dei gradienti tramite connessioni residuali standard), gli Esempi Avversari avrebbero goduto di un *Transfer ASR* sensibilmente **superiore** rispetto ad architetture diverse.
Tuttavia, l'indagine empirica ha smentito tale assunto: i tassi di trasferimento registrati su ResNet50 si sono rivelati pressoché identici a quelli ottenuti sulla rete **SENet50**. Di fronte a questa equivalenza statistica, al fine di evitare ridondanze sperimentali, si è optato per l'adozione definitiva di SENet50 come rete NN2 ufficiale.
Questa scelta metodologica è strategicamente giustificata dalla volontà di rendere lo scenario Black-Box il più robusto possibile: i moduli di ricalibrazione adattiva dei canali (*Squeeze-and-Excitation blocks*) presenti in SENet50 introducono una divergenza architetturale profonda rispetto a NN1. Se un attacco riesce a trasferirsi su SENet50, il successo non è imputabile a una banale similitudine strutturale tra i modelli, ma alla reale e intrinseca gravità della perturbazione generata.

4.1.3. PRE-PROCESSING E NORMALIZZAZIONE CAFFE PER SENET50

Il secondo ostacolo risiede nel *Domain Shift* del pre-processing. Mentre InceptionResnetV1 (NN1) opera su tensori in formato RGB normalizzati scalarmente nel range $[-1.0, 1.0]$, SENet50 (NN2) richiede un tensore in formato BGR, sul quale viene operata una sottrazione statica delle medie del dataset (Mean Subtraction: $[91.49, 103.88, 131.09]$) senza applicare alcuno scaling frazionario.

La proiezione forzata delle perturbazioni ottimizzate su NN1 all'interno di questo differente dominio vettoriale costituisce il benchmark ideale per verificare se la vulnerabilità risieda nelle logiche universali di estrazione delle feature o sia strettamente sovradattata alle equazioni di normalizzazione della rete sorgente.

4.2. TRASFERIBILITÀ DEGLI ATTACCHI ERROR-GENERIC (UNTARGETED)

Poiché l'obiettivo è la mera distruzione delle *feature* identificative della classe originale (che risultano universalmente rilevanti a prescindere dall'architettura), l'esito dell'attacco dipende principalmente dall'aggressività della perturbazione e dalla sua invarianza alle trasformazioni spaziali.

4.2.1. TRASFERIBILITÀ FGSM

Il confronto tra le curve di *Security Evaluation* nei due scenari svela l'impatto quantitativo della barriera architetturale (Upscaling e Normalizzazione Caffe).

Come illustrato nella curva originale (Figura 52), l'FGSM Untargeted gode di un'efficacia devastante sull'oracolo. Già al budget minimo di $\epsilon = 0.025$, la *Robust Accuracy* collassa istantaneamente allo **0.8%**. La rete sorgente risulta totalmente incapace di resistere alla perturbazione calcolata sui propri pesi.

Sottoponendo i medesimi campioni avversari alla rete SENet50 (Figura 51), si osserva un drastico recupero delle prestazioni iniziali. Al medesimo budget $\epsilon = 0.025$, la *Robust Accuracy* risale al **34.8%**. La discrepanza spaziale (il ridimensionamento da 160×160 a 224×224) e il filtro dei layer di Squeeze-and-Excitation di NN2 neutralizzano quasi due terzi del potere offensivo dell'attacco.

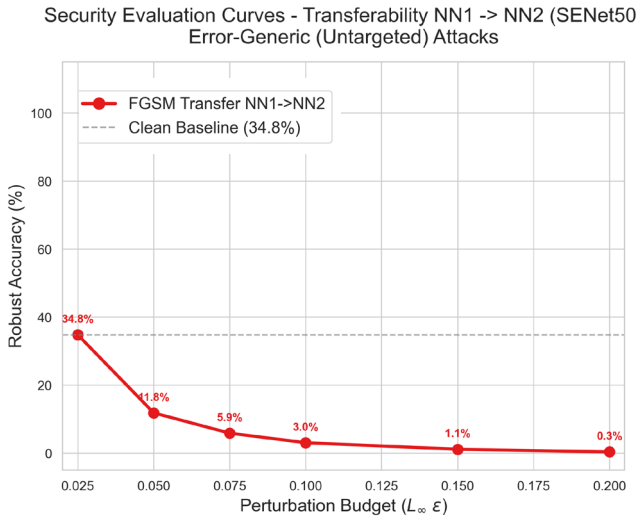


Figura 51 – Security Evaluation Curves – Transferability FGSM

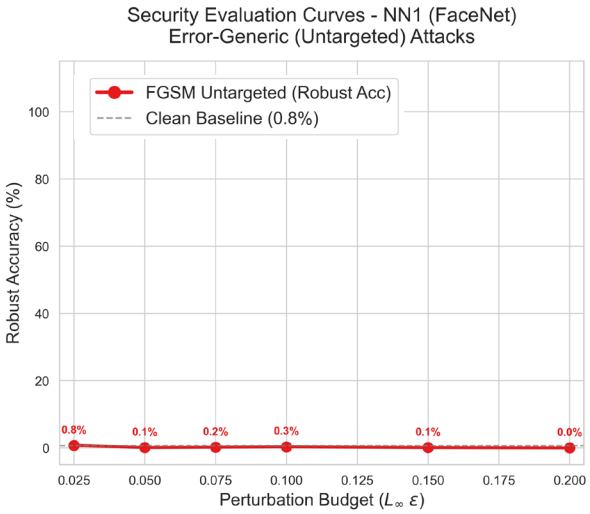


Figura 52 - Security Evaluation Curves – FGSM NN1

Nonostante lo "scudo" iniziale offerto dal *domain shift*, la curva di trasferimento dell'FGSM dimostra una notevole resilienza all'aumentare dell'intensità dell'attacco. Salendo con il budget perturbativo, la *Robust Accuracy* di NN2 viene inesorabilmente erosa, scendendo all'**11.8%** per $\epsilon = 0.050$, fino a capitolare quasi totalmente allo **3.0%** al regime massimo di $\epsilon = 0.1$.

4.2.2. TRASFERIBILITÀ BIM

Il confronto tra le curve di sicurezza evidenzia dinamiche diametralmente opposte rispetto a quanto osservato per gli attacchi *single-step*.

Il grafico sorgente (Figura 54) conferma la supremazia dell'approccio iterativo sull'oracolo noto. A un budget di $\epsilon = 0.050$, il BIM disintegra il modello, abbassando la *Robust Accuracy* ad appena il **2.6%**, per poi azzerarla totalmente a regimi superiori.

Sottoponendo i medesimi tensori alla rete SENet50 (Figura 53), l'efficacia dell'attacco svanisce in modo sorprendente. Al budget minimo ($\epsilon = 0.025$), la rete bersaglio risulta quasi totalmente immune, registrando una *Robust Accuracy* del **93.9%** (un valore immensamente superiore al 34.8% registrato dall'FGSM a parità di condizioni). Come si evince dal grafico il BIM non riesce ad erodere in modo significativo l'accuratezza di NN2, anche forzando il budget massimo l'accuratezza non supera il **45.8%**.

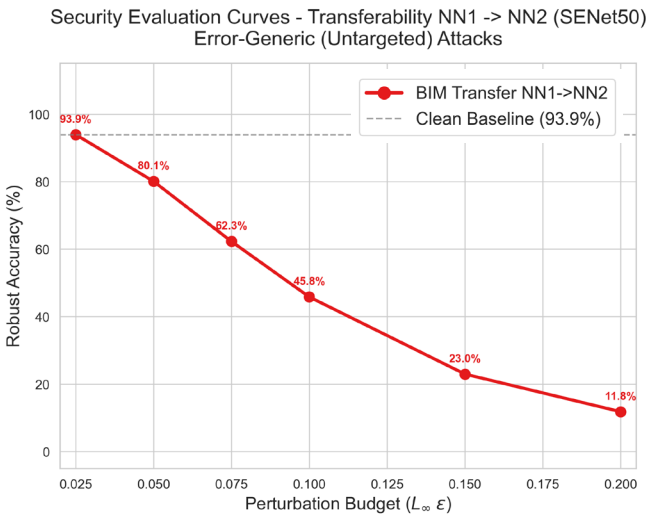


Figura 53 - Security Evaluation Curves – Transferability BIM

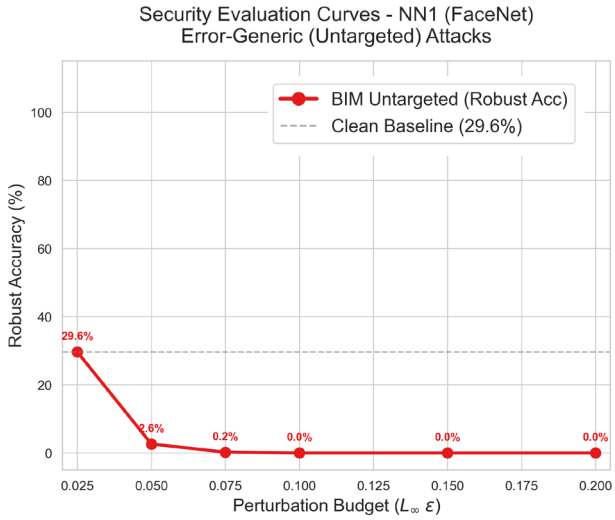


Figura 54 - Security Evaluation Curves – BIM NN1

Questo drastico disallineamento tra prestazioni *White-Box* e *Black-Box* illustra uno dei concetti cardine dell'Adversarial Machine Learning: l'**Overfitting della Perturbazione** (*Perturbation Overfitting*).

Ricalcolando il gradiente ad ogni micropasso, il BIM si adatta in modo "chirurgico" alla specifica topologia della *loss landscape* di InceptionResnetV1, infilandosi nei minimi locali e sfruttando micro-vulnerabilità altamente specifiche di quell'architettura. Tuttavia, questa precisione geometrica è estremamente fragile. Quando l'immagine subisce il *domain shift* — ovvero il ridimensionamento spaziale a 224×224 e l'applicazione dei filtri *Squeeze-and-Excitation* di NN2 — il rumore iper-localizzato del BIM viene sfocato spazialmente e disallineato semanticamente.

4.2.3. TRASFERIBILITÀ PGD

La peculiarità del test condotto sul PGD risiede nella scala perturbativa adottata: l'algoritmo è stato valutato su micro-budget ($\epsilon_{max} \leq 0.025$), evidenziando dinamiche di trasferimento notevolmente più aggressive rispetto al BIM.

Come illustrato nella curva di efficacia nativa (Figura 56), l'algoritmo annienta l'oracolo con estrema rapidità. A un budget di appena $\epsilon = 0.010$ (l'1% della dinamica dei pixel), la *Robust Accuracy* crolla allo **0.7%**, saturando allo 0.0% nei regimi marginalmente superiori.

Il trasferimento su SENet50 (Figura 55) evidenzia nuovamente il fisiologico "scudo" iniziale dettato dal *Domain Shift*. A $\epsilon = 0.010$ (laddove NN1 era già distrutta), NN2 conserva ancora un'accuratezza del **75.9%**. Tuttavia, con un lieve incremento del rumore ($\epsilon = 0.020$), la difesa architetturale di NN2 inizia a cedere drasticamente, abbassando la *Robust Accuracy* al **39.8%**.

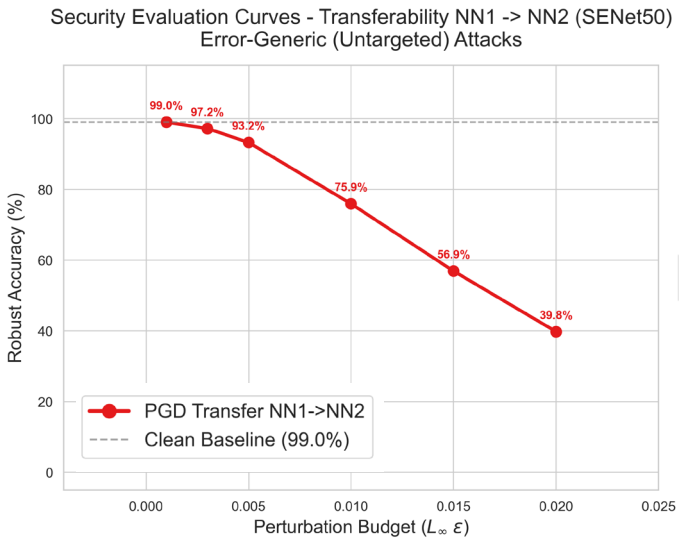


Figura 55 - Security Evaluation Curves – Transferability PGD

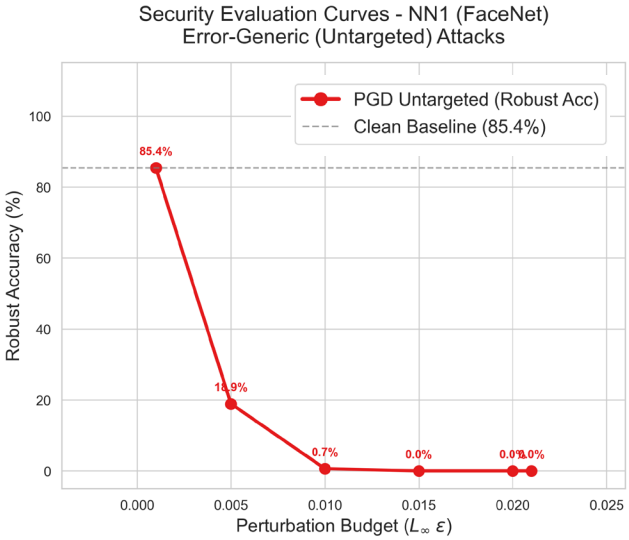


Figura 56 - Security Evaluation Curves – PGD NN1

L'aspetto più rilevante emerge dal confronto diretto con il BIM. Sottoposta al BIM con $\epsilon = 0.025$, la rete SENet50 manteneva un'accuratezza del 93.9%. Al contrario, sottoposta al PGD con un budget addirittura inferiore ($\epsilon = 0.020$), la medesima rete vede le proprie prestazioni più che dimezzate (39.8%).

Questa netta superiorità nella trasferibilità è la diretta conseguenza della differente esplorazione geometrica dello spazio latente. La peculiarità strutturale che eleva il PGD rispetto al BIM risiede nella proiezione iterativa della perturbazione all'interno di un'ipersfera di raggio ϵ (il vincolo L_∞), combinata con l'inizializzazione casuale del punto di partenza al suo interno (*random restarts*).

Mentre il BIM procede in modo strettamente deterministico, "scivolando" ciecamente verso il primo gradiente disponibile e incagliandosi in minimi locali estremamente ripidi e stretti (*sharp minima*), l'esplorazione stocastica all'interno dell'ipersfera permette al PGD di rimbalzare e generalizzare. Questo vincolo geometrico spinge l'ottimizzatore a convergere verso avvallamenti più ampi e stabili della *loss landscape* (*flat minima*).

Un rumore avversario ancorato all'interno di un *flat minimum* possiede una resilienza matematica nettamente superiore. Esso tollera lievi spostamenti nello spazio senza perdere la propria natura malevola, riuscendo a conservare l'efficacia offensiva anche a fronte delle distorsioni indotte dal *Domain Shift* spaziale (upscaling a 224×224) e cromatico (normalizzazione Caffe). In conclusione, il vincolo sferico di proiezione e la stocasticità del PGD agiscono come un naturale regolarizzatore contro l'overfitting della perturbazione, garantendo un'elevata trasferibilità in contesti Black-Box.

4.2.4. TRASFERIBILITÀ DEEPFOOL

L'analisi incrociata delle curve di sicurezza evidenzia il divario prestazionale più estremo registrato in fase di valutazione *Black-Box*.

Sul modello sorgente (Figura 58), l'algoritmo dimostra un'elevata efficienza. A un budget $\epsilon = 0.025$, la *Robust Accuracy* precipita al **36.2%**, raggiungendo un quasi totale annullamento delle capacità predittive della rete (**0.7%**) già a $\epsilon = 0.075$.

Sottoponendo le medesime immagini a SENet50 (Figura 57), l'attacco viene integralmente neutralizzato. La curva di sicurezza si trasforma in una retta pressoché piatta: al budget minimo l'accuratezza è del **99.2%**, e perfino consentendo all'algoritmo un margine di manovra teorico massimo ($\epsilon = 0.1$), la rete bersaglio mantiene una resilienza granitica pari al **98.8%**. L'efficacia dell'attacco è statisticamente nulla.

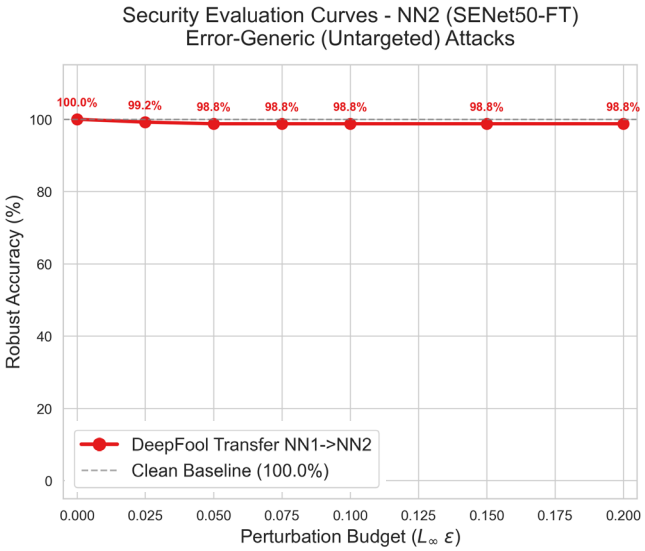


Figura 57 - Security Evaluation Curves – Transferability Deepfool

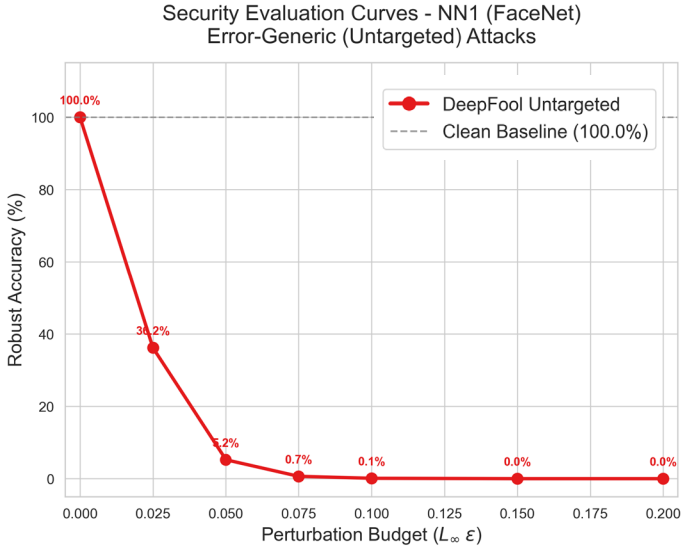


Figura 58 - Security Evaluation Curves – Deepfool NN1

Questo fallimento dimostra i limiti di un attacco eccessivamente "mirato". A differenza di altri algoritmi, DeepFool è progettato per calcolare la perturbazione minima esatta per ingannare NN1, fermandosi non appena oltrepassa il confine decisionale.

Tuttavia, proprio questa estrema precisione geometrica rende l'attacco molto fragile. Non possedendo alcun "margine di errore" o energia residua, la minima alterazione causata dal ridimensionamento dell'immagine per NN2 è sufficiente a distruggere il delicato equilibrio della perturbazione, facendo ricadere l'immagine nella sua classe originale. In sintesi, un attacco troppo iper-ottimizzato per una specifica rete perde del tutto la propria capacità di trasferirsi su altre architetture.

4.2.5. TRASFERIBILITÀ C&W

Il confronto tra le due *Security Evaluation Curves* espone il divario prestazionale più estremo registrato nell'intera indagine empirica.

Il grafico sorgente (Figura 60) conferma l'efficienza letale dell'algoritmo. Con un budget microscopico pari a $\epsilon \approx 0.0025$, l'accuratezza viene pressoché dimezzata (58.9%). La rete collassa totalmente (Robust Accuracy allo **0.0%**) a un limite di $\epsilon \approx 0.013$, soglia in cui il rumore risulta biologicamente impercettibile all'occhio umano.

Sottoponendo i medesimi tensori alla rete SENet50 (Figura 59), l'efficacia dell'attacco viene letteralmente annullata. La curva di trasferimento si presenta come una retta asintotica fissa al limite superiore: al budget massimo calcolato dall'algoritmo, la rete bersaglio conserva una resilienza quasi perfetta pari al **98.0%**. Il *Transfer ASR* è statisticamente trascurabile.

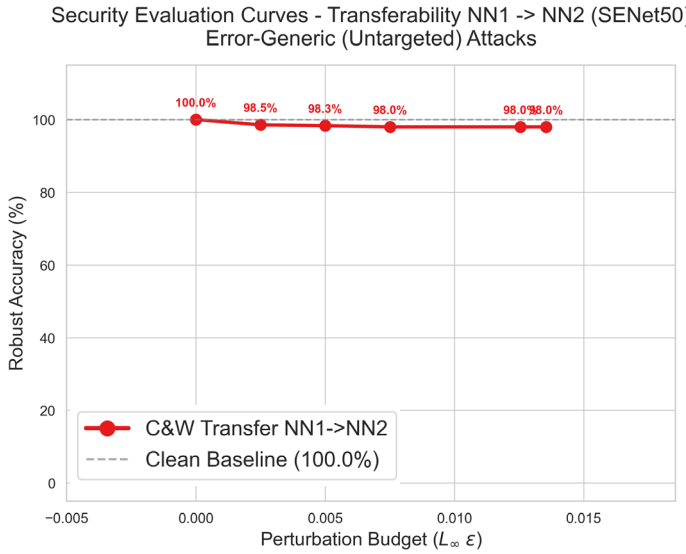


Figura 59 - Security Evaluation Curves – Transferability C&W

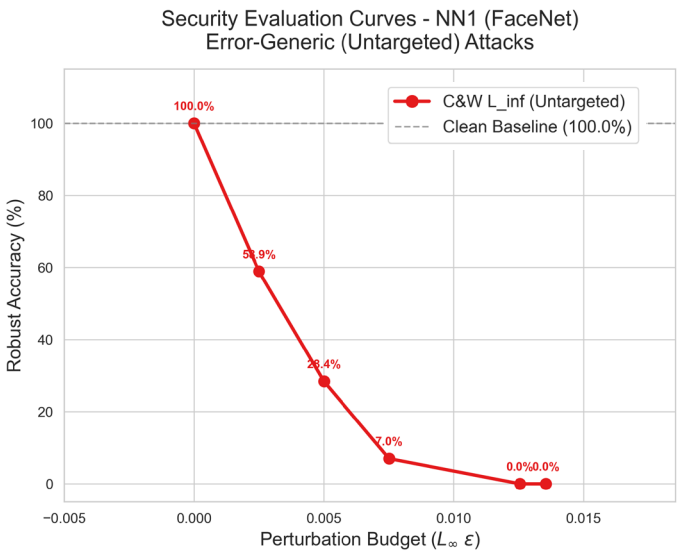


Figura 60 - Security Evaluation Curves – C&W NN1

Il fallimento sistematico del C&W nello scenario *Black-Box* convalida formalmente il paradigma dell'**Overfitting della Perturbazione**.

Dato che l'algoritmo C&W non inietta rumore stocastico, ma "scolpisce" alterazioni semantiche ad altissima frequenza perfettamente allineate ai filtri convoluzionali di NN1, ed essendo l'alg

oritmo progettato per arrestarsi nell'esatto istante in cui la *loss margin-based* viene soddisfatta, il tensore avversario **non possiede alcuna energia perturbativa residua**. Come per DeepFool, l'attacco risulta essere troppo ottimizzato per una specifica rete, perdendo del tutto la propria capacità di trasferirsi su altre architetture.

4.3. TRASFERIBILITÀ DEGLI ATTACCHI ERROR-SPECIFIC (TARGETED)

In questo scenario, l'attacco non solo deve distruggere la rappresentazione originale della classe, ma deve anche sopravvivere al passaggio attraverso una nuova architettura (NN2) ed allinearsi per coincidenza ai gradienti e ai confini decisionali della specifica classe bersaglio impostata su NN1.

4.3.1. TRASFERIBILITÀ FGSM (TARGETED)

L'analisi della trasferibilità per l'algoritmo FGSM in scenario mirato conferma in modo lampante le gravi limitazioni strutturali degli attacchi *single-step*. Al fine di fornire una comparazione organica, le curve di *Targeted Transfer ASR* relative a tutte le euristiche esplorate sono state aggregate in un'unica vista riepilogativa.

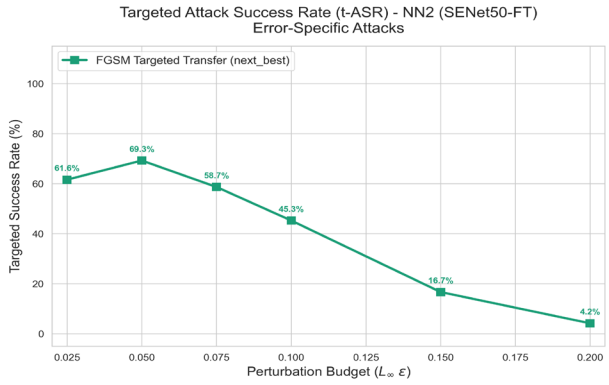


Figura 61 - Targeted Attack Success Rate - FGSM NEXT-BEST

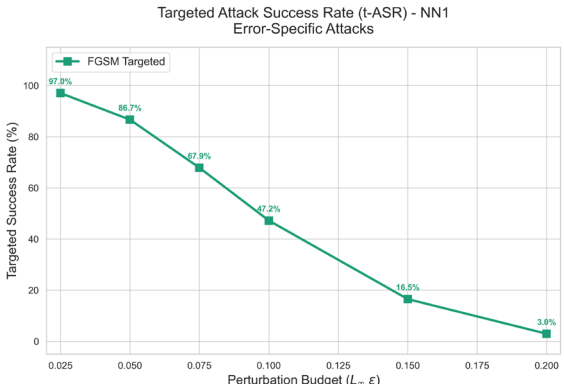


Figura 62 - Targeted Attack Success Rate - FGSM NEXT-BEST

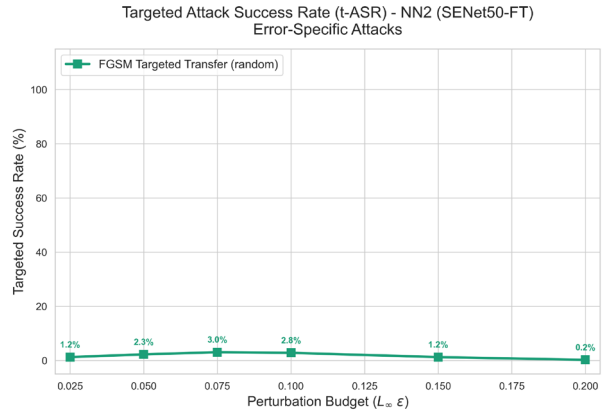


Figura 63 - Targeted Attack Success Rate - FGSM RANDOM

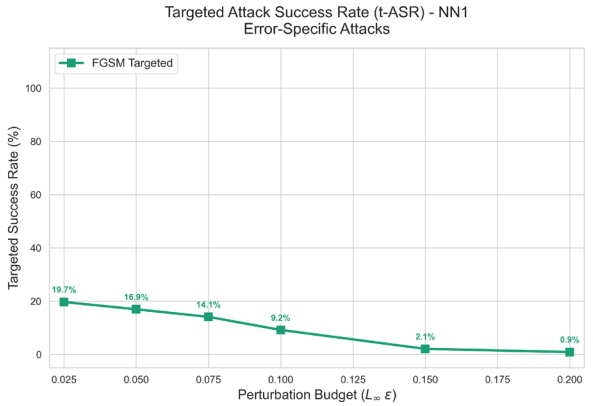


Figura 64 - Targeted Attack Success Rate - FGSM RANDOM

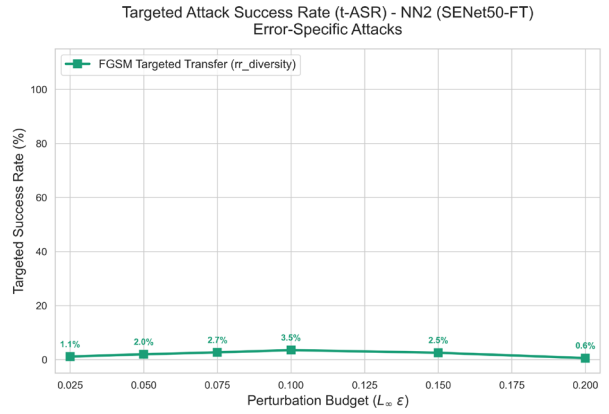


Figura 65 - Targeted Attack Success Rate - FGSM RR-DIVERSITY

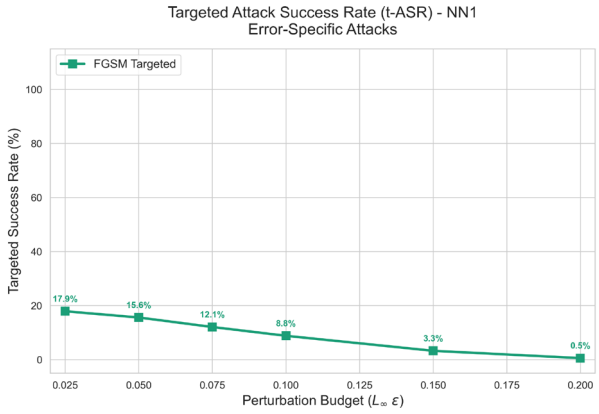


Figura 66 - Targeted Attack Success Rate - FGSM RR-DIVERSITY

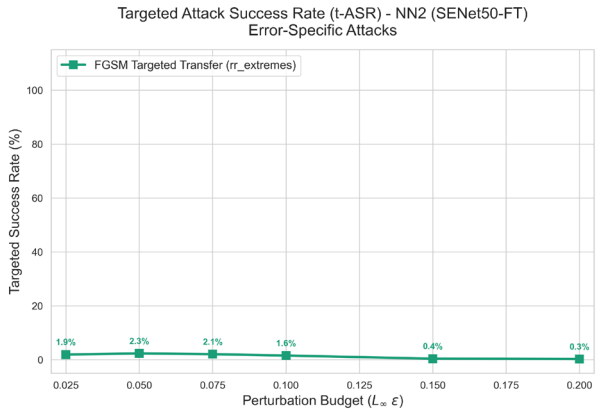


Figura 67 - Targeted Attack Success Rate - FGSM RR-EXTREMES

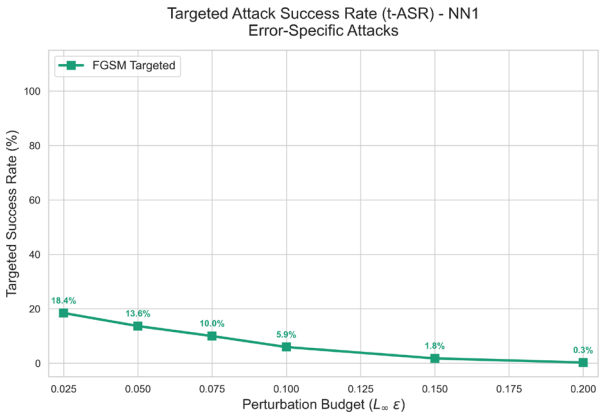


Figura 68 - Targeted Attack Success Rate - FGSM RR-EXTREMES

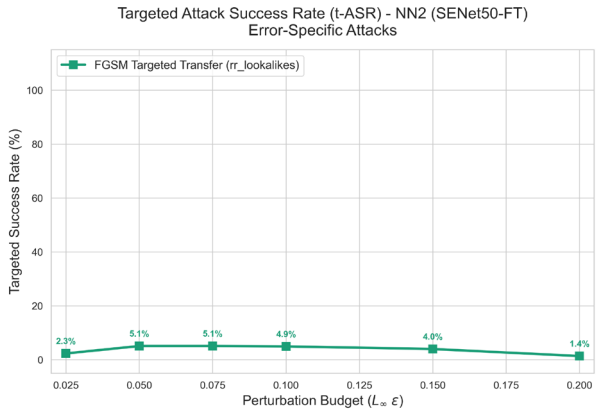


Figura 69 - Targeted Attack Success Rate - FGSM RR-LOOKALIKES

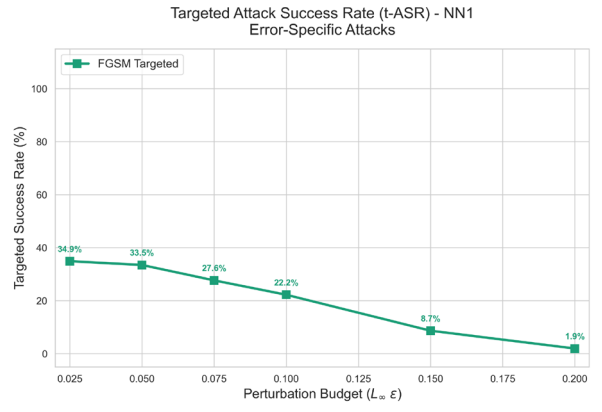


Figura 70 - Targeted Attack Success Rate - FGSM RR-LOOKALIKES

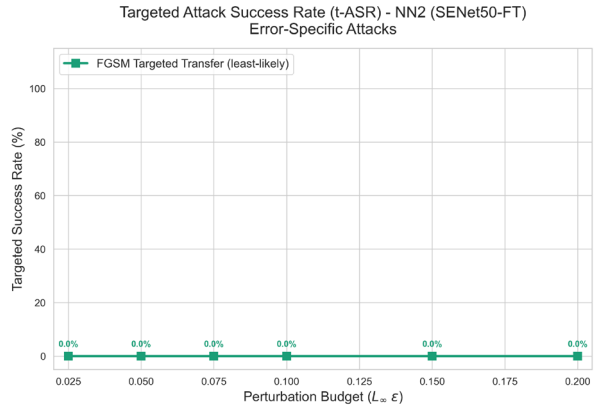


Figura 71 - Targeted Attack Success Rate – FGSM LEAST-LIKELY

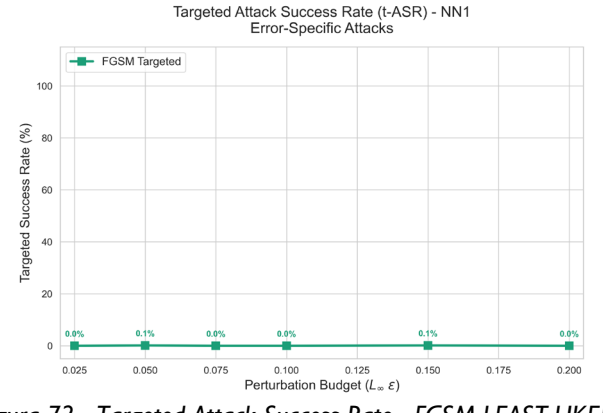


Figura 72 - Targeted Attack Success Rate - FGSM LEAST-LIKELY

Osservando i dati globali, emerge come la natura lineare e non iterativa dell'FGSM sia quasi del tutto insufficiente a forzare un'impersonificazione su un'architettura *Black-Box* come SENet50. Per tutte le strategie che richiedono uno spostamento nello spazio latente verso bersagli arbitrari, distanti o complessi (come *Random*, *Least-Likely* e le varianti *Round-Robin*), la curva di successo su NN2 risulta pressoché piatta. A prescindere dal budget ϵ concesso, il t-ASR si arena su valori riconducibili a puro rumore statistico (oscillando tra lo 0.0% e il 3.0%).

L'unica anomalia statistica di parziale rilievo si registra nell'euristica *Next-Best*. In questo specifico scenario, il tasso di trasferimento raggiunge valori moderati (toccando un picco del 69.3% a $\epsilon = 0.050$).

4.3.2. TRASFERIBILITÀ BIM (TARGETED)

L'algoritmo Basic Iterative Method (BIM), pur avendo dimostrato un dominio assoluto nello scenario *White-Box* (forzando il 100% di *Targeted ASR* in tutte le euristiche), manifesta gravi criticità strutturali quando sottoposto al test di trasferibilità. La sua natura fortemente iterativa lo porta a ottimizzare la perturbazione in modo speculare sulla *loss landscape* di InceptionResnetV1. Nel passaggio a SENet50, questo estremo sovradattamento (*Perturbation Overfitting*) causa una frammentazione del gradiente, vanificando la convergenza mirata.

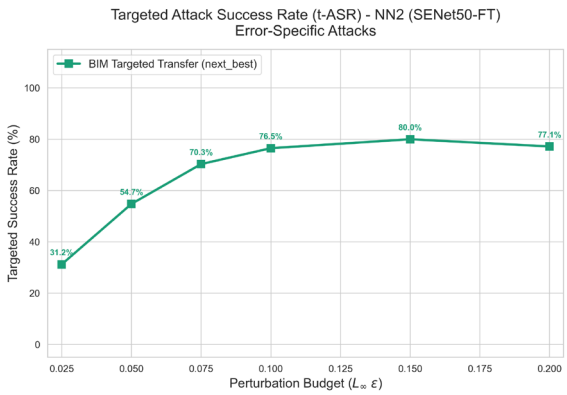


Figura 73 - Targeted Attack Success Rate - BIM NEXT-BEST

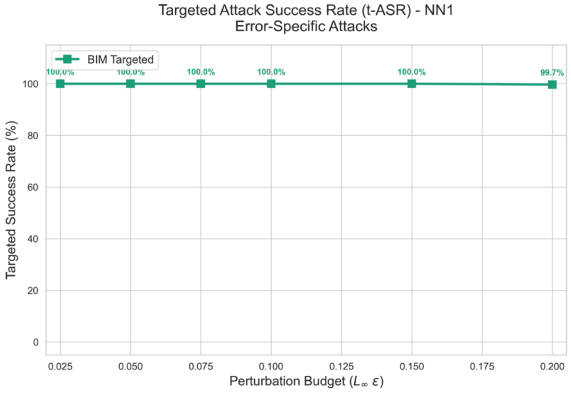


Figura 74 - Targeted Attack Success Rate - BIM NEXT-BEST

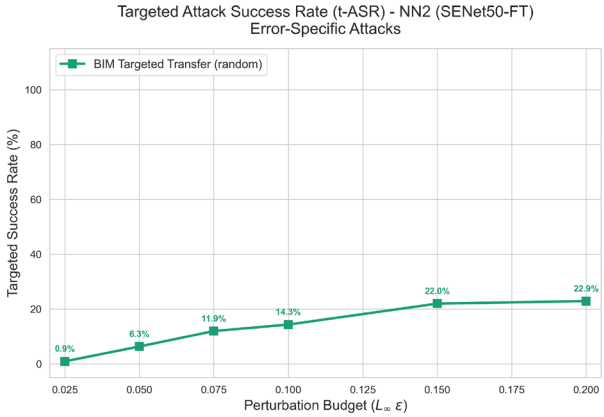


Figura 75 - Targeted Attack Success Rate - BIM RANDOM

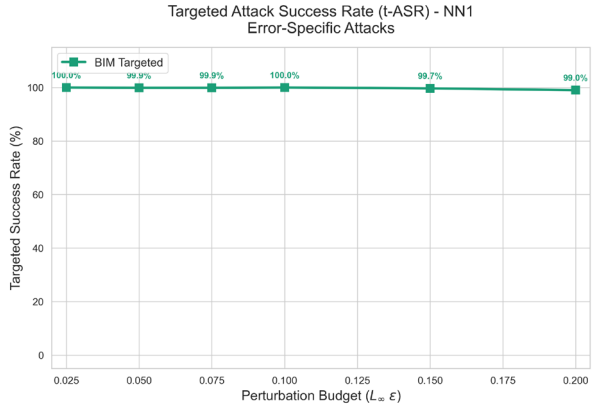


Figura 76 - Targeted Attack Success Rate - BIM RANDOM

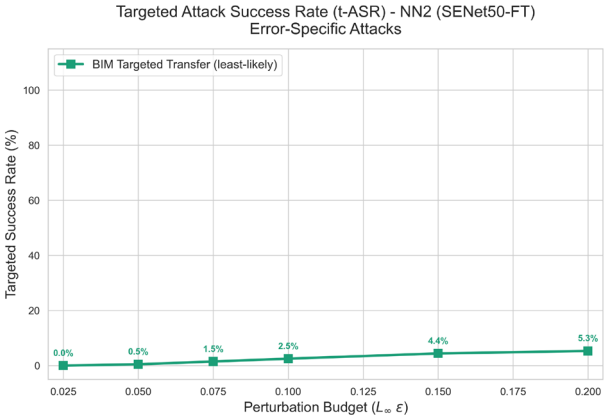


Figura 77 - Targeted Attack Success Rate - BIM LEAST-LIKELY

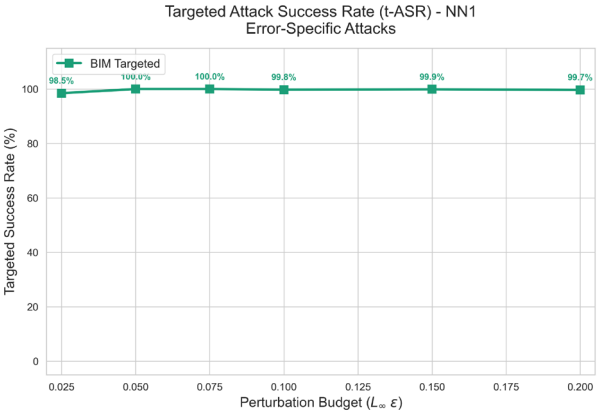


Figura 78 - Targeted Attack Success Rate - BIM LEAST-LIKELY

L'unico scenario in cui il BIM conserva una parziale efficacia in ambito *Black-Box* è l'euristica *Next-best* (il bersaglio più adiacente alla classe originale).

Confrontando le curve, si evince che il tasso di successo su NN2 non è istantaneo come su NN1 (dove partiva dal 100% a $\epsilon = 0.025$). Al budget minimo, il *Transfer t-ASR* si attesta al 31.2%. Tuttavia, all'aumentare dell'energia perturbativa, l'attacco riesce ad oltrepassare parzialmente le difese di SENet50, raggiungendo un picco del **75.5%** a $\epsilon = 0.1$.

4.3.3. TRASFERIBILITÀ PGD (TARGETED)

L'algoritmo Projected Gradient Descent (PGD), pur rappresentando l'apice dell'efficacia in scenario *White-Box* grazie all'integrazione dei *random restarts* e della proiezione sferica iterativa, subisce un collasso prestazionale pressoché totale quando impiegato per il trasferimento di attacchi mirati come si può evincere dai grafici sottostanti di confronto tra le varie euristiche.

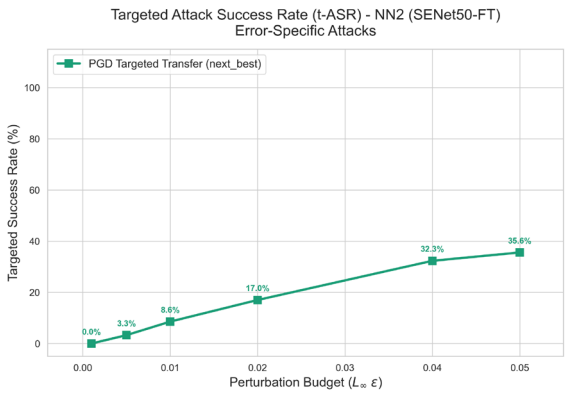


Figura 79 - Targeted Attack Success Rate - PGD NEXT-BEST

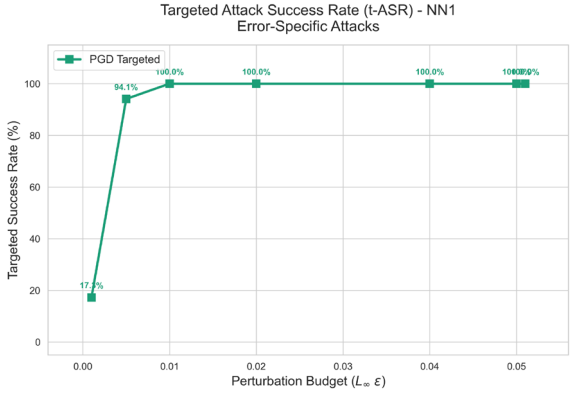


Figura 80 - Targeted Attack Success Rate - PGD NEXT-BEST

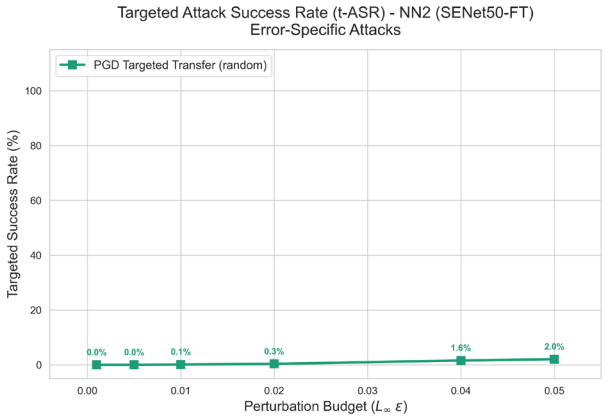


Figura 81 - Targeted Attack Success Rate - PGD RANDOM

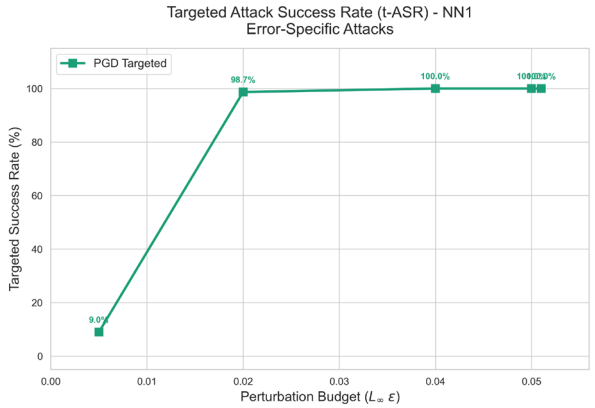


Figura 82 - Targeted Attack Success Rate - PGD RANDOM

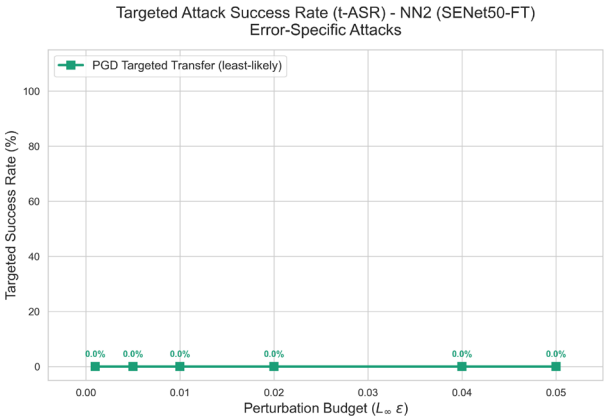


Figura 83 - Targeted Attack Success Rate - PGD LEAST-LIKELY

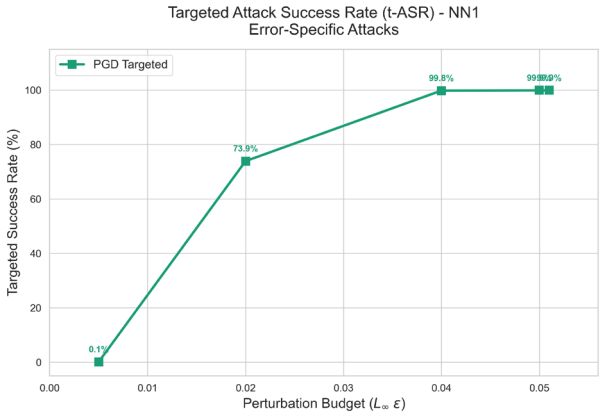


Figura 84 - Targeted Attack Success Rate - PGD LEAST-LIKELY

I grafici del PGD Targeted certificano un principio cardine della *Transferability*: distruggere una classe (Untargeted) richiede pattern generici, ma costruirne una specifica (Targeted) richiede pattern strettamente correlati all'architettura.

L'algoritmo PGD calcola un vettore perturbativo che "disegna" le feature specifiche della classe bersaglio esattamente come se le aspetta InceptionResnetV1. Nel momento in cui l'immagine subisce il *Domain Shift* verso SENet50, l'allineamento spaziale dei pixel viene sfalsato dall'interpolazione bilineare. Di conseguenza, il vettore avversario si frammenta.

4.3.4. TRASFERIBILITÀ C&W (TARGETED)

L'algoritmo Carlini & Wagner (C&W) rappresenta il vertice dell'efficacia offensiva in scenario *White-Box*. Sfruttando una funzione di costo *margin-based* e una ricerca binaria avanzata, l'ottimizzatore modella la perturbazione con molta precisione, estraendo la distorsione minima assoluta necessaria per varcare il confine decisionale della classe bersaglio su InceptionResnetV1. Tuttavia, l'analisi del trasferimento mirato su SENet50 dimostra come questa estrema iper-ottimizzazione si traduca nella massima vulnerabilità possibile in ottica *Black-Box*.

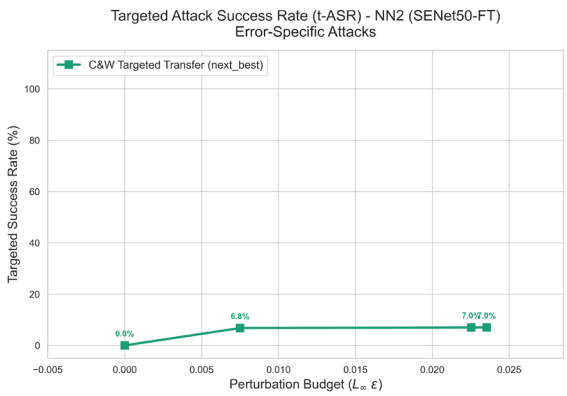


Figura 85 - Targeted Attack Success Rate – C&W NEXT-BEST

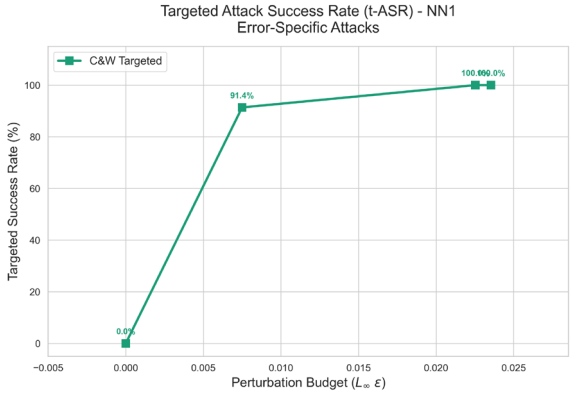


Figura 86 - Targeted Attack Success Rate – C&W NEXT-BEST

Il grafico sorgente (*Figura 86*) conferma l'assoluta precisione dell'algoritmo. Con un budget microscopico pari a $\epsilon \approx 0.007$, il *Targeted ASR* raggiunge già il **91.4%**, per poi saturare infallibilmente al **100.0%** a $\epsilon \approx 0.023$. L'oracolo viene piegato con un'alterazione visivamente nulla (poco più del 2% del range dei pixel).
Sottoponendo le medesime immagini alla rete SENet50 (Figura 85), l'efficacia mirata dell'attacco viene letteralmente annientata. A $\epsilon \approx 0.007$, il *Transfer t-ASR* si attesta a un misero **6.8%**. Anche concedendo il budget massimo calcolato per la convergenza su NN1 ($\epsilon \approx 0.023$), la curva si arena al **7.0%**.
Il fallimento sistematico del C&W Targeted in scenario *Black-Box* è la dimostrazione matematica definitiva del paradigma dell'**Overfitting della Perturbazione**.

5. MECCANISMO DI DIFESA

Al fine di preservare i pesi originari del modello bersaglio (InceptionResnetV1) e mantenere inalterata la *Clean Accuracy* sui dati legittimi, in questo progetto si è evitato il computazionalmente oneroso *Adversarial Training*. La strategia difensiva si è invece concentrata sull'implementazione di moduli logici esterni e indipendenti, testati e valutati secondo tre paradigmi complementari:

1. **Pre-processing Pipeline**: Degradazione meccanica del rumore stocastico tramite filtri spaziali classici.
2. **Denoiser**: Ricostruzione attiva dell'immagine pulita tramite reti neurali.
3. **Anomaly Detection**: Rilevamento delle anomalie basato sull'errore di ricostruzione e blocco preventivo dell'input compromesso.

5.1. PREPROCESSING PIPELINE

L'obiettivo della pipeline di preprocessing è alterare il tensore di input in modo sufficiente da distruggere la perturbazione ϵ, ma non abbastanza da corrompere le feature semantiche del volto necessarie per la classificazione corretta.

5.1.1. SCOUTING INDIVIDUALE DEI FILTRI

Nella prima fase, avvalendosi della libreria *Adversarial Robustness Toolbox (ART)*, è stato condotto uno *scouting* isolato sui singoli meccanismi di pre-processing:

- **JPEG Compression (Lossy):** Introduce artefatti ad alta frequenza che distruggono i micro-gradienti calcolati dagli attacchi. È stata valutata la *Quality* in un range da 10 a 90.
- **Spatial Smoothing:** Applica un filtro passa-basso (sfocatura spaziale) con kernel di dimensioni variabili (3x3, 5x5, 7x7) per diluire le perturbazioni concentrate.
- **Feature Squeezing:** Riduce la profondità di bit dell'immagine (quantizzazione dei colori da 8-bit a 3, 4 o 5-bit), appiattendo le differenze millimetriche introdotte dall'ottimizzatore.

Per ogni filtro, è stata valutata la *Clean Retention* (impatto sulle immagini non attaccate) e la *Recovery Rate* (capacità di riportare alla classe originaria) su campioni estratti dall'attacco C&W (sia *Targeted* che *Untargeted*). Lo scouting ha evidenziato un rigoroso *trade-off*: difese troppo aggressive (es. Squeezing a 3-bit o JPEG a qualità 10) neutralizzavano l'attacco, ma distruggevano anche le prestazioni della baseline pulita.

5.1.2. GRID SEARCH 3D E SELEZIONE DELLA PIPELINE

Poiché un singolo filtro non garantiva un compromesso accettabile, è stata sviluppata una **Triple-Cascading Defense**. L'input viene fatto transitare sequenzialmente attraverso tre stadi: **Spatial Smoothing → Feature Squeezing → JPEG Compression**.

Per individuare la configurazione ottimale, è stata implementata una *Grid Search 3D* automatizzata che ha esplorato 27 combinazioni di iperparametri.

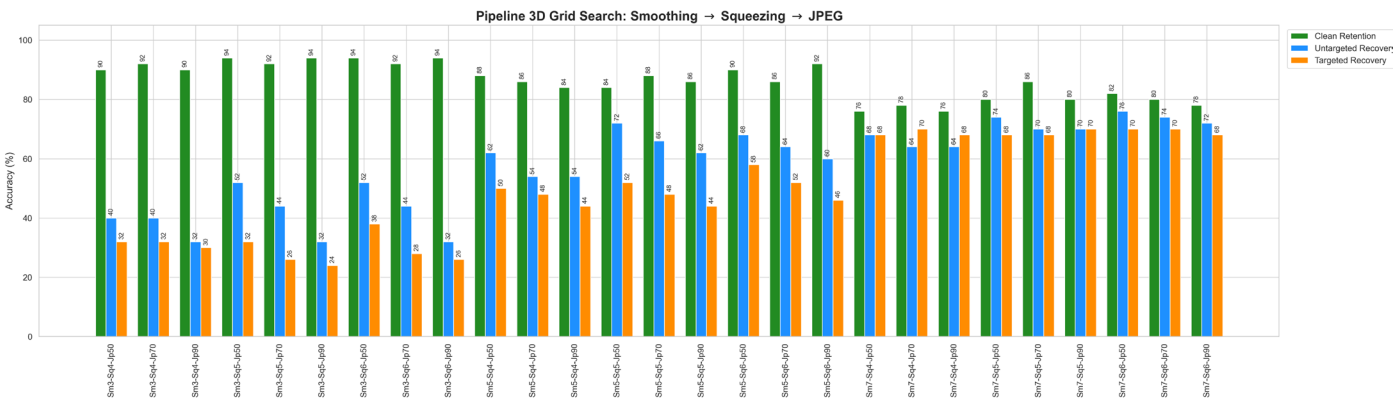


Figura 87 – Pipeline Grid Search on Smoothing, Compression and Squeezing

L'algoritmo di selezione è stato vincolato da due regole stringenti:

1. **Filtro di Usabilità:** Scartare qualsiasi configurazione che faccia scendere la *Clean Accuracy* al di sotto del **90%**. Tuttavia, abbiamo scelto la configurazione che fornisce una maggiore resilienza.
2. **Massimizzazione della Resilienza:** Tra le configurazioni valide, selezionare quella che massimizza la somma matematica della *Untargeted Recovery* e della *Targeted Recovery*.

A valle della Grid Search, per la validazione finale, la pipeline è stata snellita escludendo il Feature Squeezing poiché troppo distruttivo o ridondante, attestandosi sulla configurazione vincente (**Smoothing 7x7 + JPEG Quality 70**). Per validare qualitativamente la difesa, è stato generato un *Ultimate Visual Showcase* estraendo casi studio specifici (successi e fallimenti della difesa), permettendo di ispezionare visivamente la mappa del rumore residuo a valle di ciascun filtro della pipeline.

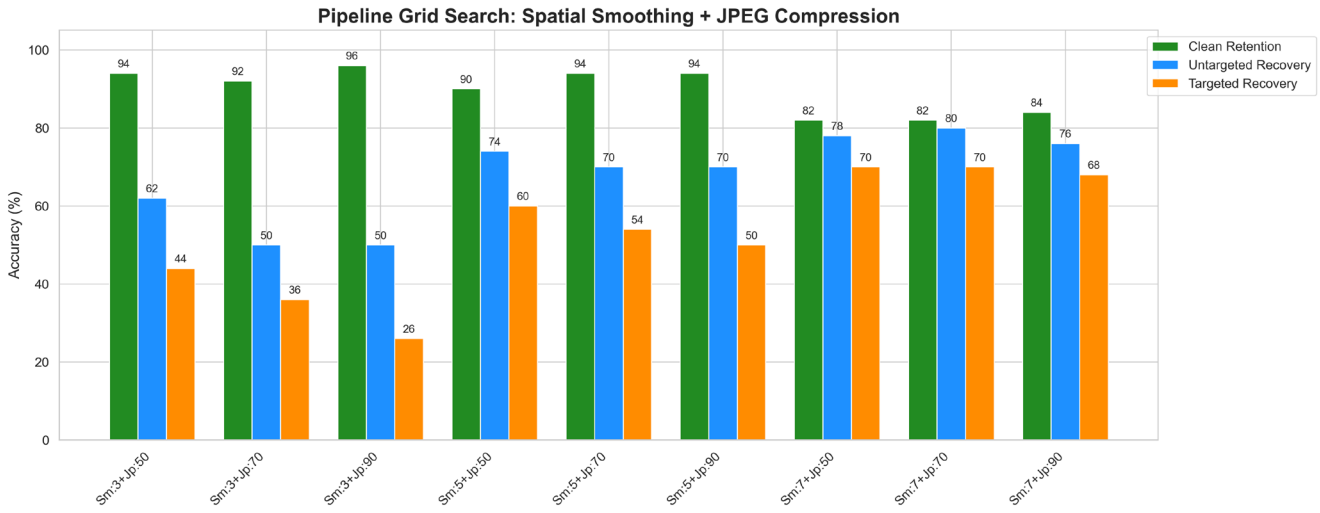


Figura 88 – Pipeline Grid Search on Smoothing and Compression

5.1.3. VALUTAZIONE DELLA ROBUSTEZZA POST-DIFESA

Il modulo di purificazione definitivo è stato applicato all'intero database di attacchi generati. Grazie al Google Sheets, le metriche post-difesa sono state aggregate e confrontate sistematicamente con le prestazioni originali ottenendo una **Defended Security Evaluation Curves.** L'introduzione della pipeline altera drasticamente la morfologia delle curve di sicurezza per gli attacchi untargeted. Mentre le curve originali (*Undefended*) collassavano rapidamente a 0% per micro-budget, le curve *Defended* mostrano un leggero sollevamento (*gap* prestazionale verde/rosso) per alcuni attacchi, dimostrando come la rete riesca a conservare una parte dei tassi di *Robust Accuracy* anche ad alti regimi di perturbazione (es. $\epsilon \geq 0.050$).

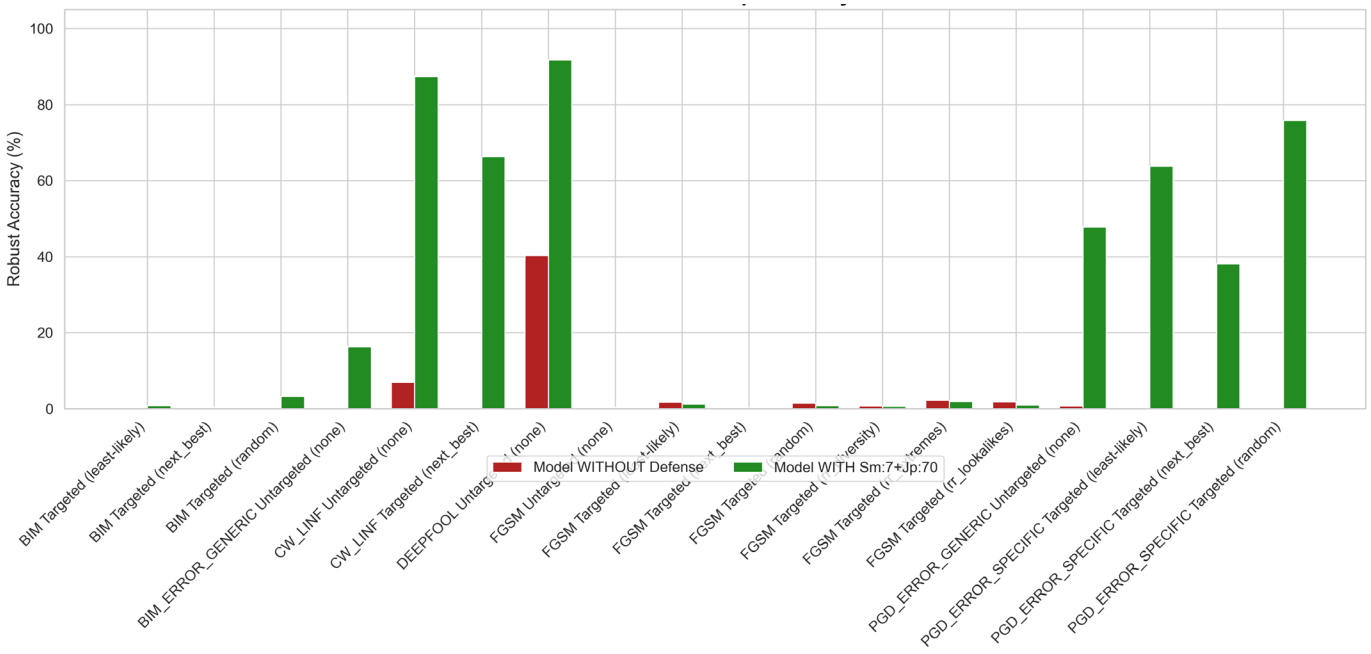


Figura 89 – Global Defense Impact Analysis

Nella seguente tabella mostriamo i risultati ottenuti per ogni attacco della Defended Security Evaluation Curve (DSEC).

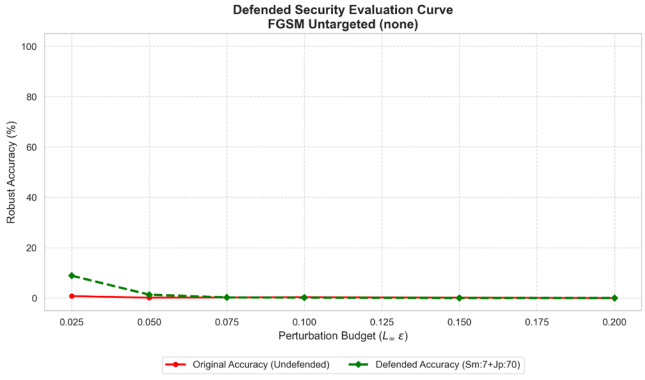


Figura 90 – FGSM Untargeted

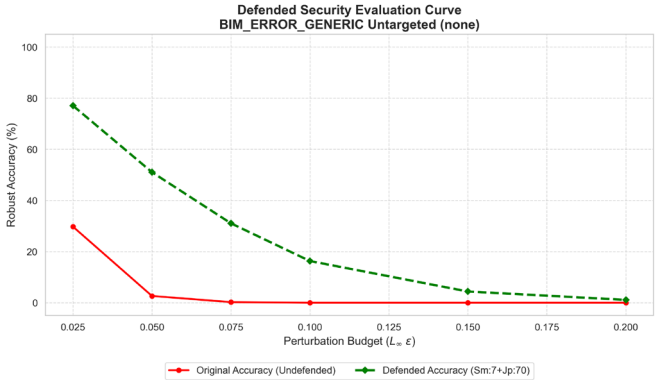


Figura 91 - BIM Untargeted

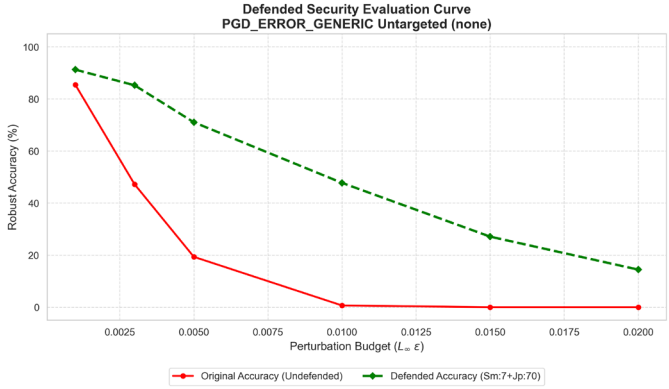


Figura 92 – PGD Untargeted

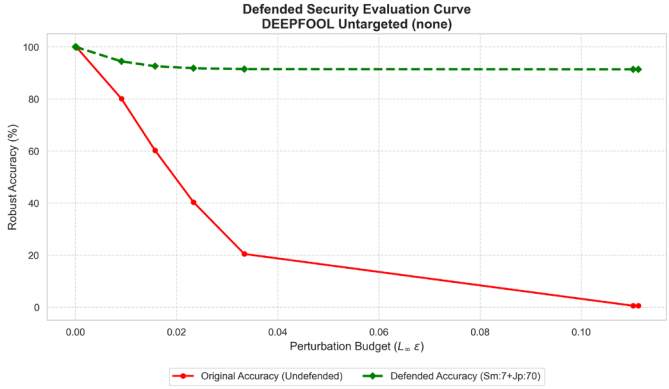


Figura 93 - DeepFool Untargeted

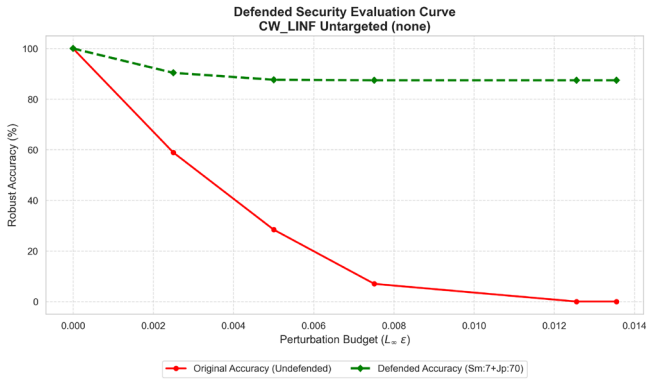


Figura 94 – C&W Untargeted

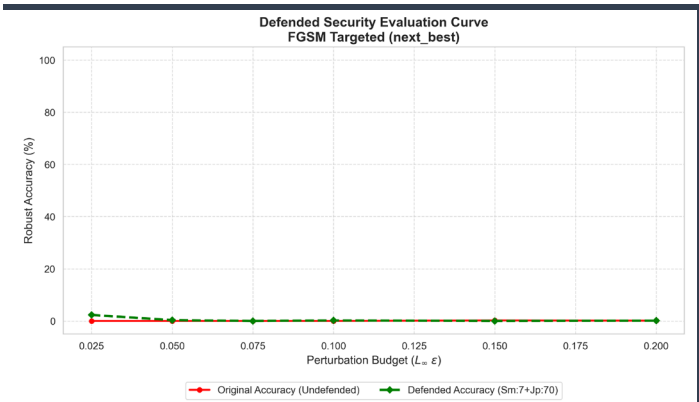


Figura 95 – FGSM NEXT-BEST

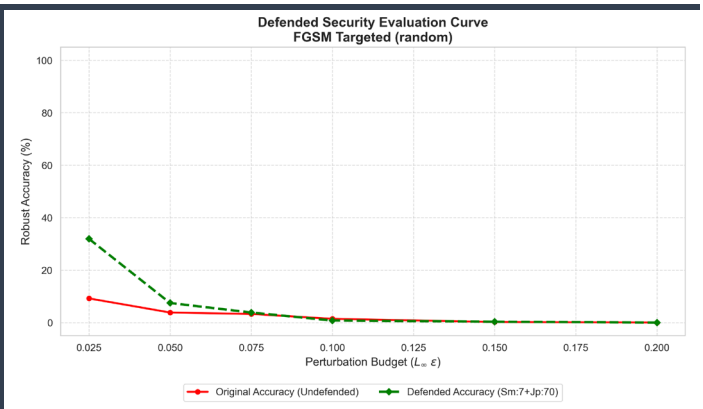


Figura 96 - FGSM RANDOM

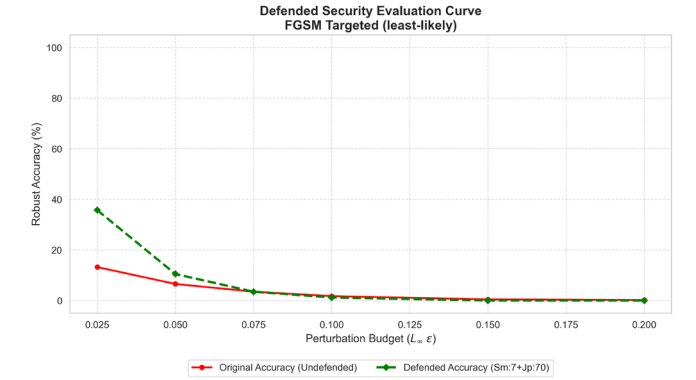


Figura 97 – FGSM LEAST-LIKELY

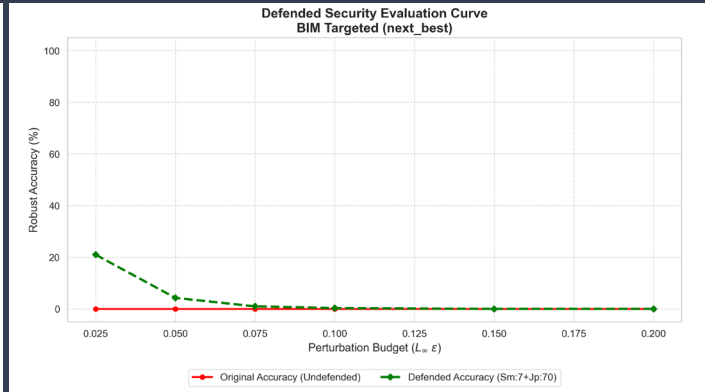


Figura 98 - BIM NEXT-BEST

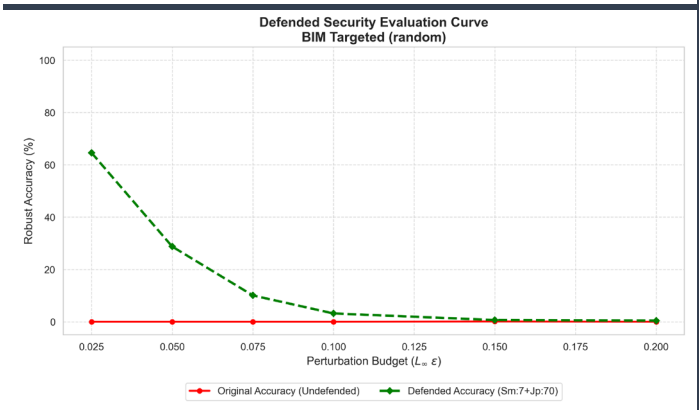


Figura 99 – BIM RANDOM

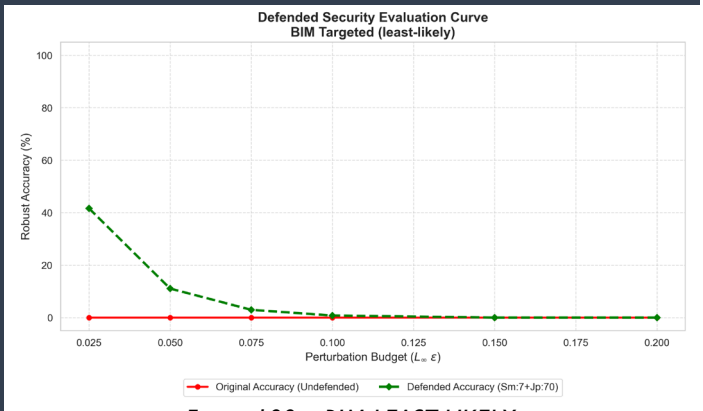


Figura 100 – BIM LEAST-LIKELY

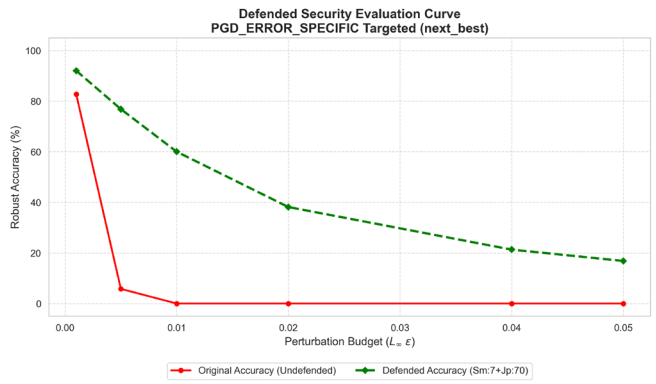


Figura 101 – PGD NEXT-BEST

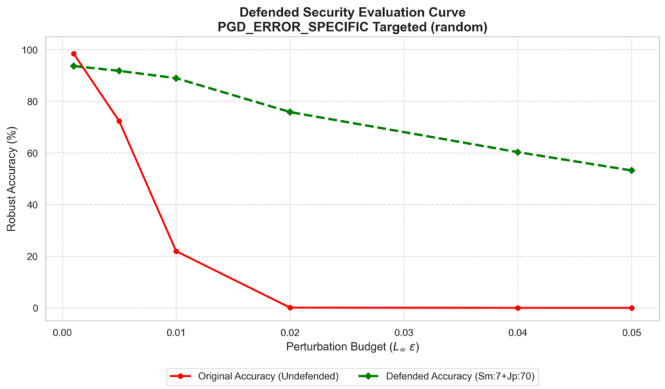


Figura 102 – PGD RANDOM

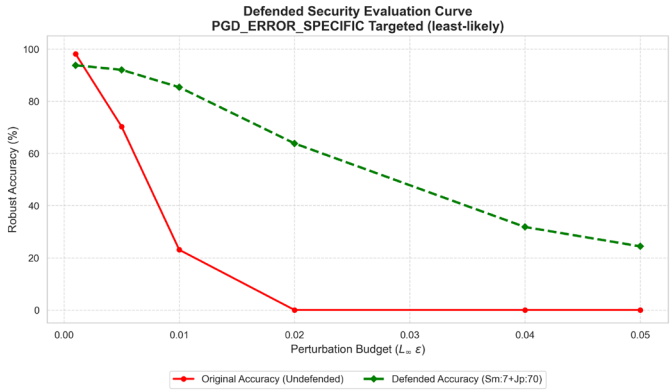


Figura 103 – PGD LEAST-LIKELY

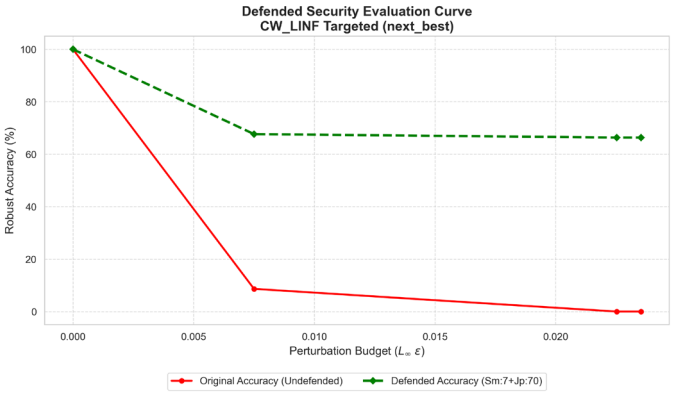


Figura 104 – C&W NEXT-BEST

5.2. DENOSING AUTOENCODER (DAE)

Al fine di superare i limiti rigidi dei filtri spaziali e geometrici descritti (Sezione 5.1), si è deciso di implementare un secondo livello di difesa basato sul *Deep Learning*. Per questo scopo è stato progettato e addestrato *ex novo* un **Denoising Autoencoder (DAE)** convoluzionale.

5.2.1. ARCHITETTURA E ADDESTRAMENTO (FLOAT TIFF)

L'Autoencoder è composto da un *Encoder* a 3 layer convoluzionali (che comprime lo spazio latente) e un *Decoder* a 3 layer simmetrici (che ricostruisce l'input).
Una particolarità fondamentale risiede nel dataset di addestramento: il modello è stato addestrato esclusivamente sui campioni originali in formato **TIFF a 32-bit Floating-Point** estratti dalla *Clean Baseline*. Questo accorgimento garantisce che la rete impari a mappare la distribuzione di densità fisiologica dei volti naturali con precisione sub-pixel.
L'addestramento è stato condotto per 100 epoche minimizzando la *Mean Squared Error (MSE) Loss*, forzando l'Autoencoder a ignorare le alte frequenze per ricostruire solo i pattern strutturali dominanti.

5.2.2. DENOISING PURIFICATION

In questa modalità operativa, l'Autoencoder sostituisce interamente i filtri di *Smoothing* e *JPEG*. L'immagine (potenzialmente avversaria) viene fatta transitare attraverso l'Autoencoder. Il collo di bottiglia (*bottleneck*) della rete agisce da purificatore naturale: non avendo mai visto distribuzioni di rumore avversario in fase di addestramento, il DAE scarta la perturbazione stocastica e ricostruisce solo il volto pulito. Questa immagine ricostruita viene poi fornita al classificatore InceptionResnetV1. Rispetto alla pipeline classica, l'Autoencoder è risultato capace di preservare in modo accettabile la semantica dell'identità originaria (*Clean Retention*).

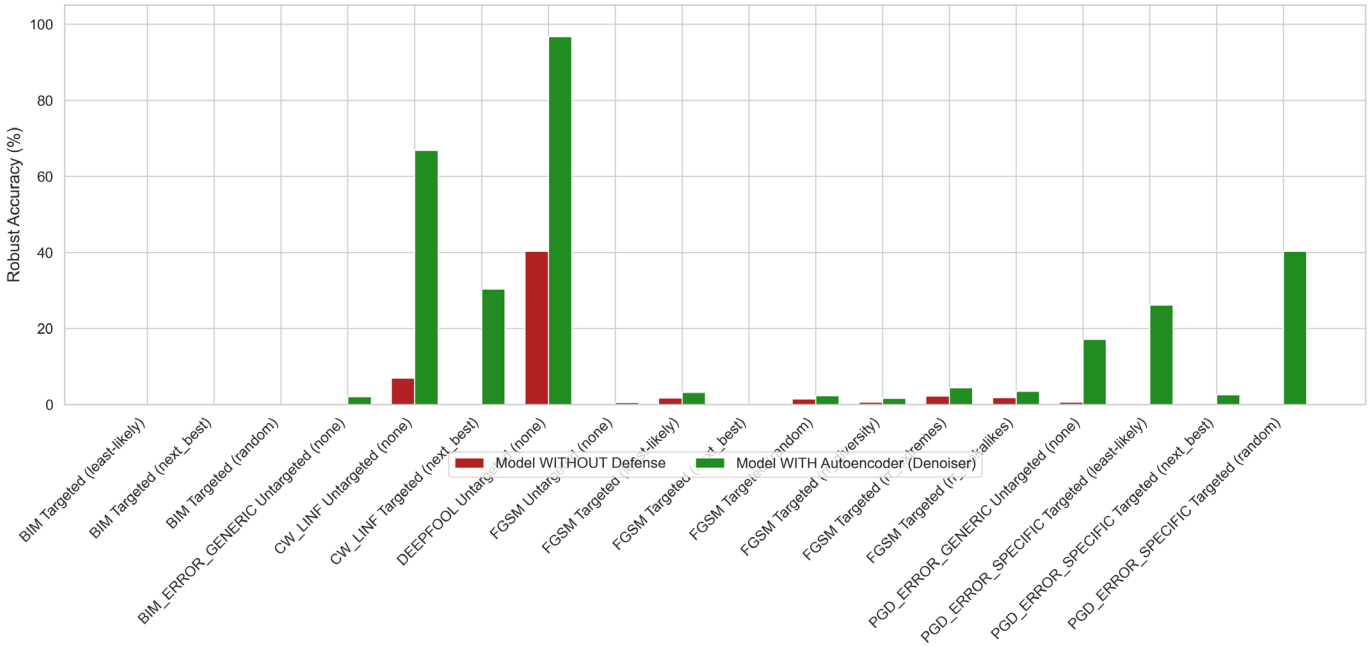


Figura 105 - Global Defence Impact Analysis (Denoising Autoencoder)

Nella seguente tabella mostriamo i risultati ottenuti per ogni attacco della Defended Security Evaluation Curve (DSEC).

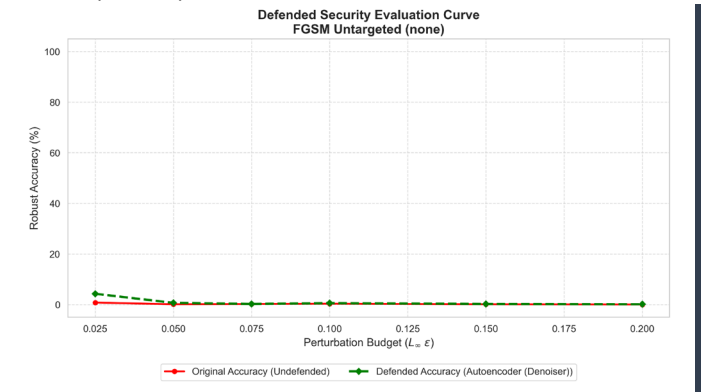


Figura 106 – FGSM Untargeted

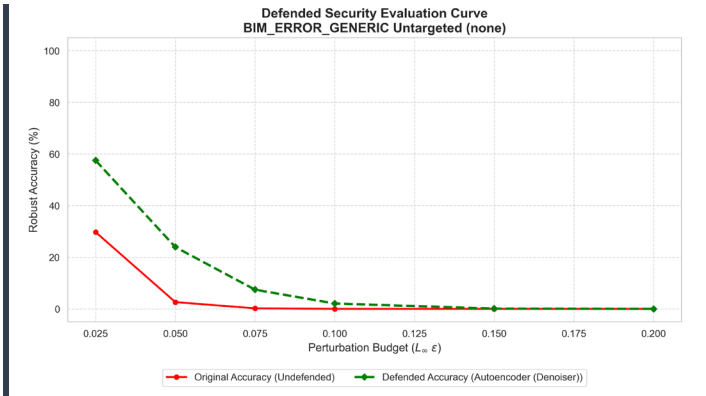


Figura 107 - BIM Untargeted

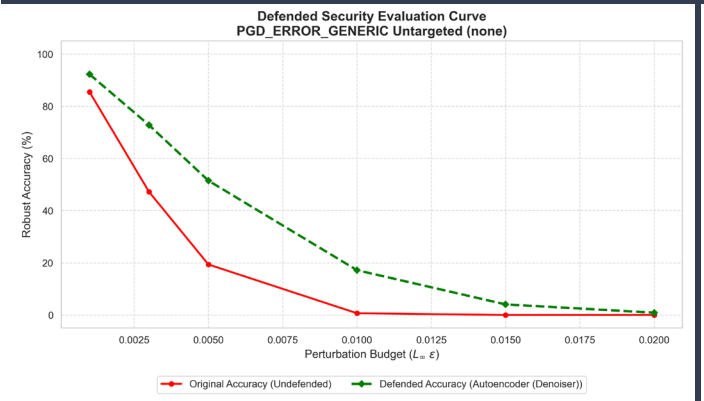


Figura 108 – PGD Untargeted

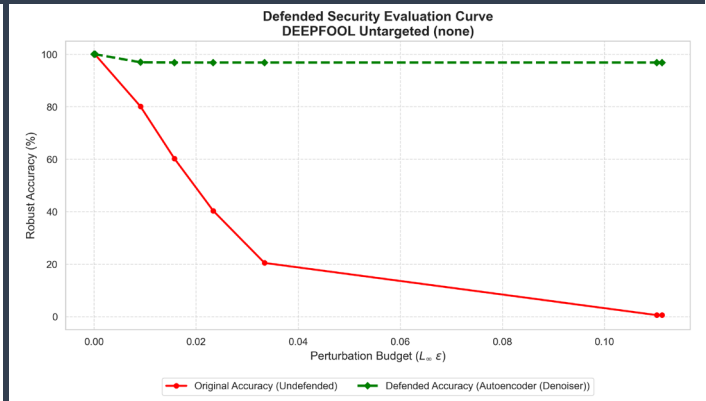


Figura 109 - DeepFool Untargeted

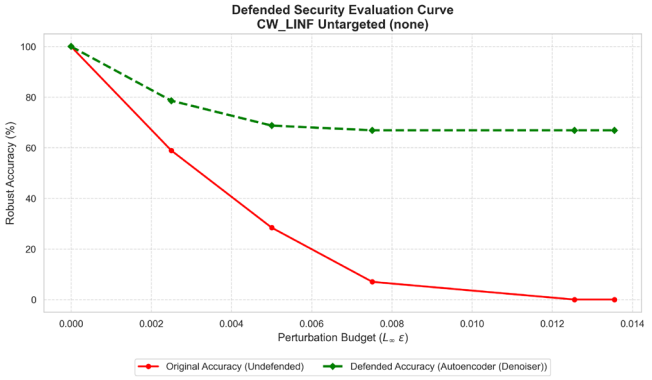


Figura 110 – C&W Untargeted

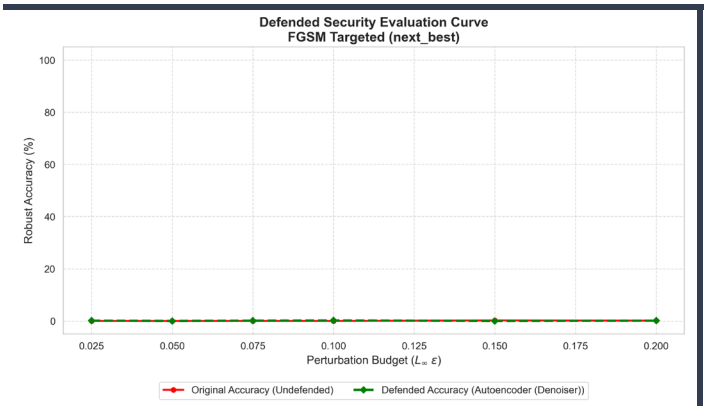


Figura 111 – FGSM NEXT-BEST

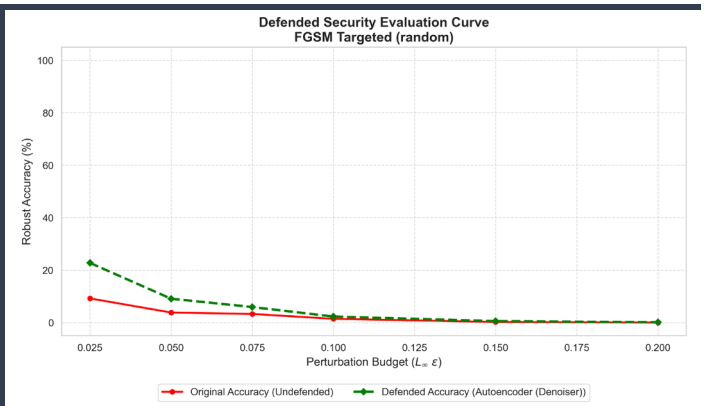


Figura 112 - FGSM RANDOM

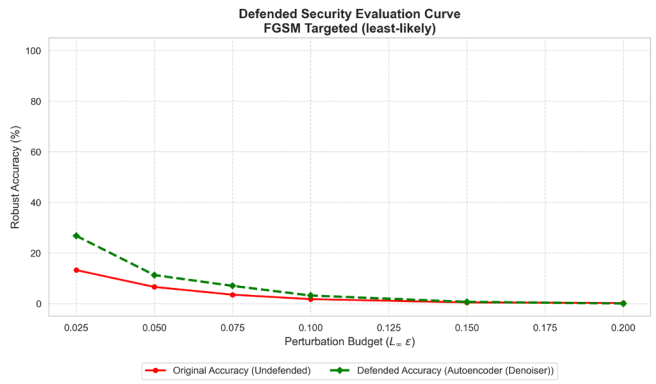


Figura 113 – FGSM LEAST-LIKELY

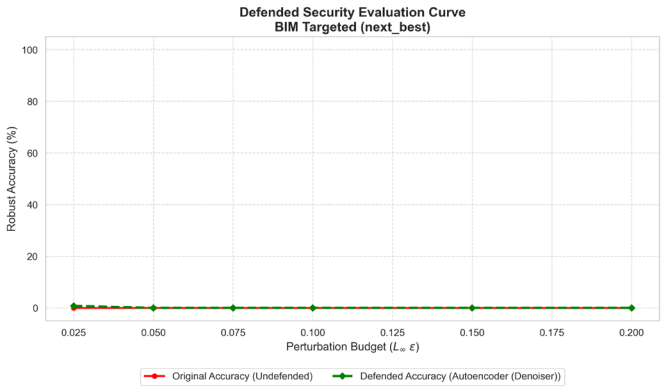


Figura 114 - BIM NEXT-BEST

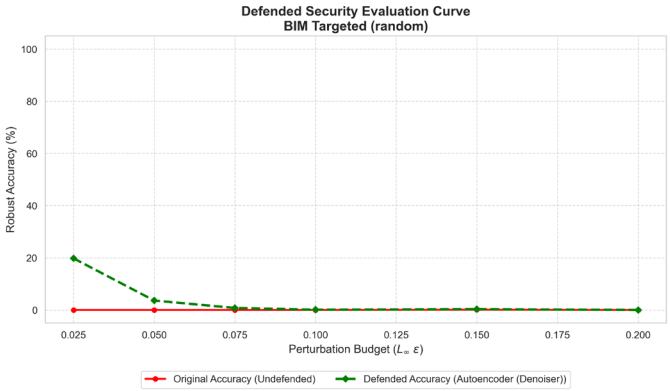


Figura 115 – BIM RANDOM

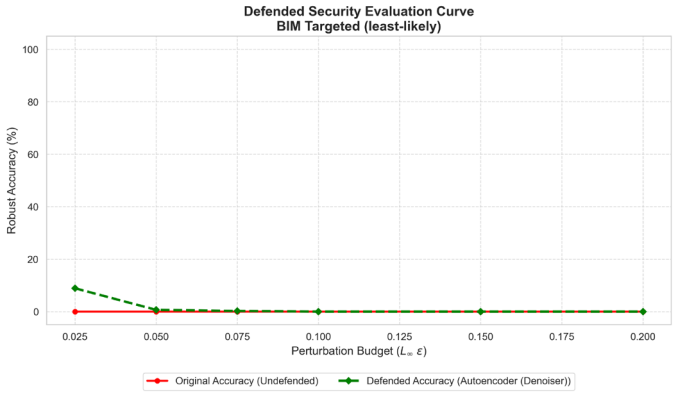


Figura 116 – BIM LEAST-LIKELY

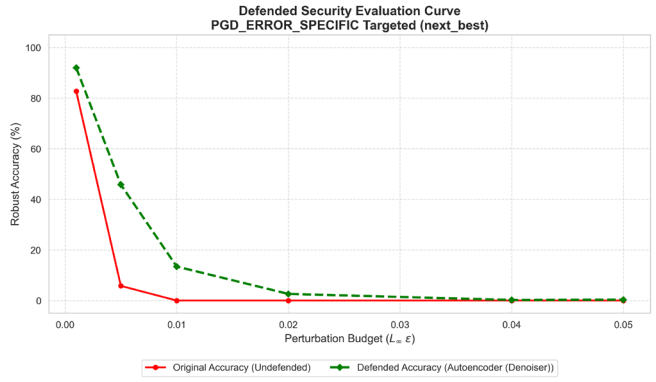


Figura 117 – PGD NEXT-BEST

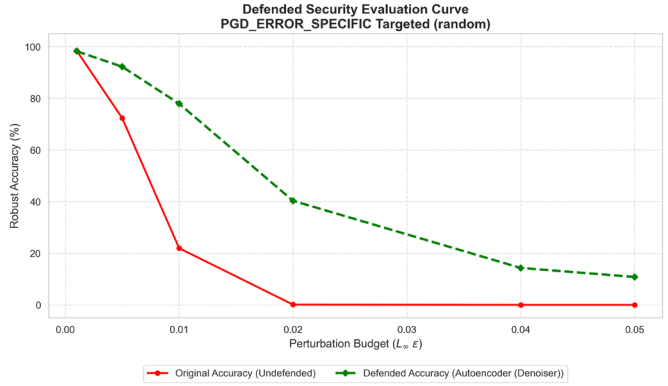


Figura 118 – PGD RANDOM

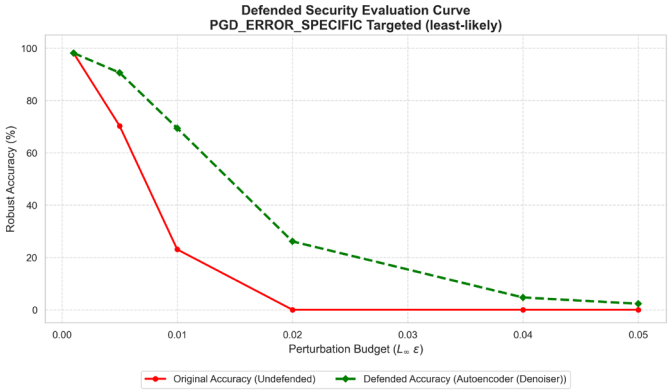


Figura 119 – PGD LEAST-LIKELY

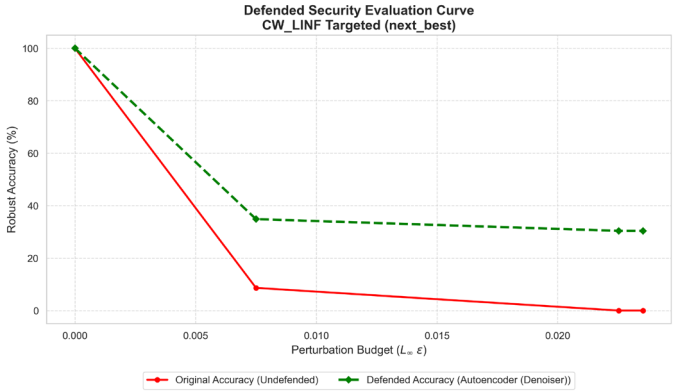


Figura 120 – C&W NEXT-BEST

5.3. ANOMALY DETECTION

Sebbene la ricostruzione tramite Autoencoder rappresenti un'ottima difesa passiva, algoritmi che hanno perturbazioni forti basate sul gradiente, riescono ad ingannare il DAE. Per neutralizzare definitivamente queste minacce, l'architettura dell'Autoencoder è stata riadattata per funzionare come un **Anomaly Detector**.

5.3.1. RILEVAMENTO BASATO SULL'ERRORE DI RICOSTRUZIONE (MSE)

Il meccanismo di detection non inoltra l'immagine alla rete di classificazione, ma sfrutta il divario di ricostruzione latente. Sottoponendo un'immagine legittima all'Autoencoder, l'errore di ricostruzione (calcolato come MSE tra l'input e l'output) risulta minimo. Al contrario, se l'immagine è corrotta da un rumore avversario, la discrepanza matematica genera un MSE marcatamente più elevato.

5.3.2. DEFINIZIONE DELLA SOGLIA E ROC TRADE-OFF

Calcolando l'MSE sull'intero Test Set, è stato possibile tracciare le densità di distribuzione. Come atteso, la curva dell'MSE per le immagini pulite e quella per gli attacchi (preso come esempio PGD) formano due distribuzioni nettamente distinte.

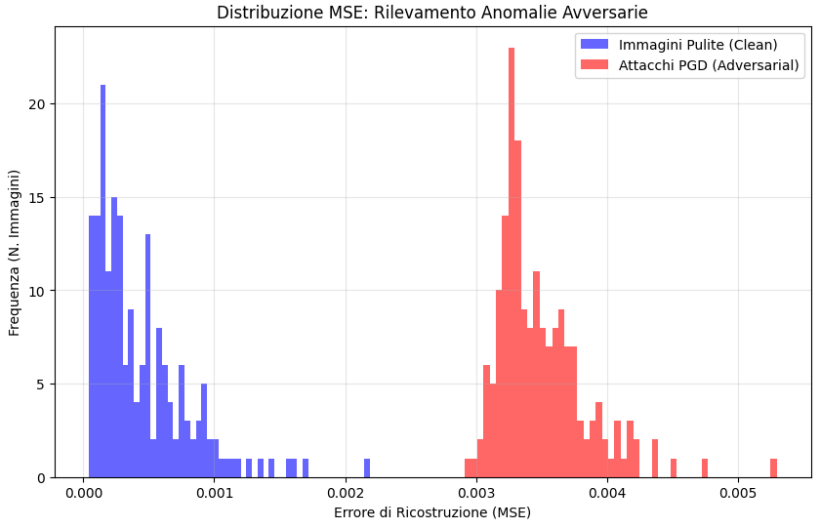


Figura 121 - Distribuzione dell'Errore di Ricostruzione (MSE) calcolato dal DAE

Per automatizzare il blocco, è stata calcolata una soglia (*Threshold*) dinamica, basata sul percentile delle immagini pulite, concedendo un tasso di falsi positivi tollerato (FPR = 5%). Il sistema opera quindi su tre possibili esiti tracciati in un'analisi di sistema globale:

1. **Detected & Blocked by AE (True Positives):** L'MSE supera la soglia. La richiesta viene rigettata ancor prima di interrogare il modello di *Face Recognition*.
2. **False Alarms (False Positives):** Immagini pulite con varianze naturali elevate, bloccate erroneamente a causa di un MSE superiore alla soglia.
3. **Bypassed:** L'immagine sfugge all'Anomaly Detector, passando al modello target, il quale a sua volta può resistere (*Resisted by FaceNet*) o soccombere all'attacco (*Fatal Success*).

Nella seguente tabella mostriamo i risultati ottenuti per ogni attacco della Defended Security Evaluation Curve (DSEC).

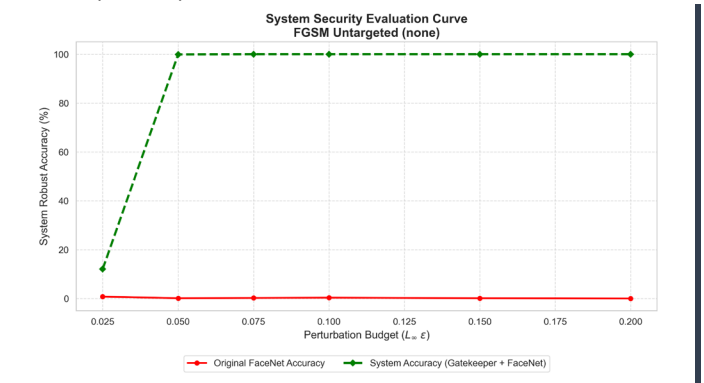


Figura 122 – FGSM Untargeted

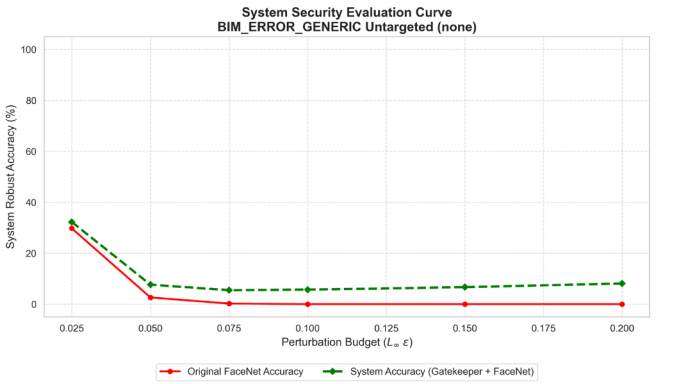


Figura 123 - BIM Untargeted

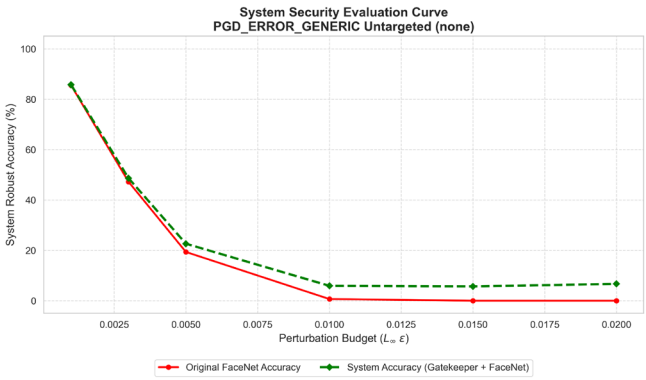


Figura 124 – PGD Untargeted

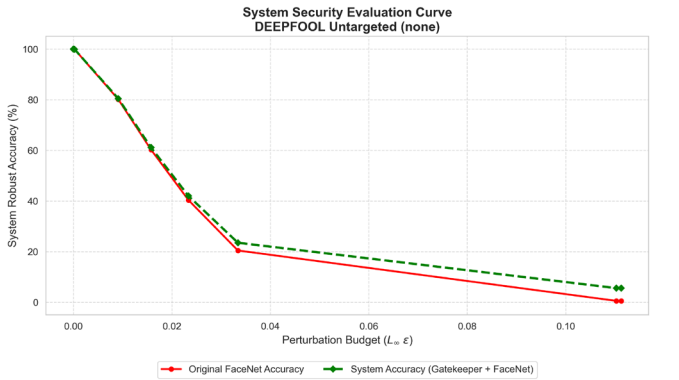


Figura 125 - DeepFool Untargeted

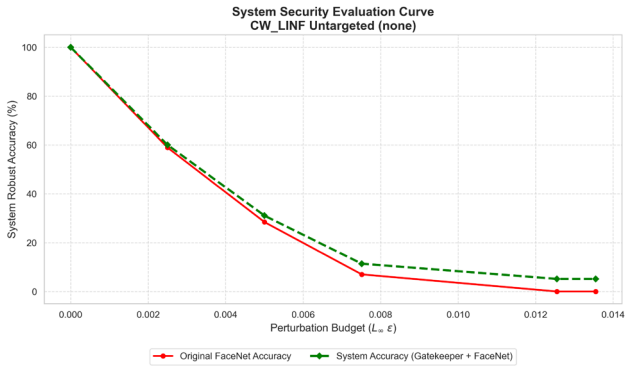


Figura 126 – C&W Untargeted

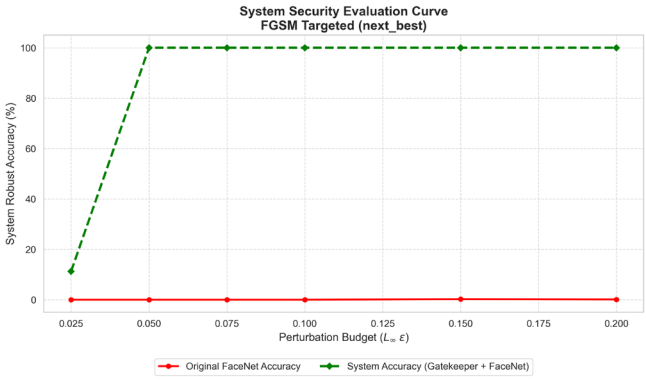


Figura 127 – FGSM NEXT-BEST

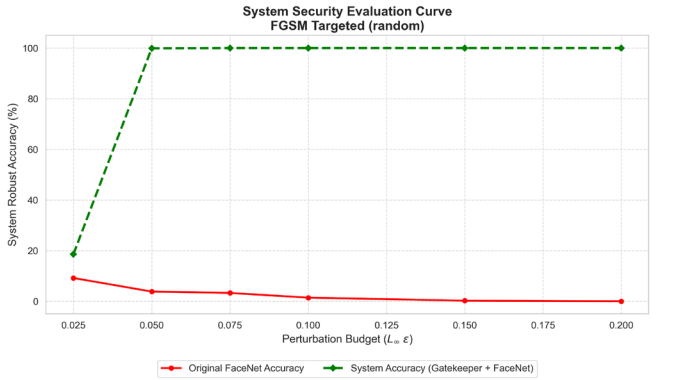


Figura 128 - FGSM RANDOM

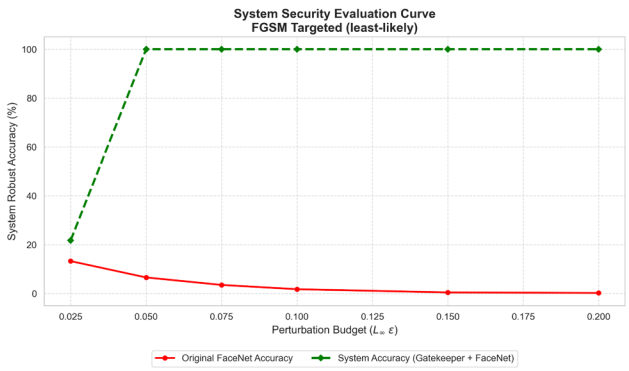


Figura 129 – FGSM LEAST-LIKELY

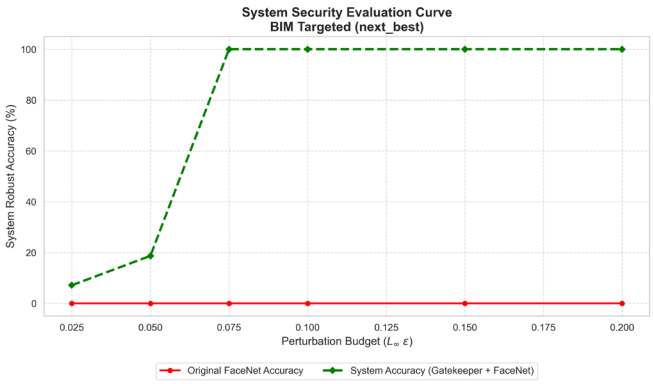


Figura 130 - BIM NEXT-BEST

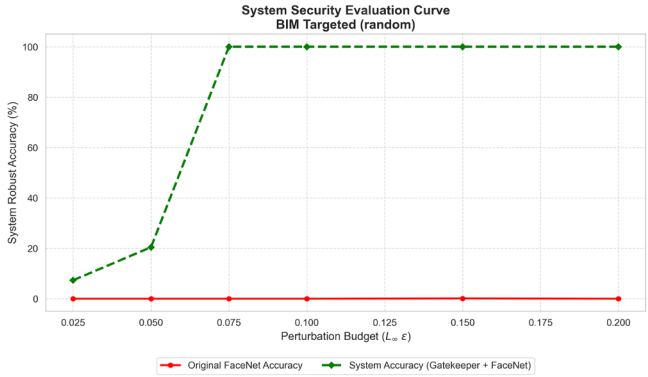


Figura 131 – BIM RANDOM

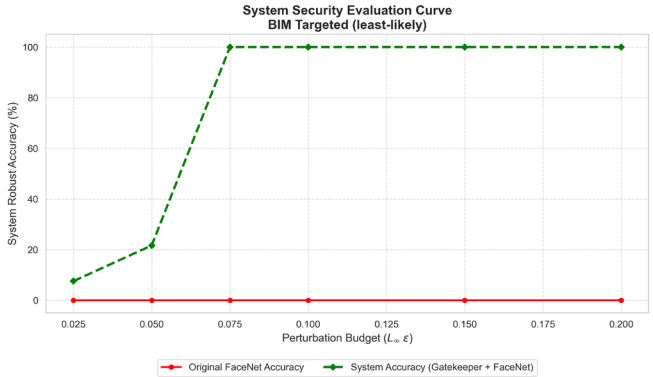


Figura 132 – BIM LEAST-LIKELY

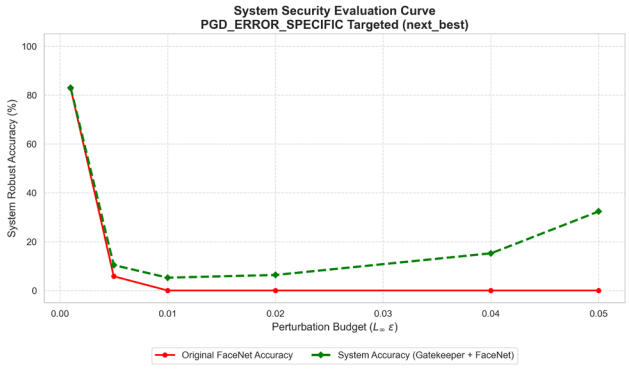


Figura 133 – PGD NEXT-BEST

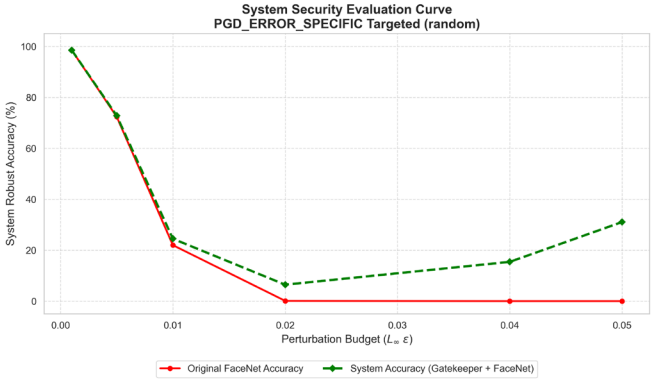


Figura 134 – PGD RANDOM

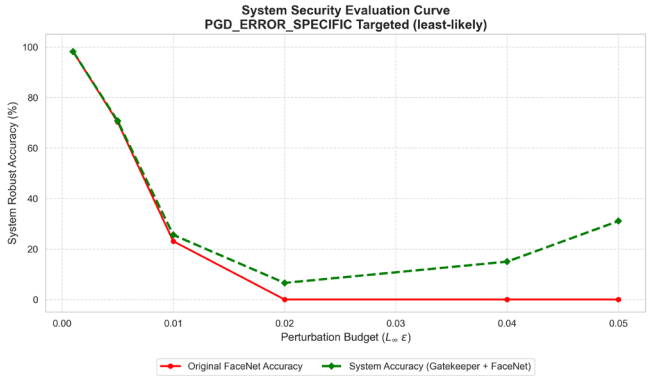


Figura 135 – PGD LEAST-LIKELY

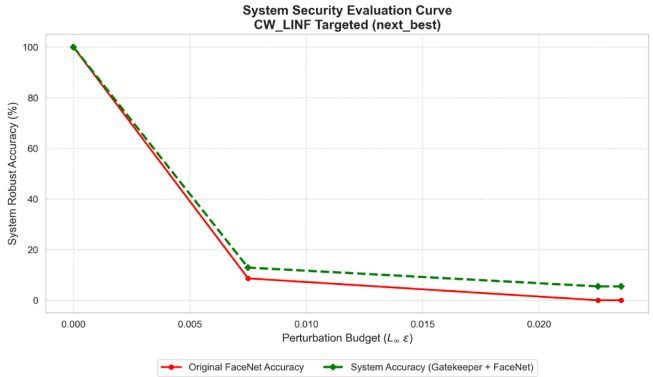


Figura 136 – C&W NEXT-BEST

Per mostrare l'efficacia del Anomaly Detector, sono sotto riportati alcuni grafici che spiegano come cambiano le performance della soluzione con l'opzione di rigetto del campione anomalo.

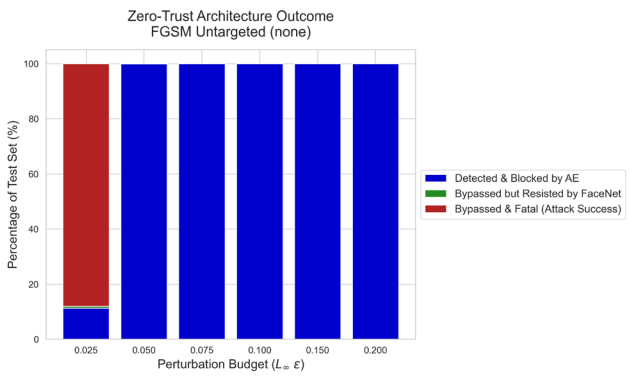


Figura 137 – FGSM Untargeted

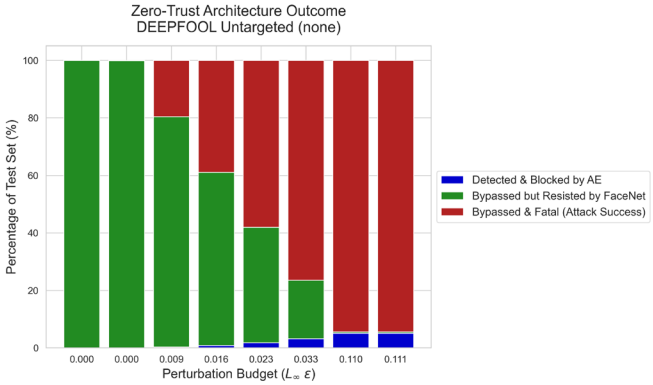


Figura 138 – DeepFool Untargeted

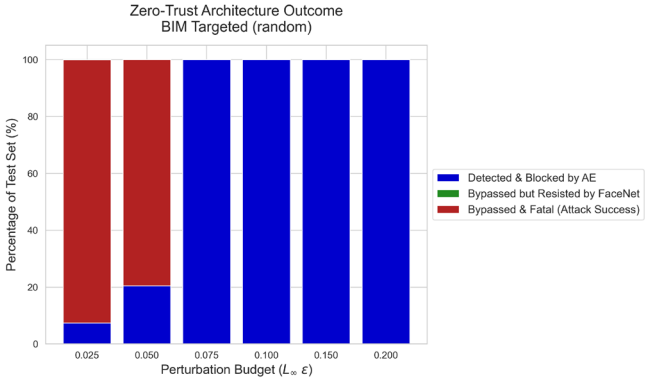


Figura 139 – BIM LEAST-LIKELY

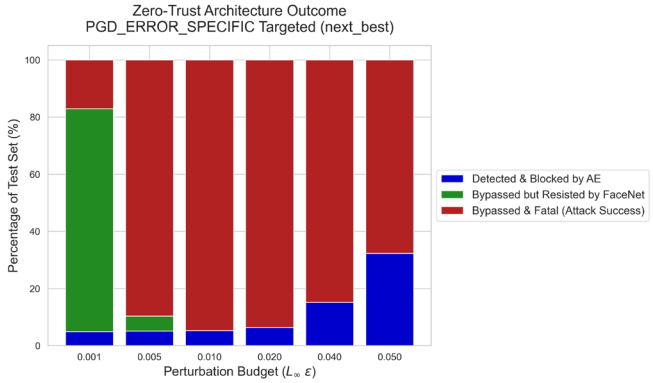


Figura 140 – PGD NEXT-BEST

6. CONCLUSIONI

6.1. SINTESI DELL'EFFICACIA DEGLI ATTACCHI E DELLA TRASFERIBILITÀ

L'indagine in scenario **White-Box** (modello NN1, InceptionResnetV1) ha confermato la catastrofica fragilità delle reti convoluzionali profonde dinanzi a manipolazioni del dominio di input. Anche ponendo vincoli di impercettibilità visiva estremamente restrittivi (bassi valori del budget L_∞), l'accuratezza del modello decade rapidamente.

Mentre attacchi *single-step* come l'FGSM si sono rivelati insufficienti a forzare i complessi confini decisionali in scenari *Targeted*, algoritmi iterativi avanzati (PGD) e metodi *margin-based* iper-ottimizzati (C&W) hanno dimostrato di poter alterare a piacimento l'identità predetta dalla rete. In particolare, le euristiche di ottimizzazione realizzate per l'attacco Carlini & Wagner hanno garantito il raggiungimento di un *Targeted Attack Success Rate* (t-ASR) pressoché totale, riuscendo a forzare lo scenario *Next Best*.

L'analisi di **Trasferibilità** in scenario **Black-Box** (modello NN2, SENet50) ha svelato dinamiche fondamentali dell'Adversarial Machine Learning:

1. **Degrado Strutturale:** La discrepanza dimensionale (Upscaling da 160x160 a 224x224) e la differente normalizzazione tensoriale (spazio BGR di Caffe) agiscono come un forte e naturale meccanismo di difesa, distruggendo gran parte dell'efficacia degli attacchi iper-ottimizzati (come C&W), che subiscono un marcato fenomeno di *overfitting* sul modello sorgente.
2. **Asimmetria tra scenari Untargeted e Targeted:** Se da un lato gli attacchi *Error-Generic* (Untargeted) conservano un moderato potere di trasferimento (poiché la corruzione delle *feature* fondamentali di un volto tende ad avere effetti globali su reti addestrate sullo stesso dataset), gli attacchi *Error-Specific* (Targeted) falliscono quasi sistematicamente nel loro scopo primario. Tuttavia, l'analisi disaggregata degli esiti ha dimostrato un fenomeno cruciale: pur fallendo l'impersonificazione mirata (*Targeted Success* $\approx 0\%$), l'identità originale viene comunque distrutta (*Untargeted Transfer Success* elevato), tramutando un attacco mirato fallito in un efficace attacco generico.

Tra i meccanismi di difesa implementati vi sono algoritmi di pre-processing, denoising autoencoder e anomaly detection. Ognuno presenta dei punti di forza e di debolezza:

- **Pre-processing:** L'utilizzo sequenziale di filtri classici (come lo *Spatial Smoothing* unito alla compressione *JPEG*) si è dimostrata una contromisura computazionalmente leggera e pronta all'uso (*plug-and-play*). Risulta particolarmente efficace nello sfocare e neutralizzare attacchi a perturbazione minima che aggiungono dettagli ad alta frequenza all'immagine originale (Deepfool, C&W). Tuttavia, soffre di un rigido *trade-off*: filtri troppo aggressivi degradano in modo inaccettabile la *Clean Accuracy* degli utenti legittimi. Inoltre, si è rivelata strutturalmente inefficace contro attacchi con grandi perturbazioni basate sul gradiente (FSGM, BIM, PDG), i cui pattern riescono facilmente ad aggirare questi filtri statici. Il motivo è che questi attacchi generano una quantità di rumore che il pre-processing non riesce ad "eliminare".
- **Denoising Autoencoder:** L'impiego dell'Autoencoder come purificatore attivo ha superato i limiti dei filtri classici nel preservare le *feature* semantiche del volto. Essendo stato addestrato esclusivamente su immagini pulite ad altissima fedeltà (TIFF a 32-bit), la rete impara a scartare il rumore attraverso il suo "collo di bottiglia" (*bottleneck*), ricostruendo un volto fisiologicamente naturale. Per comprendere il suo punto di debolezza dobbiamo rifarci alla teoria. In breve, il sistema approssima una distribuzione di probabilità, ottimizzata per ricostruire al meglio l'immagine. Alla fine dell'addestramento, il modello ha imparato a mappare ogni immagine pulita in un punto dello spazio latente, e da questo sa ricostruire l'immagine originale. Quindi un punto costruito dalle immagini originali, si trova sulla manifold. In fase di inferenza, quando corrompiamo l'immagine con un algoritmo di attacco, lo spostiamo fuori dalla manifold (il punto rosso). Il Denoising Autoencoder impara a

prendere questo punto corrotto e a "spingerlo" indietro verso la manifold. Ma questo approccio non funziona sempre. Infatti, da un punto corrotto, potrebbero esserci più punti sulla manifold che potrebbero averlo generato. L'autoencoder è deterministico: sceglierà di proiettarlo sul punto **più vicino** sulla manifold, che potrebbe non essere quello originale da cui eravamo partiti. Questo è un limite, ma anche una dimostrazione del fatto che ha imparato la *struttura* della manifold, non solo a invertire il rumore.

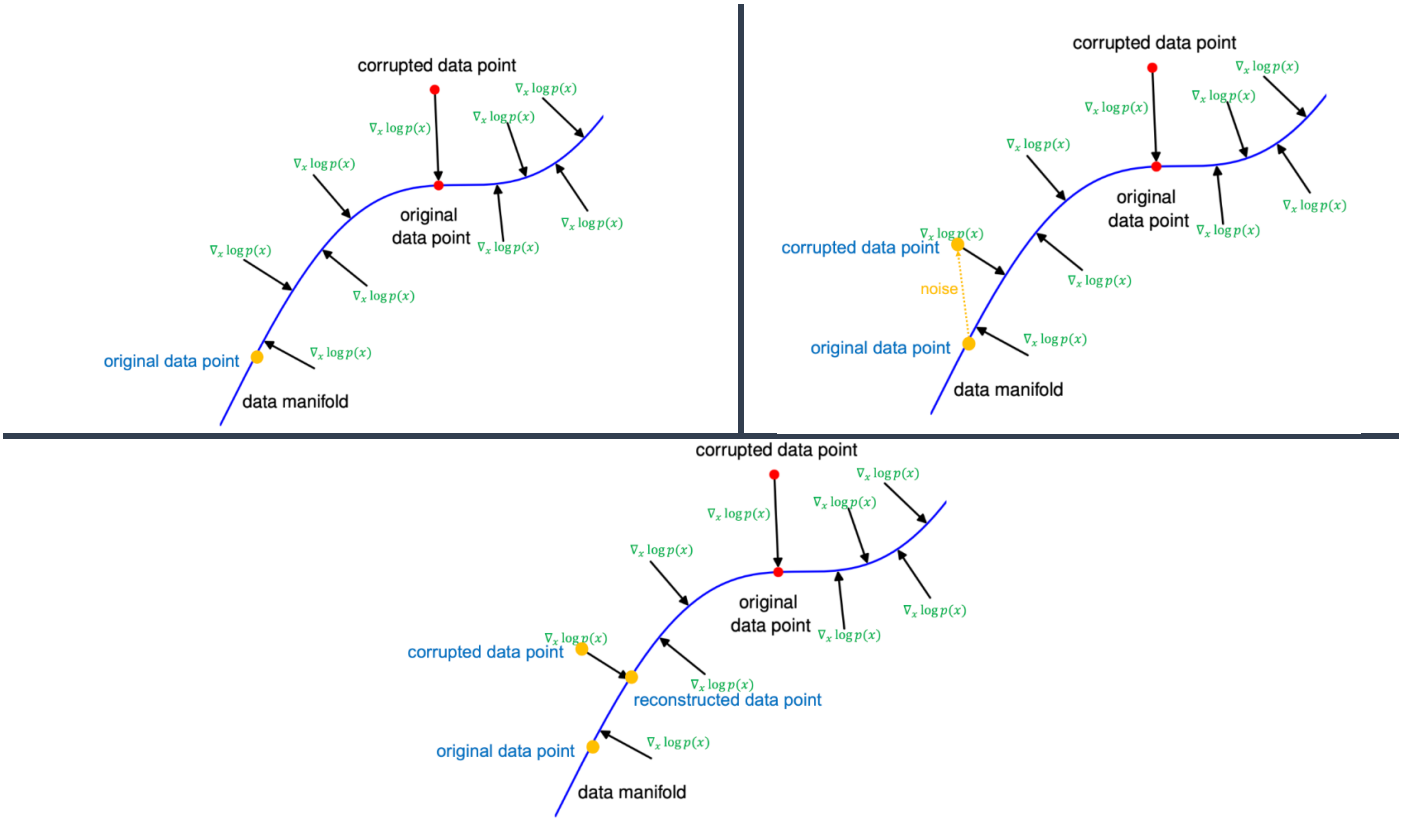


Figura 141 – Struttura del Manifold

- **Anomaly Detection:** Riconfigurare l'Autoencoder come sentinella preventiva si è confermata la strategia più robusta dell'intero progetto. Invece di purificare l'immagine, il sistema calcola l'errore di ricostruzione (MSE). Poiché gli Esempi Avversari generano una discrepanza matematica nettamente superiore rispetto alle immagini legittime bloccando l'input prima che raggiunga il classificatore facciale. Il più grande punto di forza è la sua natura agnostica: non dovendo conoscere l'algoritmo di attacco, offre un potere discriminativo elevatissimo.

6.2. SVILUPPI FUTURI

Alla luce dei risultati empirici e teorici ottenuti, tra i meccanismi di difesa che volevamo implementare nella nostra soluzione rientra la **Purificazione Generativa** **(Diffusion Models)**. Nel campo della *Detection* e *Purification*, i classici filtri lineari e le reti discriminatorie binarie si stanno rivelando obsoleti. Uno sviluppo promettente prevede l'uso di Modelli Generativi Denoising (come i *Diffusion Models*), capaci di fare *reverse-engineering* dell'immagine in input proiettandola in uno spazio di rumore e ricostruendo un volto pulito condizionato dalla semantica originale, distruggendo completamente il *pattern* avversario introdotto dall'attaccante.